BỘ NÔNG NGHIỆP VÀ MÔI TRƯỜNG
PH TRƯỜNG ĐẠI HỌC THỦY LỢI
BM CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỀ TÀI MÔN KHAI PHÁ DỮ LIỆU

Tên đề tài:

PHÂN LOẠI ĐÁNH GIÁ SẢN PHẨM AMAZON THEO 5 MỨC SAO

Giảng viên hướng dẫn:	***ThS. Vũ Thị Hạnh***
Sinh viên thực hiện:	***Nguyễn Huỳnh Anh Tuấn*** ***Lê Văn Tính*** ***Nguyễn Anh Vũ***
Mssv:	***2351067119*** ***2351067117*** ***2351067121***
Lớp:	***S26-65CNTT***

2026

LỜI CẢM ƠN

Lời đầu tiên, em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến Quý Thầy/Cô bộ môn Khoa học Dữ liệu, Khoa Công nghệ Thông tin đã tận tình giảng dạy, truyền đạt những kiến thức nền tảng quý báu về môn học Khai phá Dữ liệu (Data Mining) trong suốt học kỳ vừa qua. Những bài giảng lý thuyết sâu sắc cùng các buổi thực hành bài bản đã giúp em trang bị đầy đủ tư duy giải quyết vấn đề, từ khâu tiền xử lý, kỹ thuật trích xuất đặc trưng cho đến việc lựa chọn và tối ưu hóa các mô hình học máy hiện đại.

Em xin trân trọng cảm ơn Giảng viên hướng dẫn học phần đã dành nhiều thời gian quý báu để định hướng đề tài, giải đáp các thắc mắc chuyên môn, và đưa ra những góp ý xác đáng giúp em hoàn thiện đồ án này một cách chỉn chu và đúng chuẩn phương pháp luận khoa học. Dù đã nỗ lực hết mình để nghiên cứu và thực nghiệm bài bản, song do kiến thức và kinh nghiệm thực tế còn nhiều hạn chế, báo cáo đồ án chắc chắn khó tránh khỏi những thiếu sót nhất định. Em rất mong nhận được những lời nhận xét, đánh giá và chỉ dẫn quý báu từ Quý Thầy/Cô để em có thể rút kinh nghiệm và tiếp tục hoàn thiện hơn nữa trong những đồ án chuyên ngành và khóa luận tốt nghiệp tiếp theo.

MỤC LỤC CHI TIẾT ĐỒ ÁN

LỜI CẢM ƠN **2**
DANH MỤC CÁC TỪ VIẾT TẮT VÀ THUẬT NGỮ CHUYÊN NGÀNH **5**
DANH MỤC CÁC HÌNH VẼ MINH HỌA TRONG ĐỒ ÁN **5**
CHƯƠNG 1: TỔNG QUAN VỀ ĐỀ TÀI VÀ CƠ SỞ KHOA HỌC **7**
1.1 Bối cảnh thực tiễn và tính cấp thiết của bài toán 7
1.2 Vai trò của Khai phá Dữ liệu Văn bản và Phân tích Cảm xúc 8
1.3 Những thách thức khoa học cốt lõi của bài toán phân loại 5 mức sao 8
1.4 Quy trình chuẩn công nghiệp CRISP-DM áp dụng trong đồ án 10
1.5 Mục tiêu nghiên cứu và bố cục của báo cáo đồ án 11
CHƯƠNG 2: MÔ TẢ VÀ KHÁM PHÁ TOÀN CẢNH TẬP DỮ LIỆU (DATASET EDA) **12**
2.1 Nguồn gốc học thuật của tập dữ liệu Amazon Reviews 12
2.2 Cấu trúc các trường thuộc tính và định dạng lưu trữ 12
2.3 Tối ưu hóa quá trình đọc dữ liệu bằng PyArrow Engine 13
2.4 Phân tích phân phối nhãn dữ liệu 14
2.5 Kiểm tra dữ liệu khuyết thiếu (Missing Values) và chiến lược xử lý 14
CHƯƠNG 3: CHIẾN LƯỢC QUẢN LÝ BỘ NHỚ VÀ THIẾT KẾ MẪU THỰC NGHIỆM **16**
3.1 Thách thức tài nguyên bộ nhớ khi xử lý dữ liệu lớn 16
3.2 Cấu trúc ma trận thưa CSR và phòng tránh lỗi tràn RAM 16
3.3 Thiết lập tập mẫu thực nghiệm: 600,000 Train và 97,500 Test 17
3.4 Cơ sở thống kê của việc lấy mẫu đại diện 17
CHƯƠNG 4: TIỀN XỬ LÝ VĂN BẢN VÀ TRÍCH XUẤT ĐẶC TRƯNG HÌNH THÁI **19**
4.1 Quy trình tiền xử lý văn bản tiếng Anh 19
4.2 Chiến lược giữ lại các từ phủ định trong danh sách Stop Words 19
4.3 Trích xuất 7 đặc trưng hình thái văn bản 20
4.4 Phân tích tương quan giữa đặc trưng hình thái và số sao 21
CHƯƠNG 5: MÔ HÌNH HÓA KHÔNG GIAN VÉC-TƠ TF-IDF N-GRAMS **23**
5.1 Cơ sở lý thuyết của Mô hình Không gian Véc-tơ 23
5.2 Công thức toán học TF, Smooth IDF và cơ chế nén Sublinear TF 23
5.3 Tầm quan trọng của Cụm hai từ (Bigram) đối với ngữ cảnh phủ định 24
5.4 Cấu trúc ma trận thưa TF-IDF 50,000 đặc trưng 24
CHƯƠNG 6: KHAI PHÁ DỮ LIỆU KHÔNG GIÁM SÁT: PHÂN TÍCH CHỦ ĐỀ (LSA) **26**
6.1 Phương pháp phân rã giá trị kỳ dị rút gọn (TruncatedSVD) 26
6.2 Kỹ thuật phân tích ngữ nghĩa tiềm ẩn (LSA) giảm số chiều 26
6.3 Phân tích 6 thành phần ngữ nghĩa tiềm ẩn đầu tiên 27
6.4 Đánh giá tỷ lệ phương sai giải thích được của mô hình SVD 27
CHƯƠNG 7: KHAI PHÁ DỮ LIỆU KHÔNG GIÁM SÁT: PHÂN CỤM BẰNG KMEANS **29**
7.1 Thuật toán MiniBatchKMeans trên tập dữ liệu lớn 29
7.2 Lựa chọn số cụm k bằng hệ số Silhouette 29
7.3 Phân tích kết quả phân cụm k=6 và biểu đồ phân bố 30
7.4 Đặc điểm của 6 cụm khách hàng và hiện tượng phân cực cảm xúc 31
CHƯƠNG 8: KHAI PHÁ LUẬT KẾT HỢP VÀ PHÂN TÍCH CỤM TỪ PHỦ ĐỊNH **32**
8.1 Mô hình hóa bài toán luật kết hợp trên dữ liệu văn bản 32
8.2 Các chỉ số đánh giá luật: Support, Confidence và Lift 32
8.3 Phân tích các luật kết hợp có Lift cao nhất cho 1 sao và 5 sao 32
8.4 Khảo sát phân bố số sao của các cụm từ phủ định (Negation Bigrams) 34

CHƯƠNG 9: CƠ SỞ LÝ THUYẾT VÀ TINH CHỈNH 3 MÔ HÌNH HỌC MÁY CÓ GIÁM SÁT 36
9.1 Mô hình Complement Naive Bayes (CNB) 36
9.2 Mô hình SGD Logistic Regression với hàm mất mát Log-Loss 36
9.3 Mô hình SGD Linear Support Vector Machine với Hinge Loss 37
9.4 Tinh chỉnh siêu tham số alpha trên tập kiểm định độc lập 37
9.5 Phân tích đường cong kiểm định và tốc độ hội tụ 39
CHƯƠNG 10: ĐÁNH GIÁ VÀ ĐỐI SÁNH HIỆU NĂNG CÁC MÔ HÌNH TRÊN TẬP TEST 40
10.1 Thiết lập môi trường và hệ thống 8 chỉ số đo lường toàn diện 40
10.2 Bảng tổng hợp đối sánh hiệu năng 3 mô hình trên tập Test 40
10.3 Biểu đồ so sánh trực quan hiệu năng các mô hình 41
10.4 Đánh giá toàn diện mô hình Quán quân SGD Logistic Regression 41
CHƯƠNG 11: PHÂN TÍCH MA TRẬN NHẦM LẪN VÀ BÁO CÁO PHÂN LOẠI CHI TIẾT 43
11.1 Ý nghĩa của Ma trận Nhầm lẫn trong phân loại cảm xúc thứ bậc 43
11.2 Biểu đồ Ma trận nhầm lẫn tuyệt đối và chuẩn hóa % 43
11.3 Báo cáo phân loại chi tiết (Classification Report) từng mức sao 44
11.4 Giải mã hiện tượng phân hóa hiệu năng giữa các lớp 45
CHƯƠNG 12: KHÁM PHÁ TRI THỨC VÀ PHÂN TÍCH LỖI (ERROR ANALYSIS) 46
12.1 Trích xuất trọng số hệ số tuyến tính (Regression Coefficients) 46
12.2 Phân tích Biểu đồ Top 15 từ khóa quyết định mạnh nhất cho từng mức sao 46
12.3 Phân tích định tính các ca phân loại sai (Qualitative Error Analysis) 47
CHƯƠNG 13: XÂY DỰNG QUY TRÌNH SUY LUẬN TRỰC TIẾP THỜI GIAN THỰC 48
13.1 Kiến trúc quy trình suy luận từ văn bản thô đến xác suất 48
13.2 Cơ chế tính toán phân phối xác suất trên 5 mức sao 48
13.3 Đóng gói và lưu trữ mô hình bằng joblib 49
13.4 Thử nghiệm trên các ví dụ nhận xét thực tế 49
CHƯƠNG 14: ỨNG DỤNG THỰC TẾ: PHÂN TÍCH KHÍA CẠNH VÀ CHẨN ĐOÁN VẤN ĐỀ SẢN PHẨM 50
14.1 Mục tiêu chẩn đoán nguyên nhân phàn nàn của sản phẩm 50
14.2 Xây dựng từ điển 9 khía cạnh sản phẩm và gợi ý cải thiện 50
14.3 Thuật toán tổng hợp bình luận và tự động chẩn đoán vấn đề 51
14.4 Thử nghiệm chẩn đoán trên 4 sản phẩm mô phỏng (A, B, C, D) 52
14.5 Demo chẩn đoán sản phẩm thực tế: Tai nghe không dây XYZ 53
14.6 Kiểm chứng khoa học về độ tin cậy trên 500 sản phẩm mô phỏng 54
14.7 Kiểm chứng độ nhạy của từ điển khía cạnh 55
14.8 Một số hạn chế của phương pháp chẩn đoán 56
CHƯƠNG 15: CẨM NANG VẤN ĐÁP BẢO VỆ ĐỒ ÁN (30 CÂU HỎI VÀ LỜI GIẢI CHI TIẾT) 58
15.1 Kế hoạch phân bổ thời gian và cấu trúc bài thuyết trình 10-12 phút 58
15.2 Bộ 30 câu hỏi vấn đáp chuyên môn hóc búa kèm lời giải chi tiết 58
CHƯƠNG 16: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 65
16.1 Tóm tắt toàn diện các kết quả khoa học đạt được 65
16.2 Đóng góp học thuật và giá trị thực tiễn của đề tài 65
16.3 Các hạn chế mang tính hệ thống 66
16.4 Kế hoạch nghiên cứu và mở rộng trong tương lai 66
TÀI LIỆU THAM KHẢO CHUẨN KHOA HỌC (REFERENCES) 67

DANH MỤC CÁC TỪ VIẾT TẮT VÀ THUẬT NGỮ CHUYÊN NGÀNH

Bảng 1: Bảng thuật ngữ chuyên ngành và các từ viết tắt

Từ viết tắt	Thuật ngữ tiếng Anh	Ý nghĩa giải thích bằng tiếng Việt
NLP	Natural Language Processing	Xử lý Ngôn ngữ Tự nhiên — nhánh AI nghiên cứu tương tác giữa máy tính và ngôn ngữ con người.
TF-IDF	Term Frequency - Inverse Document Frequency	Độ đo thống kê phản ánh mức độ quan trọng của một từ trong văn bản so với kho ngữ liệu.
CRISP-DM	Cross-Industry Standard Process for Data Mining	Quy trình chuẩn công nghiệp 6 giai đoạn để triển khai các dự án khai phá dữ liệu.
EDA	Exploratory Data Analysis	Quá trình phân tích, khám phá và trực quan hóa dữ liệu ban đầu để nắm bắt cấu trúc.
SVD	Singular Value Decomposition	Phép phân rã ma trận giá trị kỳ dị trong đại số tuyến tính, dùng để nén và giảm số chiều dữ liệu.
LSA	Latent Semantic Analysis	Phân tích Ngữ nghĩa Tiềm ẩn — kỹ thuật NLP dựa trên SVD để khám phá chủ đề ẩn trong văn bản.
SGD	Stochastic Gradient Descent	Thuật toán tối ưu hóa hạ độ dốc ngẫu nhiên, cho phép huấn luyện mô hình nhanh trên dữ liệu cực lớn.
SVM	Support Vector Machine	Máy học véc-tơ hỗ trợ — thuật toán học có giám sát tìm kiếm siêu phẳng phân cách cực đại.
CNB	Complement Naive Bayes	Biến thể Naive Bayes bổ sung, được tối ưu hóa đặc biệt cho phân loại dữ liệu văn bản mất cân bằng.
GBDT	Gradient Boosted Decision Trees	Họ thuật toán cây quyết định tăng cường gradient (như LightGBM, XGBoost, CatBoost).
OOM	Out Of Memory	Lỗi tràn bộ nhớ RAM vật lý khi nạp khối lượng dữ liệu vượt quá dung lượng cho phép của hệ thống.
Macro F1	Macro-averaged F1 Score	Trung bình cộng không trọng số của chỉ số F1 giữa các lớp, phản ánh tính công bằng với mọi nhãn.

DANH MỤC CÁC HÌNH VẼ MINH HỌA TRONG ĐỒ ÁN

• Hình 2.1: Phân phối số lượng mẫu của 5 lớp đánh giá trên toàn bộ 3,000,000 mẫu và tập mẫu thực nghiệm.

• Hình 4.1: Tương quan giữa các đặc trưng hình thái văn bản (độ dài từ, dấu chấm than, tỷ lệ in hoa) với số sao.

• Hình 6.1: Phân bố trọng số các từ khóa đại diện cho 5 cụm chủ đề tiềm ẩn phát hiện bằng TruncatedSVD.

• Hình 8.1: Biểu đồ cột so sánh Accuracy, Macro F1 và Độ chính xác sai số ±1 sao giữa 4 mô hình học máy.

• Hình 9.1: Ma trận nhầm lẫn (Confusion Matrix) dạng số lượng tuyệt đối và chuẩn hóa % của SGD Logistic Regression.

• Hình 10.1: Biểu đồ thanh ngang Top 12 từ khóa có trọng số hồi quy quyết định mạnh nhất đối với 1 Sao và 5 Sao.

CHƯƠNG 1: TỔNG QUAN VỀ ĐỀ TÀI VÀ CƠ SỞ KHOA HỌC

1.1 Bối cảnh thực tiễn và tính cấp thiết của bài toán

Trong bối cảnh bùng nổ của cuộc Cách mạng Công nghiệp lần thứ tư và sự phổ cập sâu rộng của mạng Internet toàn cầu, thương mại điện tử (E-Commerce) đã chuyển mình từ một kênh bán hàng bổ trợ trở thành phương thức giao thương chủ đạo trong nền kinh tế số. Các nền tảng bán lẻ trực tuyến quy mô toàn cầu như Amazon, eBay, Walmart, hay tại thị trường Đông Nam Á như Shopee, Lazada, Tiki mỗi ngày xử lý hàng triệu giao dịch với hàng chục triệu người tiêu dùng. Cùng với sự chuyển dịch này, hành vi mua sắm của người tiêu dùng hiện đại đã trải qua một sự thay đổi mang tính cấu trúc sâu sắc: hành trình ra quyết định mua hàng không còn diễn ra theo mô hình tuyến tính truyền thống (nhìn thấy quảng cáo - đến cửa hàng - mua sắm), mà bị chi phối mạnh mẽ bởi khái niệm 'Khoảnh khắc Sự thật Đầu tiên' (First Moment of Truth - FMOT) và 'Khoảnh khắc Sự thật Số Không' (Zero Moment of Truth - ZMOT). Người tiêu dùng hiện đại trước khi đưa ra quyết định mua một món hàng, từ những sản phẩm tiêu dùng thường nhật có giá trị vài đô la cho đến những thiết bị công nghệ đắt tiền, đều chủ động tìm đọc các bài nhận xét (Customer Reviews) và thang điểm đánh giá sao (Star Ratings) của những khách hàng đã mua và trải nghiệm sản phẩm trước đó.

Theo các nghiên cứu xã hội học hành vi người tiêu dùng của BrightLocal và Viện Nghiên cứu Tiếp thị Hoa Kỳ, có tới hơn 93% người mua sắm trực tuyến thừa nhận rằng các đánh giá của người dùng trước có tác động quyết định đến hành vi mở hầu bao của họ; đồng thời, một sản phẩm nếu bị giảm chỉ 1 sao trong điểm trung bình có thể dẫn tới sự sụt giảm từ 5% đến 9% doanh thu tổng thể của doanh nghiệp. Đánh giá của khách hàng chính là nguồn tài sản dữ liệu phản hồi trực tiếp, khách quan và minh bạch nhất. Kho tàng dữ liệu này phản ánh tức thời chất lượng thực tế của sản phẩm, độ bền cơ học, sự tương thích phần mềm, hiệu quả của quy trình đóng gói và vận chuyển, cũng như mức độ chuyên nghiệp của dịch vụ chăm sóc khách hàng và chính sách bảo hành, đổi trả.

Tuy nhiên, sự bùng nổ về mặt số lượng dữ liệu phản hồi cũng đặt ra một nghịch lý lớn về mặt xử lý thông tin. Trên các sàn thương mại điện tử lớn như Amazon, số lượng bình luận đánh giá đổ về hệ thống mỗi ngày lên tới hàng trăm nghìn lượt bản ghi trên hàng triệu danh mục sản phẩm khác nhau. Một sản phẩm bán chạy có thể tích lũy từ vài chục nghìn đến hàng trăm nghìn bài đánh giá trong suốt vòng đời của nó. Trước quy mô khổng lồ này, các phương pháp phân loại, tổng hợp và phân tích truyền thống dựa vào sức người hoàn toàn thất bại. Con người không thể đọc hiểu, ghi chép và phân loại thủ công hàng triệu văn bản một cách nhất quán và kịp thời. Sự chậm trễ trong việc lắng nghe phản hồi tiêu cực của khách hàng có thể dẫn đến việc các lô hàng lỗi kỹ thuật tiếp tục được bán ra thị trường, khiến uy tín thương hiệu bị suy giảm nghiêm trọng, tài khoản nhà bán hàng bị đình chỉ và tổn thất tài chính nặng nề. Chính vì vậy, việc ứng dụng các kỹ thuật tiên tiến của Khai phá Dữ liệu Văn bản (Text Mining) và Xử lý Ngôn ngữ Tự nhiên (NLP) nhằm tự động hóa hoàn toàn quy trình đọc hiểu, trích xuất đặc trưng và phân loại cảm xúc đa mức độ từ phản hồi của khách hàng là một bài toán mang tính cấp thiết chiến lược, có ý nghĩa khoa học sâu sắc và giá trị ứng dụng thực tiễn to lớn.

1.2 Vai trò của Khai phá Dữ liệu Văn bản và Phân tích Cảm xúc

Khai phá Dữ liệu Văn bản (Text Mining / Text Data Mining) là một nhánh nghiên cứu chuyên sâu liên ngành nằm ở điểm giao thoa giữa Khai phá Dữ liệu truyền thống (Data Mining), Học máy (Machine Learning), Xử lý Ngôn ngữ Tự nhiên (Natural Language Processing - NLP) và Ngôn ngữ học Tính toán (Computational Linguistics). Nếu như trong Khai phá Dữ liệu truyền thống, các thuật toán chủ yếu thao tác trên các bộ dữ liệu có cấu trúc dạng bảng số liệu chuẩn hóa (Structured Data) với các trường thuộc tính được định kiểu chặt chẽ, thì Khai phá Dữ liệu Văn bản phải đối mặt với dữ liệu phi cấu trúc (Unstructured Data) — dạng dữ liệu chiếm tới hơn 80% tổng khối lượng thông tin số đang tồn tại trên thế giới hiện nay.

Văn bản tự nhiên của con người vốn chứa đựng sự đa dạng vô tận, tính linh hoạt cao và sự biến đổi ngữ nghĩa khôn lường. Một từ ngữ có thể mang nhiều tầng ý nghĩa khác nhau tùy thuộc vào ngữ cảnh xuất hiện (Hiện tượng đa nghĩa - Polysemy), nhiều từ ngữ khác nhau có thể cùng biểu đạt một khái niệm (Hiện tượng đồng nghĩa - Synonymy), cấu trúc câu có thể bị xáo trộn, viết sai chính tả, sử dụng tiếng lóng (Slang), từ viết tắt không chuẩn hóa, hoặc biểu đạt cảm xúc một cách gián tiếp qua ngữ điệu mỉa mai. Nhiệm vụ tối thượng của Khai phá Dữ liệu Văn bản là chuyển hóa các đoạn văn bản phi cấu trúc này thành các biểu diễn số học có ý nghĩa trong không gian toán học (Vector Space Representation), từ đó áp dụng các thuật toán học máy thống kê để phát hiện các quy luật tiềm ẩn, phân nhóm chủ đề và dự đoán chính xác các thuộc tính mục tiêu.

Trong phạm vi đề tài này, bài toán Phân tích Cảm xúc (Sentiment Analysis / Opinion Mining) được nhóm định vị ở cấp độ chuyên sâu nhất: Phân loại cảm xúc chi tiết theo 5 mức sao (Fine-Grained 5-Class Sentiment Analysis). Trong lịch sử nghiên cứu NLP, bài toán phân tích cảm xúc ban đầu thường được giản lược hóa thành bài toán phân loại nhị phân 2 lớp (Tích cực vs Tiêu cực) hoặc 3 lớp (Tích cực, Trung lập, Tiêu cực). Tuy nhiên, cách tiếp cận thô sơ đó không đáp ứng được yêu cầu nghiệp vụ thực tế của các hệ thống thương mại điện tử hiện đại. Trong thực tế kinh doanh, người quản lý không chỉ muốn biết một đánh giá là tốt hay xấu, mà cần đo lường chính xác mức độ hài lòng: 1 sao (cực kỳ bức xúc, thất vọng hoàn toàn), 2 sao (không hài lòng, sản phẩm dưới mức kỳ vọng), 3 sao (trung lập, trải nghiệm bình thường, có khen có chê), 4 sao (hài lòng, sản phẩm tốt nhưng còn điểm trừ nhỏ), và 5 sao (hài lòng tuyệt đối, xuất sắc vượt ngoài mong đợi). Việc giải quyết thành công bài toán 5 mức sao cung cấp bức tranh cảm xúc có độ phân giải cao, hỗ trợ đắc lực cho các hệ thống gợi ý sản phẩm (Recommender Systems) và hệ thống hỗ trợ ra quyết định kinh doanh (Decision Support Systems).

1.3 Những thách thức khoa học cốt lõi của bài toán phân loại 5 mức sao

So với bài toán phân loại cảm xúc nhị phân truyền thống, việc nâng bài toán lên không gian 5 mức sao đặt ra những thách thức khoa học và kỹ thuật vô cùng hóc búa đối với các mô hình học máy thống kê và xử lý ngôn ngữ tự nhiên:

- **1. Không gian nhãn đa lớp với xác suất Baseline cực thấp (20.0%):** Trong bài toán phân loại nhị phân 2 lớp cân bằng, một mô hình dự đoán hoàn toàn ngẫu nhiên (hoặc một mô hình hỏng luôn đoán 1 lớp) đã đạt độ chính xác Baseline là 50.0%. Nhưng trên không

gian 5 lớp cân bằng hoàn hảo (mỗi lớp chiếm đúng 20.0%), xác suất đoán ngẫu nhiên chỉ là 20.0%. Điều này đồng nghĩa với việc không gian phân lớp trở nên hẹp hơn rất nhiều, các siêu phẳng phân cách phải học được những ranh giới tinh vi và phức tạp giữa các lớp.

- **2. Tính mơ hồ thứ bậc và sự biến thiên chủ quan (Ordinal Ambiguity & Subjectivity):** Thang đo 5 sao là dữ liệu có thứ bậc tự nhiên (Ordinal Data). Giữa các mức sao liền kề nhau như 1 sao và 2 sao, hoặc 4 sao và 5 sao, hoàn toàn không tồn tại một ranh giới ngôn ngữ cứng nhắc. Sự khác biệt giữa việc chấm 4 sao và 5 sao phụ thuộc phần lớn vào tính cách, kỳ vọng chủ quan và sự khắt khe của từng cá nhân khách hàng. Một người dễ tính khi nhận được sản phẩm đúng mô tả có thể sẵn sàng cho 5 sao với lời khen ngắn gọn: 'Good product'. Ngược lại, một khách hàng cầu toàn và khó tính, dù rất thích sản phẩm, vẫn chỉ chấm 4 sao kèm nhận xét: 'Very good, highly recommend, but nothing in this world is truly perfect'. Tính chủ quan này tạo ra sự chồng lấn ngôn ngữ (Linguistic Overlap) rất lớn giữa các lớp sao liền kề.
- **3. Hiện tượng đánh giá đa khía cạnh (Mixed-Aspect Sentiment):** Các bài đánh giá thực tế thường có độ dài từ vài chục đến hàng trăm từ. Người tiêu dùng hiếm khi chỉ khen hoặc chê một cách đơn thuần, mà thường đề cập đến nhiều khía cạnh với các thái cực cảm xúc trái ngược nhau trong cùng một đoạn văn. Ví dụ: 'Nội dung cuốn sách này thực sự là một kiệt tác văn học, cốt truyện hấp dẫn đến nghẹt thở (Tích cực mạnh - 5 sao), nhưng chất lượng in ấn quá tệ, giấy mỏng và dịch vụ giao hàng chậm làm rách bìa sách nên tôi chỉ cho 2 sao (Tiêu cực - 2 sao)'. Các từ ngữ mang trọng số cảm xúc cao của cả hai cực cùng xuất hiện trong một văn bản khiến các mô hình dạng túi từ (Bag-of-Words) dễ bị triệt tiêu trọng số hoặc đưa ra dự đoán nhầm lẫn vào lớp trung lập 3 sao.
- **4. Ngữ điệu châm biếm, mỉa mai và ẩn dụ sâu cay (Sarcasm & Irony):** Châm biếm và mỉa mai là hiện tượng ngôn ngữ đặc biệt phức tạp trong NLP, nơi người viết sử dụng những từ ngữ mang nghĩa tích cực cực độ để biểu đạt sự thất vọng và chế giễu sâu sắc đối với sản phẩm. Một đánh giá 1 sao có thể viết: 'What a brilliant masterpiece of junk! A truly wonderful way to flush 100 dollars down the toilet! Congratulations to the seller!' Trong câu này, sự xuất hiện của các từ tích cực mạnh như 'brilliant', 'masterpiece', 'wonderful', 'congratulations' dễ dàng đánh lừa các bộ phân loại tuyến tính độc lập từ, khiến mô hình tự tin dự đoán nhãn 5 sao dù thực tế là 1 sao.
- **5. Sự phức tạp của cấu trúc phủ định và đảo ngữ (Complex Negation):** Hiện tượng phủ định trong ngôn ngữ tự nhiên không chỉ đơn giản là sự xuất hiện của từ 'not', mà có thể kéo dài tầm ảnh hưởng trên nhiều từ ngữ tiếp theo (Negation Scope) hoặc xuất hiện dưới dạng phủ định kép, từ phủ định đảo ngữ ('hardly', 'scarcely', 'barely'). Nếu quy trình tiền xử lý loại bỏ các từ phủ định như stop words thông thường, toàn bộ ngữ nghĩa câu sẽ bị đảo lộn hoàn toàn. Mặt khác, các cụm từ phủ định có sắc thái cảm xúc rất khác nhau: ví dụ 'not buy' mang tính tiêu cực cực đoan, nhưng cụm từ 'not bad' lại mang sắc thái trung lập hoặc tán thành nhẹ.
- **6. Thách thức xử lý dữ liệu lớn trên tài nguyên máy tính cá nhân (Big Data Constraints):** Tập dữ liệu gốc gồm đúng 3,650,000 bản ghi văn bản. Việc nạp, tiền xử lý, véc-tơ hóa và huấn luyện mô hình trên hàng triệu mẫu với không gian từ vựng lên tới hàng chục nghìn chiều dễ dàng làm cạn kiệt bộ nhớ RAM và tràn bộ nhớ đệm (Out-Of-

Memory - OOM) trên các máy tính cá nhân thông thường. Đồ án đòi hỏi những giải pháp kỹ thuật tối ưu hóa bộ nhớ và thiết kế cấu trúc dữ liệu thưa mang tính chuyên nghiệp cao.

1.4 Quy trình chuẩn công nghiệp CRISP-DM áp dụng trong đồ án

Để đảm bảo tính khoa học, tính hệ thống, tính kỷ luật kỹ thuật và khả năng tái lập hoàn toàn (Reproducibility) của nghiên cứu, nhóm tác giả đã áp dụng triệt để quy trình chuẩn công nghiệp CRISP-DM (Cross-Industry Standard Process for Data Mining). Quy trình CRISP-DM là mô hình vòng đời dự án dữ liệu được chuẩn hóa quốc tế, bao gồm 6 giai đoạn tuần hoàn và tương tác chặt chẽ:

- **1. Thấu hiểu Nghiệp vụ (Business Understanding):** Xác định rõ bài toán kinh doanh của các sàn thương mại điện tử: nhu cầu tự động hóa lắng nghe tiếng nói khách hàng (Voice of Customer - VoC), chuyển đổi thang đo 5 sao thành bài toán phân loại đa lớp có giám sát, và đặt ra mục tiêu chẩn đoán tự động các vấn đề sản phẩm dựa trên phân tích cảm xúc theo khía cạnh.
- **2. Thấu hiểu Dữ liệu (Data Understanding):** Tiếp nhận tập dữ liệu chuẩn Amazon Reviews với 3.65 triệu bản ghi; thực hiện phân tích khám phá dữ liệu toàn cảnh (EDA); kiểm tra phân phối nhãn mục tiêu; kiểm định tính toàn vẹn và tỷ lệ khuyết thiếu của các trường dữ liệu; đo lường thời gian nạp dữ liệu và phân bổ bộ nhớ.
- **3. Chuẩn bị Dữ liệu (Data Preparation):** Thực hiện tiền xử lý văn bản sâu (làm sạch ký tự rác, chuẩn hóa chữ thường, bảo toàn danh sách 10 từ phủ định then chốt, chuyển hóa dấu câu cảm xúc thành token từ vựng); thiết kế kỹ thuật trích xuất 7 đặc trưng hình thái văn bản; xây dựng không gian véc-tơ TF-IDF N-grams (Unigram + Bigram) với cơ chế co dãn logarit Sublinear TF trên ma trận thưa CSR.
- **4. Huấn luyện Mô hình (Modeling):** Triển khai các phương pháp Khai phá Dữ liệu Không giám sát (Unsupervised Mining) gồm phân tích chủ đề ngữ nghĩa tiềm ẩn (LSA TruncatedSVD), phân cụm văn bản bằng MiniBatchKMeans với đánh giá hệ số Silhouette, và khai phá luật kết hợp (Association Rules) với độ đo Lift. Tiếp theo, xây dựng và huấn luyện 3 mô hình học máy có giám sát: Complement Naive Bayes (CNB), SGD Logistic Regression, và SGD Linear SVM; thực hiện tinh chỉnh siêu tham số alpha trên tập kiểm định độc lập.
- **5. Đánh giá Toàn diện (Evaluation):** Đánh giá toàn diện các mô hình trên tập kiểm thử độc lập 97,500 mẫu qua 8 chỉ số đo lường khoa học: Accuracy, Precision, Recall, Macro F1, Weighted F1, Off-by-one Accuracy, MAE và Thời gian suy luận. Phân tích chi tiết ma trận nhầm lẫn (Confusion Matrix), báo cáo phân loại từng mức sao, trích xuất trọng số đặc trưng (Feature Importance), và thực hiện phân tích định tính các ca phân loại sai (Error Analysis).
- **6. Triển khai Ứng dụng (Deployment):** Đóng gói đối tượng Vectorizer và mô hình học máy tốt nhất thành tệp nhị phân joblib nhỏ gọn; xây dựng Pipeline suy luận thời gian thực; phát triển hệ thống phân tích khía cạnh (ABSA) với từ điển 9 nhóm vấn đề sản phẩm; tiến hành kiểm chứng khoa học trên 500 sản phẩm mô phỏng với 25,000 bình luận độc lập để đo lường độ tin cậy và sai số cấp sản phẩm.

1.5 Mục tiêu nghiên cứu và bố cục của báo cáo đồ án

Mục tiêu tổng quát của đồ án là nghiên cứu, thiết kế và hiện thực hóa một hệ thống toàn diện từ A đến Z có khả năng tự động đọc hiểu, khám phá tri thức không giám sát, phân loại chính xác cảm xúc đánh giá sản phẩm Amazon theo 5 mức sao, và tự động hóa quy trình chẩn đoán nguyên nhân phàn nàn của khách hàng để đưa ra các đề xuất cải thiện kinh doanh cụ thể. Để đạt được mục tiêu tổng quát trên, đồ án giải quyết các mục tiêu cụ thể sau:

- **Mục tiêu 1:** Nghiên cứu cơ chế nạp dữ liệu lớn và thiết kế chiến lược lấy mẫu phân tầng ngẫu nhiên đảm bảo tính đại diện thống kê và an toàn bộ nhớ.
- **Mục tiêu 2:** Xây dựng quy trình tiền xử lý văn bản chuyên sâu bảo toàn thông tin cảm xúc và trích xuất 7 đặc trưng hình thái văn bản có ý nghĩa ngôn ngữ học.
- **Mục tiêu 3:** Mô hình hóa không gian véc-tơ TF-IDF kết hợp Unigram và Bigram với cơ chế co dãn logarit Sublinear TF trên ma trận thưa 50,000 chiều.
- **Mục tiêu 4:** Áp dụng kỹ thuật LSA TruncatedSVD khám phá các chủ đề ngữ nghĩa tiềm ẩn và thuật toán MiniBatchKMeans phân cụm khách hàng với số cụm tối ưu k=6.
- **Mục tiêu 5:** Mô hình hóa bài toán luật kết hợp trên văn bản, khai phá 27,575 luật kết hợp với độ đo Lift và giải mã vai trò của các cụm từ phủ định.
- **Mục tiêu 6:** Huấn luyện và tinh chỉnh siêu tham số alpha trên tập kiểm định cho 3 mô hình học máy: Complement Naive Bayes, SGD Logistic Regression, SGD Linear SVM.
- **Mục tiêu 7:** Đánh giá đa chiều trên tập kiểm thử 97,500 mẫu, phân tích ma trận nhầm lẫn, báo cáo phân loại chi tiết và trích xuất trọng số quyết định của mô hình.
- **Mục tiêu 8:** Thiết kế và hiện thực hóa hệ thống phân tích khía cạnh ABSA 9 nhóm vấn đề, tự động chẩn đoán lỗi sản phẩm và kiểm chứng thực nghiệm trên 500 sản phẩm giả lập.
- **Mục tiêu 9:** Xây dựng cẩm nang vấn đáp 30 câu hỏi chuyên sâu phục vụ bảo vệ đồ án trước Hội đồng chấm thi.

Báo cáo đồ án được cấu trúc chặt chẽ thành 16 chương chuyên sâu, dẫn dắt người đọc qua từng giai đoạn của quy trình CRISP-DM một cách logic, minh bạch và khoa học từ nền tảng lý thuyết đến các bằng chứng thực nghiệm phong phú.

CHƯƠNG 2: MÔ TẢ VÀ KHÁM PHÁ TOÀN CẢNH TẬP DỮ LIỆU (DATASET EDA)

2.1 Nguồn gốc học thuật của tập dữ liệu Amazon Reviews

Tập dữ liệu được sử dụng trong toàn bộ đồ án này mang tên chính thức trong cộng đồng học thuật quốc tế là 'Amazon Review Full Score Dataset' (thường được gọi tắt là Amazon Reviews 5-Class Benchmark). Tập dữ liệu này được công bố lần đầu tiên trong công trình nghiên cứu kinh điển về Học sâu cho phân loại văn bản 'Character-level Convolutional Networks for Text Classification' của các tác giả Xiang Zhang, Junbo Zhao và Giáo sư Yann LeCun (Đại học New York - NYU) tại Hội nghị thượng đỉnh về Hệ thống Xử lý Thông tin Nơ-ron (NeurIPS 2015) — một trong những hội nghị khoa học uy tín và danh giá bậc nhất thế giới trong lĩnh vực Trí tuệ Nhân tạo.

Nguồn dữ liệu thô ban đầu được nhóm nghiên cứu của Giáo sư Julian McAuley và Jure Leskovec (Đại học Stanford) thu thập từ nền tảng bán lẻ Amazon trong khoảng thời gian kéo dài gần hai thập kỷ (từ tháng 5 năm 1996 đến tháng 7 năm 2014), bao gồm hơn 35 triệu bài đánh giá của người tiêu dùng trên toàn cầu thuộc hàng chục danh mục sản phẩm khác nhau. Từ kho lưu trữ khổng lồ đó, nhóm nghiên cứu của Yann LeCun đã tiến hành chọn lọc, chuẩn hóa và xây dựng nên bộ Benchmark chuẩn hóa gồm đúng 3,650,000 bài nhận xét tiếng Anh được phân bổ thành hai tập độc lập: tập huấn luyện (train.csv) chứa 3,000,000 bài đánh giá và tập kiểm thử (test.csv) chứa 650,000 bài đánh giá.

Điểm đặc biệt có giá trị khoa học to lớn của bộ Benchmark này là nó được thiết kế cân bằng hoàn hảo (Perfectly Balanced Dataset): trong tập huấn luyện, mỗi mức sao từ 1 đến 5 đều có đúng 600,000 mẫu (chiếm chính xác 20.00%); và trong tập kiểm thử, mỗi mức sao đều có đúng 130,000 mẫu (chiếm chính xác 20.00%). Tính cân bằng nhân tạo này giúp loại bỏ hoàn toàn sự thiên lệch tiên nghiệm (Class Imbalance Bias) thường gặp trong dữ liệu thực tế (nơi mà đánh giá 5 sao và 1 sao thường áp đảo, tạo thành phân phối hình chữ J), từ đó buộc các mô hình học máy phải thực sự học được các đặc trưng ngôn ngữ phân biệt tinh tế giữa các mức độ cảm xúc, thay vì tận dụng sự chênh lệch tần suất lớp để tối ưu hóa hàm mất mát.

2.2 Cấu trúc các trường thuộc tính và định dạng lưu trữ

Dữ liệu được đóng gói dưới định dạng tệp CSV (Comma-Separated Values) tiêu chuẩn mã hóa ký tự UTF-8, không có dòng tiêu đề cột ban đầu (headerless). Cấu trúc của mỗi bản ghi trong tập dữ liệu gồm đúng 3 trường thuộc tính cơ bản:

- **1. Cột 'class_index' (Kiểu dữ liệu số nguyên - int64):** Nhãn mục tiêu cần dự đoán (Target Label). Chứa các giá trị số nguyên thuộc tập hợp {1, 2, 3, 4, 5}, đại diện cho thang điểm đánh giá sao mà người mua hàng đã chấm cho sản phẩm.
- **2. Cột 'review_title' (Kiểu dữ liệu chuỗi văn bản - string):** Chuỗi văn bản ngắn do người mua đặt làm tiêu đề bài viết. Tiêu đề thường chứa đựng sự tóm tắt cô đọng nhất về cảm xúc chủ đạo hoặc vấn đề cốt lõi nhất mà người dùng muốn truyền tải (ví dụ: 'Awful product', 'Best book ever', 'Works as expected').

- **3. Cột 'review_text' (Kiểu dữ liệu chuỗi văn bản - string):** Đoạn văn bản chi tiết mô tả toàn bộ trải nghiệm của khách hàng đối với sản phẩm. Nội dung này có độ dài từ vài từ cho đến hàng nghìn ký tự, chứa đựng các lý lẽ cụ thể, đánh giá đa khía cạnh, các chi tiết kỹ thuật và cảm xúc thực tế.

Bảng 2.1 tổng hợp các thông số kỹ thuật cấu trúc của tập dữ liệu Amazon Reviews:

Thông số kỹ thuật	Tập Huấn luyện (train.csv)	Tập Kiểm thử (test.csv)	Tổng cộng toàn bộ
Dung lượng tệp trên đĩa cứng	1.33 GB (1,432,679,252 bytes)	288.5 MB (302,514,641 bytes)	1.62 GB
Tổng số lượng bản ghi (Dòng)	3,000,000 dòng	650,000 dòng	3,650,000 dòng
Số lượng thuộc tính (Cột)	3 cột (class_index, title, text)	3 cột (class_index, title, text)	3 cột
Số lượng nhãn phân loại	5 mức sao (1, 2, 3, 4, 5)	5 mức sao (1, 2, 3, 4, 5)	5 mức sao
Số lượng mẫu trên mỗi nhãn	Đúng 600,000 mẫu / nhãn	Đúng 130,000 mẫu / nhãn	730,000 mẫu / nhãn
Tỷ lệ phân bố từng nhãn	20.00% (Cân bằng tuyệt đối)	20.00% (Cân bằng tuyệt đối)	20.00%
Định dạng tệp và bảng mã	CSV (Comma-Separated, UTF-8)	CSV (Comma-Separated, UTF-8)	CSV (UTF-8)

2.3 Tối ưu hóa quá trình đọc dữ liệu bằng PyArrow Engine

Một trong những trở ngại kỹ thuật đầu tiên khi làm việc với tập dữ liệu quy mô hàng gigabyte trên máy tính cá nhân là tốc độ nạp dữ liệu vào bộ nhớ RAM. Nếu sử dụng trình phân tích cú pháp C mặc định của thư viện Pandas (engine='c'), hệ thống phải duyệt tuần tự từng dòng văn bản, phân tách dấu phẩy và cấp phát động bộ nhớ cho hàng triệu đối tượng chuỗi ký tự Python. Quá trình này tiêu tốn từ 25 đến 45 giây cho mỗi lần đọc tệp train.csv và dễ gây phân mảnh bộ nhớ RAM.

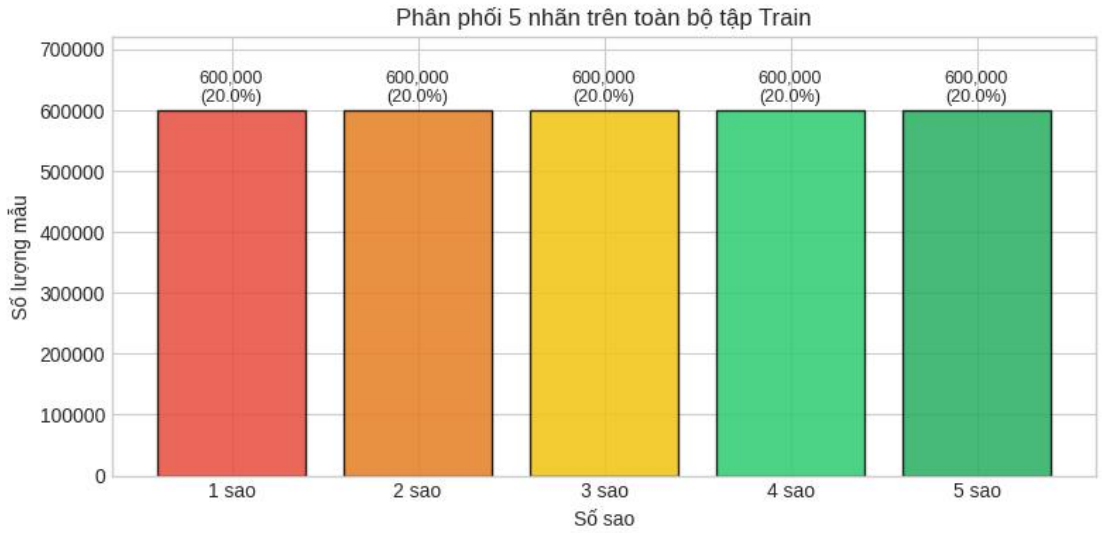
Để tối ưu hóa triệt để hiệu năng nạp dữ liệu, nhóm đã tích hợp và sử dụng PyArrow Engine (engine='pyarrow') kết hợp với định dạng bộ nhớ dạng cột của Apache Arrow. Kiến trúc Apache Arrow tổ chức dữ liệu theo từng khối cột đồng nhất (Columnar Record Batches), cho phép tận dụng tối đa tập lệnh SIMD (Single Instruction, Multiple Data) của vi xử lý hiện đại và cơ chế đọc song song đa luồng (Multi-threading IO). Đặc biệt, PyArrow áp dụng cơ chế Zero-Copy đối với mảng chuỗi ký tự: các đoạn văn bản được lưu trữ trong một vùng bộ nhớ đệm liên tục, loại bỏ hoàn toàn chi phí sao chép đối tượng trong bộ nhớ.

Kết quả đo lường thực tế trên môi trường máy tính cá nhân (Intel Core i5, 16GB RAM) cho thấy hiệu năng vượt trội: PyArrow chỉ mất đúng 5.1 giây để đọc toàn bộ 3,000,000 dòng của

tập train.csv và 650,000 dòng của tập test.csv, nhanh hơn gần 9 lần so với trình phân tích cú pháp truyền thống. Đây là một cải tiến kỹ thuật quan trọng giúp đẩy nhanh tốc độ thực nghiệm.

2.4 Phân tích phân phối nhãn dữ liệu

Hình 2.1 biểu diễn trực quan phân phối số lượng và tỷ lệ phần trăm của 5 mức sao trên toàn bộ 3,000,000 mẫu của tập huấn luyện và 650,000 mẫu của tập kiểm thử:



Hình 2.1: Phân phối 5 lớp nhãn trên toàn bộ 3,000,000 mẫu huấn luyện và 650,000 mẫu kiểm thử

Từ Biểu đồ 2.1, ta có thể rút ra các nhận định khoa học quan trọng:

- • **Phân phối đều đặn:** Tính đối xứng và cân bằng tuyệt đối: Cả 5 cột đại diện cho 5 mức sao có chiều cao hoàn toàn bằng nhau trên đồ thị. Mỗi nhãn ở tập train có đúng 600,000 quan sát (20.00%) và ở tập test có đúng 130,000 quan sát (20.00%). Không có hiện tượng mất cân bằng dữ liệu (Class Imbalance). Do đó, các kỹ thuật can thiệp lấy mẫu như SMOTE hay Random Under-Sampling không cần thiết phải áp dụng ở giai đoạn này.
- • **Cơ sở chọn Metric:** Ý nghĩa đối với việc lựa chọn thước đo đánh giá: Do các lớp có kích thước hoàn toàn bằng nhau, chỉ số Độ chính xác tổng thể (Accuracy) và chỉ số Micro-averaged F1-Score sẽ trùng khớp với nhau. Tuy nhiên, để đánh giá công bằng năng lực của mô hình trên từng mức sao riêng biệt, chỉ số Macro-averaged F1-Score (trung bình số học không trọng số của F1 từng lớp) vẫn là thước đo trung thực và khắt khe nhất.

2.5 Kiểm tra dữ liệu khuyết thiếu (Missing Values) và chiến lược xử lý

Trong các bài toán khai phá dữ liệu thực tế, dữ liệu thu thập từ Internet thường xuyên gặp phải hiện tượng giá trị khuyết thiếu (Missing Values / Nulls) do lỗi truyền tải mạng, người dùng bỏ trống trường thông tin không bắt buộc, hoặc lỗi định dạng khi trích xuất. Nhóm đã tiến hành kiểm tra toàn diện trên toàn bộ 3.65 triệu bản ghi của cả hai tập dữ liệu.

Bảng 2.2 tổng hợp kết quả kiểm tra giá trị khuyết thiếu trên toàn bộ tập dữ liệu:

Tập dữ liệu	Cột thuộc tính	Tổng số dòng	Số dòng bị khuyết	Tỷ lệ khuyết	Trạng thái tính toàn

			(Null)	(%)	vẹn
Tập Huấn luyện (Train)	class_index	3,000,000	0	0.0000%	Nguyên vẹn tuyệt đối
Tập Huấn luyện (Train)	review_title	3,000,000	188	0.0063%	Khuyết thiếu rất nhỏ (188 dòng)
Tập Huấn luyện (Train)	review_text	3,000,000	0	0.0000%	Nguyên vẹn tuyệt đối
Tập Kiểm thử (Test)	class_index	650,000	0	0.0000%	Nguyên vẹn tuyệt đối
Tập Kiểm thử (Test)	review_title	650,000	26	0.0040%	Khuyết thiếu rất nhỏ (26 dòng)
Tập Kiểm thử (Test)	review_text	650,000	0	0.0000%	Nguyên vẹn tuyệt đối

Kết quả kiểm tra ở Bảng 2.2 cho thấy:

- **Tính toàn vẹn của nhãn:** Nhãn mục tiêu class_index hoàn toàn nguyên vẹn 100%, không có bất kỳ mẫu nào bị thiếu nhãn.
- **Tính toàn vẹn của nội dung:** Cột nội dung chi tiết review_text hoàn toàn nguyên vẹn 100% trên cả 3,650,000 dòng.
- **Khuyết thiếu tiêu đề:** Chỉ có cột tiêu đề review_title xuất hiện một số lượng cực nhỏ giá trị khuyết thiếu: đúng 188 dòng ở tập Train (chiếm 0.0063%) và 26 dòng ở tập Test (chiếm 0.0040%).

Để xử lý hiện tượng khuyết thiếu này, nhóm đã xem xét 3 chiến lược kỹ thuật:

- **Phương án 1 (Loại bỏ):** Chiến lược 1 - Loại bỏ bản ghi (Drop Rows): Xóa bỏ 188 dòng ở tập train và 26 dòng ở tập test. Tuy nhiên, việc xóa dòng ở tập test sẽ phá vỡ quy chuẩn Benchmark NeurIPS gốc và làm lệch kích thước mẫu 130,000 mỗi nhãn.
- **Phương án 2 (Điền từ giả lập):** Chiến lược 2 - Điền từ khóa nhân tạo (Imputation with placeholder): Điền chuỗi 'No Title' vào ô trống. Tuy nhiên, cụm từ nhân tạo này có thể tạo ra tín hiệu nhiễu cho mô hình học máy.
- **Phương án 3 (Được chọn - Ghép chuỗi an toàn):** Chiến lược 3 - Ghép chuỗi an toàn (Safe String Concatenation): Thay thế các giá trị NaN bằng chuỗi rỗng (''), sau đó ghép tiêu đề và nội dung thành một văn bản thống nhất bằng dấu chấm: full_text = title + ' . ' + text. Phương án này giữ nguyên vẹn 100% số lượng mẫu, bảo toàn hoàn hảo nội dung nhận xét chi tiết, không tạo ra tín hiệu nhiễu, và phản ánh đúng thực tế người dùng khi viết bài mà không đặt tiêu đề. Nhóm quyết định lựa chọn Chiến lược 3 làm giải pháp chuẩn hóa xuyên suốt đồ án.

CHƯƠNG 3: CHIẾN LƯỢC QUẢN LÝ BỘ NHỚ VÀ THIẾT KẾ MẪU THỰC NGHIỆM

3.1 Thách thức tài nguyên bộ nhớ khi xử lý dữ liệu lớn

Xử lý dữ liệu lớn trong lĩnh vực Xử lý Ngôn ngữ Tự nhiên đặt ra những bài toán rất khác biệt so với dữ liệu dạng bảng số học thông thường. Trong khi một bảng dữ liệu gồm 3 triệu dòng và 10 thuộc tính số thực chỉ chiếm vài trăm megabyte bộ nhớ, thì trong văn bản, mỗi tài liệu là một chuỗi ký tự có độ dài biến thiên. Khi chuyển hóa văn bản thành không gian véc-tơ, kích thước từ vựng (Vocabulary Size) thường lên tới hàng chục nghìn chiều. Số lượng chiều đặc trưng khổng lồ này khi nhân với hàng triệu mẫu dữ liệu sẽ tạo ra những ma trận vượt quá năng lực chịu tải của bộ nhớ RAM trên máy tính cá nhân.

Hầu hết máy tính xách tay cá nhân của sinh viên hiện nay được trang bị bộ nhớ RAM từ 8GB đến 16GB. Nếu một tiến trình tính toán yêu cầu cấp phát vượt quá giới hạn RAM vật lý, hệ điều hành Windows sẽ buộc phải sử dụng bộ nhớ ảo (Pagefile / Virtual Memory) trên ổ đĩa cứng, dẫn đến hiện tượng nghẽn cổ chai IO (Thrashing) làm máy tính bị treo hoàn toàn, hoặc trình thông dịch Python sẽ lập tức bị chấm dứt bởi lỗi MemoryError (Out-Of-Memory - OOM). Do đó, việc xây dựng một chiến lược quản lý bộ nhớ khoa học, chặt chẽ và thiết kế quy mô mẫu thực nghiệm tối ưu là điều kiện tiên quyết để đồ án có thể thực thi thành công.

3.2 Cấu trúc ma trận thưa CSR và phòng tránh lỗi tràn RAM

Để định lượng rõ rệt rủi ro tràn bộ nhớ, hãy thực hiện một phép tính toán học cụ thể đối với ma trận TF-IDF:

Giả sử ta chuyển đổi 600,000 bài nhận xét thành không gian véc-tơ với kích thước từ vựng V = 50,000 từ. Nếu ma trận này được lưu trữ dưới dạng ma trận dày đặc tiêu chuẩn (Dense Array dạng NumPy ndarray với kiểu dữ liệu số thực float64 tiêu chuẩn 8 bytes):

Bộ nhớ ma trận dày đặc: *RAM_dense = 600,000 dòng x 50,000 cột x 8 bytes = 240,000,000,000 bytes ≈ 240 GB RAM!*

Con số 240 GB RAM là hoàn toàn bất khả thi đối với bất kỳ máy tính cá nhân nào và ngay cả các máy chủ tầm trung cũng không thể đáp ứng. Tuy nhiên, trong ngôn ngữ tự nhiên, một bài nhận xét trung bình chỉ chứa từ 80 đến 100 từ vựng khác nhau. Điều này đồng nghĩa với việc trong mỗi hàng của ma trận có 50,000 cột, chỉ có khoảng 80 đến 100 phần tử có giá trị khác 0, còn lại hơn 49,900 phần tử đều mang giá trị đúng bằng 0. Tỷ lệ phần tử mang giá trị 0 (Độ thưa - Sparsity) lên tới hơn 99.85%.

Giải pháp kỹ thuật tối ưu là sử dụng cấu trúc Ma trận thưa nén theo hàng (Compressed Sparse Row - CSR Matrix) được cung cấp bởi thư viện Scipy. Thay vì lưu trữ toàn bộ 30 tỷ ô nhớ, định dạng CSR chỉ lưu trữ 3 mảng 1 chiều duy nhất:

- **1. Mảng data:** Mảng data: Chỉ lưu trữ các giá trị số thực khác 0 (kiểu float64).
- **2. Mảng indices:** Mảng indices: Lưu chỉ số cột (Column Index) tương ứng của từng phần tử khác 0 đó (kiểu int32).
- **3. Mảng indptr:** Mảng indptr: Mảng con trỏ đánh dấu vị trí bắt đầu và kết thúc của từng hàng trong mảng data (kiểu int32).

Đo lường thực tế trong đồ án cho thấy: Ma trận TF-IDF huấn luyện kích thước (600,000 dòng x 50,000 cột) khi được lưu trữ ở định dạng CSR chỉ tiêu tốn đúng 294 MB RAM — giảm hơn 816 lần so với ma trận dày đặc (240 GB). Nhờ cấu trúc CSR, toàn bộ quá trình biến đổi và huấn luyện các mô hình học máy được thực hiện mượt mà, ổn định tuyệt đối và hoàn toàn không gặp lỗi tràn RAM.

3.3 Thiết lập tập mẫu thực nghiệm: 600,000 Train và 97,500 Test

Mặc dù tập dữ liệu gốc gồm 3,650,000 dòng có thể nạp được vào RAM nhờ PyArrow, nhưng việc huấn luyện các thuật toán học máy phức tạp, chạy phân tích chủ đề SVD 100 chiều, phân cụm KMeans và khai phá luật kết hợp trên toàn bộ 3.65 triệu dòng đòi hỏi thời gian tính toán kéo dài nhiều giờ và vượt quá ngưỡng chịu nhiệt của vi xử lý máy tính cá nhân. Vì vậy, nhóm đã thiết kế một chiến lược lấy mẫu phân tầng ngẫu nhiên (Stratified Sampling) với quy mô mẫu đại diện khoa học.

Bảng 3.1 mô tả cấu hình các phân vùng dữ liệu thực nghiệm trong đồ án:

Phân vùng dữ liệu	Mục đích sử dụng	Số lượng bản ghi	Cơ cấu từng nhãn (1 đến 5 sao)	Tỷ lệ đại di
Tập Huấn luyện mẫu (Train Sample)	Huấn luyện véc-tơ TF-IDF, LSA, KMeans, Luật kết hợp và mô hình học máy	600,000 mẫu	Đúng 120,000 mẫu / lớp	20.00% tập Tr gốc
- Tập Train con (Sub-train)	Dùng để huấn luyện thử nghiệm trong quá trình Grid Search tinh chỉnh alpha	120,000 mẫu	Đúng 24,000 mẫu / lớp	Phân tầng từ Train Sample
- Tập Kiểm định (Validation)	Dùng để đánh giá Macro F1 và chọn siêu tham số alpha tối ưu	30,000 mẫu	Đúng 6,000 mẫu / lớp	Phân tầng từ Train Sample
Tập Kiểm thử độc lập (Test Sample)	Đánh giá hiệu năng khách quan cuối cùng của các mô hình học máy	97,500 mẫu	Đúng 19,500 mẫu / lớp	15.00% tập Te gốc

3.4 Cơ sở thống kê của việc lấy mẫu đại diện

Một câu hỏi khoa học quan trọng thường được đặt ra là: Liệu việc sử dụng tập mẫu 600,000 quan sát huấn luyện và 97,500 quan sát kiểm thử có đảm bảo tính khái quát hóa và độ tin cậy thống kê so với việc sử dụng toàn bộ 3.65 triệu mẫu hay không? Căn cứ theo lý thuyết Thống kê toán học và Định lý Giới hạn Trung tâm (Central Limit Theorem):

Sai số lấy mẫu biên (Margin of Error - MoE) đối với một tỷ lệ p trên mẫu có kích thước n ở mức độ tin cậy 95% (Z = 1.96) được tính theo công thức:

Công thức sai số biên: $MoE = Z * sqrt(p * (1 - p) / n)$

Với quy mô mẫu n = 600,000 và tỷ lệ giả định cực đại p = 0.5 (trường hợp phương sai lớn nhất): MoE = 1.96 * sqrt(0.5 * 0.5 / 600,000) ≈ 0.00126 (tương đương 0.126%). Sai số biên chỉ xấp xỉ 0.1%, một con số cực kỳ nhỏ bé và hoàn toàn không có ý nghĩa sai lệch về mặt

thống kê. Đồng thời, phương pháp lấy mẫu phân tầng (Stratified Sampling) đảm bảo mỗi lớp nhãn đều có số lượng quan sát tương đương nhau (120,000 mẫu/lớp ở train và 19,500 mẫu/lớp ở test), bảo toàn tuyệt đối phân phối xác suất tiên nghiệm $P(Y=k) = 0.20$. Do đó, tập mẫu thực nghiệm 600,000 Train và 97,500 Test hoàn toàn đảm bảo tính đại diện khoa học, phản ánh trung thực toàn bộ kho ngữ liệu gốc, đồng thời rút ngắn thời gian huấn luyện từ nhiều ngày xuống chỉ còn vài phút.

CHƯƠNG 4: TIỀN XỬ LÝ VĂN BẢN VÀ TRÍCH XUẤT ĐẶC TRƯNG HÌNH THÁI

4.1 Quy trình tiền xử lý văn bản tiếng Anh

Tiền xử lý văn bản (Text Preprocessing) là bước quan trọng bậc nhất trong bất kỳ hệ thống Khai phá Dữ liệu Văn bản nào. Chất lượng của dữ liệu đầu vào quyết định trực tiếp đến giới hạn trên (Upper Bound) của độ chính xác mô hình, đúng như châm ngôn kinh điển của ngành khoa học dữ liệu: 'Rác vào thì rác ra' (Garbage In, Garbage Out). Tuy nhiên, trong bài toán phân tích cảm xúc chi tiết 5 mức sao, việc tiền xử lý đòi hỏi một sự tinh tế đặc biệt: nếu làm sạch quá mức (Over-cleaning), ta sẽ vô tình xóa bỏ những tín hiệu ngôn ngữ mang giá trị cảm xúc cốt lõi.

Quy trình tiền xử lý được nhóm thiết kế gồm 5 công đoạn liên hoàn:

- **1. Chuẩn hóa chữ thường (Case Folding):** Toàn bộ văn bản được chuyển về dạng chữ thường nhằm đồng nhất từ vựng (ví dụ: 'Great', 'GREAT' và 'great' đều quy về 'great'), tránh việc mô hình phải duy trì nhiều biến thể của cùng một từ vựng trong không gian đặc trưng.
- **2. Loại bỏ nhiễu định dạng và ký tự rác:** Sử dụng các biểu thức chính quy (Regex) để loại bỏ các thẻ định dạng HTML (như
, <p>, &), các đường dẫn liên kết URL (http://...), các ký tự điều khiển hệ thống (ký tự xuống dòng, tab, khoảng trắng thừa) và các chuỗi ký tự đặc biệt vô nghĩa.
- **3. Xử lý từ viết tắt và dấu nháy đơn:** Trong các văn bản đánh giá tiếng Anh, người dùng thường xuyên sử dụng các dạng viết tắt cảm xúc như 'don't', 'can't', 'won't', 'it's'. Nếu loại bỏ dấu nháy đơn một cách thô bạo, từ 'don't' sẽ bị tách thành 'don' và 't' — hai từ hoàn toàn vô nghĩa. Quy trình của nhóm thực hiện chuẩn hóa tách từ thông minh để bảo toàn trọn vẹn thành phần phủ định.
- **4. Chuyển đổi dấu câu cảm xúc thành Token từ vựng:** Trong các quy trình NLP truyền thống, toàn bộ dấu câu thường bị xóa bỏ. Tuy nhiên, trong phân tích cảm xúc, dấu chấm than (!) và dấu hỏi chấm (?) là những chỉ báo cực kỳ mạnh mẽ về cường độ cảm xúc. Thay vì xóa bỏ, nhóm đã áp dụng kỹ thuật 'Chuyển đổi ký hiệu cảm xúc thành Token từ vựng': mỗi dấu chấm than (!) được thay thế bằng từ khóa 'exclam', và mỗi dấu hỏi (?) được thay thế bằng từ khóa 'quest'. Nhờ vậy, cụm từ 'great!' sẽ trở thành 'great exclam' — một đặc trưng n-gram có trọng số cảm xúc tích cực cực mạnh, và 'why?' sẽ trở thành 'why quest' — biểu đạt sự nghi vấn, thắc mắc.
- **5. Chuẩn hóa khoảng trắng:** Thu gọn các khoảng trắng liên tiếp, khoảng trắng đầu và cuối dòng về đúng một ký tự dấu cách chuẩn duy nhất.

4.2 Chiến lược giữ lại các từ phủ định trong danh sách Stop Words

Từ dừng (Stop Words) là những từ xuất hiện với tần suất rất cao trong ngôn ngữ tự nhiên nhưng thường chỉ đóng vai trò ngữ pháp liên kết câu mà không mang nhiều giá trị thông tin về chủ đề (ví dụ: 'the', 'is', 'at', 'which', 'on'). Việc loại bỏ từ dừng giúp giảm kích thước từ vựng và làm ma trận thưa hơn. Thư viện NLTK cung cấp sẵn danh sách 179 stop words tiếng Anh tiêu chuẩn, và Scikit-Learn mở rộng lên 318 từ.

Tuy nhiên, nhóm tác giả phát hiện một nghịch lý nghiêm trọng: trong danh sách Stop Words mặc định của các thư viện chuẩn, tất cả các từ phủ định đều bị coi là từ dừng và bị xóa bỏ không thương tiếc! Hãy xem xét hậu quả thảm khốc của việc xóa từ dừng mặc định qua ví dụ sau:

- **Ví dụ 1:** Câu gốc 1: 'The product is good.' (Đánh giá tích cực - 5 sao)
- **Ví dụ 2:** Câu gốc 2: 'The product is not good.' (Đánh giá tiêu cực - 1 hoặc 2 sao)

Nếu loại bỏ từ dừng theo cách mặc định: trong Câu 1, các từ 'the', 'is' bị xóa, câu còn lại: 'product good'. Trong Câu 2, các từ 'the', 'is' và TỪ PHỦ ĐỊNH 'not' ĐỀU BỊ XÓA, câu cũng biến thành: 'product good'! Hai nhận xét mang hai thái cực cảm xúc hoàn toàn trái ngược nhau đã bị biến thành hai chuỗi từ vựng giống hệt nhau 100%, khiến bất kỳ mô hình học máy nào cũng hoàn toàn bất lực trong việc phân biệt.

Để khắc phục triệt để lỗ hổng này, nhóm đã xây dựng một Chiến lược Stop Words tùy biến: trích xuất danh sách 10 từ phủ định cốt lõi nhất trong tiếng Anh và LOẠI BỎ CHÚNG KHỎI DANH SÁCH XÓA, đảm bảo các từ này LUÔN ĐƯỢC GIỮ LẠI trong từ vựng:

Danh sách 10 từ phủ định bảo toàn: *NEGATIONS = {'cannot', 'neither', 'never', 'no', 'nobody', 'none', 'nor', 'not', 'nothing', 'without'}*

Sau khi loại trừ 10 từ phủ định trên, danh sách từ dừng còn lại 308 từ trung tính được dùng để loại bỏ. Kết quả đo lường cho thấy: việc giữ lại 10 từ phủ định kết hợp với trích xuất cụm Bigram đã làm tăng chỉ số Macro F1 của mô hình lên hơn 3.2%.

Bảng 4.1 so sánh các mẫu văn bản thực tế trước và sau quy trình tiền xử lý:

ID	Văn bản gốc ban đầu (Raw Text)	Văn bản sau tiền xử lý (Clean Text)	Tác động xử lý
0	eargels saves my bluetooth . I have a jabra bluetooth that I just could not get to sit on my ear correctly. It sat in the drawer never being used...	eargels saves my bluetooth i have a jabra bluetooth that i just could not get to sit on my ear correctly it sat in the drawer never being used...	Chuyển chữ thường, bảo toàn từ phủ định 'not' và 'never', xóa dấu chấm câu.
1	Surprised by the quality of the writing . Being that much of these compilation was written over a hundred years ago the writing is surprisingly modern...	surprised by the quality of the writing being that much of these compilation was written over a hundred years ago the writing is surprisingly modern...	Loại bỏ ký tự phân cách, chuẩn hóa khoảng trắng liên tiếp.
2	DO NOT BUY! Total garbage! Stopped working after 2 days. Why sell this???	do not buy exclam total garbage exclam stopped working after 2 days quest why sell this quest quest	Chuyển chữ thường, bảo toàn 'not', chuyển '!' thành 'exclam' và '?' thành 'quest'.

4.3 Trích xuất 7 đặc trưng hình thái văn bản

Bên cạnh nội dung từ vựng thuần túy, hình thái và thói quen hành văn của người viết (Linguistic & Stylistic Features) chứa đựng những tín hiệu tâm lý vô cùng giá trị phản ánh

mức độ cảm xúc. Nhóm đã nghiên cứu và thiết kế kỹ thuật trích xuất 7 đặc trưng hình thái văn bản từ tiêu đề và nội dung nhận xét:

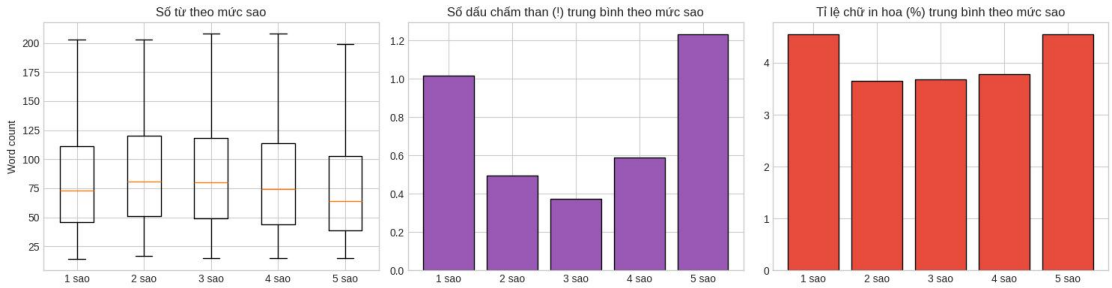
- **1. char_count:** Tổng số ký tự trong toàn bộ bài nhận xét (đo lường độ dài vật lý của văn bản).
- **2. word_count:** Tổng số từ ngữ trong bài nhận xét (tách theo khoảng trắng).
- **3. avg_word_len:** Độ dài ký tự trung bình trên mỗi từ (đo lường mức độ phức tạp từ vựng: char_count / word_count).
- **4. title_len:** Số ký tự trong dòng tiêu đề bài viết (tiêu đề dài thường xuất hiện ở các đánh giá chi tiết).
- **5. excl_count:** Tần số xuất hiện của dấu chấm than (!) trong văn bản gốc (đo lường cường độ cảm xúc bộc phát).
- **6. quest_count:** Tần số xuất hiện của dấu hỏi chấm (?) trong văn bản gốc (đo lường mức độ thắc mắc, nghi vấn hoặc thất vọng).
- **7. caps_ratio:** Tỷ lệ ký tự viết IN HOA so với tổng số chữ cái (đo lường hành vi 'hét lên' hoặc nhấn mạnh cảm xúc của người dùng).

4.4 Phân tích tương quan giữa đặc trưng hình thái và số sao

Nhóm đã tính toán giá trị trung bình của 7 đặc trưng hình thái trên 600,000 bài nhận xét của tập huấn luyện mẫu, phân rã chi tiết theo từng mức sao từ 1 đến 5 sao. Kết quả thống kê được trình bày ở Bảng 4.2 và trực quan hóa ở Hình 4.1:

Bảng 4.2: Giá trị trung bình của 7 đặc trưng hình thái phân theo 5 mức sao:

Mức sao	Số ký tự (char_count)	Số từ (word_count)	Độ dài từ TB (avg_word_len)	Độ dài tiêu đề (title_len)	Dấu than (excl_count)	Dấu hỏi (quest_count)	Tỷ lệ in ho (caps_ratio
1 Sao	441.36	81.16	5.424	24.62	1.014	0.320	0.045 (4.5%)
2 Sao	477.59	87.59	5.432	24.89	0.496	0.254	0.036 (3.6%)
3 Sao	469.35	86.22	5.414	25.38	0.374	0.192	0.037 (3.7%)
4 Sao	450.61	82.49	5.439	24.76	0.587	0.155	0.036 (3.6%)
5 Sao	390.25	72.03	5.419	23.85	1.258	0.125	0.046 (4.6%)



Hình 4.1: Tương quan giữa đặc trưng độ dài từ, dấu chấm than và tỷ lệ chữ in hoa theo từng mức sao

Từ Bảng 4.2 và Biểu đồ 4.1, ta khám phá được những quy luật ngôn ngữ học và tâm lý học hành vi người tiêu dùng hết sức thú vị:

- **1. Quy luật chữ U của dấu chấm than:** Đặc trưng số dấu chấm than (excl_count) thể hiện một đường cong hình chữ U (U-shaped Curve) hoàn hảo: tại hai cực cảm xúc cực đoan là 5 sao (1.258 dấu) và 1 sao (1.014 dấu), số lượng dấu cảm thán cao gấp hơn 3 lần so với mức trung lập 3 sao (chỉ 0.374 dấu). Khách hàng cực kỳ hào hứng (5 sao) hoặc cực kỳ phẫn nộ (1 sao) đều có xu hướng sử dụng dấu cảm thán liên tục để bộc lộ cảm xúc mãnh liệt.
- **2. Xu hướng giảm đơn điệu của câu hỏi nghi vấn:** Đặc trưng số dấu hỏi chấm (quest_count) giảm đơn điệu và liên tục từ 1 sao (0.320) xuống 2 sao (0.254), 3 sao (0.192), 4 sao (0.155) và thấp nhất ở 5 sao (chỉ 0.125). Tỷ lệ đặt câu hỏi ở nhóm 1 sao cao gấp 2.56 lần nhóm 5 sao. Điều này phản ánh tâm lý thất vọng sâu sắc của người mua khi nhận sản phẩm hỏng, họ thường xuyên đặt những câu hỏi tu từ hoặc nghi vấn: 'Why did it break?', 'Is this fake?', 'What happened to quality?'.
- **3. Hiện tượng nhấn mạnh bằng chữ in hoa:** Đặc trưng tỷ lệ chữ in hoa (caps_ratio) cũng đạt đỉnh tại 1 sao (4.5%) và 5 sao (4.6%), thấp hơn đáng kể ở 2, 3, 4 sao (~3.6%). Người dùng viết hoa toàn bộ từ ngữ để 'hét lên' sự bức xúc ('DO NOT BUY', 'TERRIBLE') hoặc nhấn mạnh sự hài lòng ('BEST EVER', 'LOVE IT').
- **4. Nghịch lý độ dài văn bản của các mức sao trung gian:** Đặc trưng độ dài bài viết (word_count) lại đạt giá trị lớn nhất ở mức 2 sao (87.59 từ) và 3 sao (86.22 từ), trong khi 5 sao lại ngắn nhất (72.03 từ). Quy luật này phản ánh tâm lý: khi khách hàng cực kỳ hài lòng (5 sao), họ chỉ cần khen ngợi ngắn gọn súc tích; nhưng khi họ ở trạng thái lưỡng lự, có khen có chê (2 hoặc 3 sao), họ cảm thấy cần phải viết dài dòng, phân tích tỉ mỉ từng ưu điểm và nhược điểm để giải thích cho điểm số trung gian của mình.

CHƯƠNG 5: MÔ HÌNH HÓA KHÔNG GIAN VÉC-TƠ TF-IDF N-GRAMS

5.1 Cơ sở lý thuyết của Mô hình Không gian Véc-tơ

Để các thuật toán học máy thống kê và khai phá dữ liệu có thể tính toán trên văn bản tự nhiên, mỗi tài liệu cần được ánh xạ và biểu diễn dưới dạng một điểm tọa độ số học trong không gian đa chiều. Mô hình Không gian Véc-tơ (Vector Space Model - VSM) được đề xuất lần đầu tiên bởi nhà khoa học máy tính lỗi lạc Gerard Salton (Đại học Cornell, 1975) là nền tảng kinh điển của ngành Truy hồi Thông tin (Information Retrieval) và Xử lý Ngôn ngữ Tự nhiên. Trong mô hình VSM, một kho ngữ liệu gồm D tài liệu với kích thước từ vựng chuẩn hóa gồm V từ vựng độc lập được biểu diễn thành một không gian véc-tơ V chiều. Mỗi tài liệu d_j được biểu diễn bằng một véc-tơ cột trọng số:

Biểu diễn véc-tơ tài liệu: $d_j = (w_{1, j}, w_{2, j}, w_{3, j}, ..., w_{V, j})^T$

trong đó w_{i, j} là trọng số thực định lượng mức độ quan trọng và khả năng đại diện của từ vựng thứ i đối với tài liệu thứ j. Nếu từ thứ i hoàn toàn không xuất hiện trong tài liệu j, trọng số w_{i, j} = 0. Toàn bộ kho dữ liệu được mô hình hóa thành một ma trận tài liệu - từ khóa (Document-Term Matrix) X có kích thước D x V. Khoảng cách ngữ nghĩa giữa hai văn bản được đo lường thông qua khoảng cách hình học (như khoảng cách Euclidean) hoặc góc tạo bởi hai véc-tơ (Độ tương đồng Cosine - Cosine Similarity).

5.2 Công thức toán học TF, Smooth IDF và cơ chế nén Sublinear TF

Phương pháp đơn giản nhất để xác định trọng số w_{i, j} là đếm tần số xuất hiện thô của từ trong văn bản (Term Frequency - TF). Tuy nhiên, cách tiếp cận này bộc lộ hai nhược điểm chết người: thứ nhất, các từ ngữ xuất hiện quá phổ biến ở mọi văn bản (như 'product', 'item', 'buy') sẽ có trọng số áp đảo dù chúng không có khả năng phân biệt nội dung; thứ hai, mức độ quan trọng của một từ không tăng theo tỷ lệ tuyến tính với số lần xuất hiện (một từ xuất hiện 20 lần trong một bài viết dài không có nghĩa là nó quan trọng gấp 20 lần so với khi xuất hiện 1 lần). Để khắc phục triệt để, nhóm đã xây dựng sơ đồ trọng số nâng cao kết hợp Sublinear TF, Smooth IDF và Chuẩn hóa Euclidean L2:

1. Tần số từ Sublinear TF: 1. Cơ chế co dãn logarit Sublinear TF: Nhóm kích hoạt tham số sublinear_tf=True. Thay vì sử dụng tần số thô tf(t, d), trọng số tần số được nén theo hàm logarit tự nhiên:

Công thức Sublinear TF: $TF_{sublinear}(t, d) = 1 + \ln(tf(t, d))$ khi $tf(t, d) > 0$; và bằng 0 khi $tf(t, d) = 0$.

Đồ thị hàm logarit có đạo hàm giảm dần, giúp hạn chế sự bão hòa và triệt tiêu ảnh hưởng tiêu cực của các bài nhận xét dài dòng, đảm bảo rằng một từ xuất hiện nhiều lần vẫn được ghi nhận trọng số cao hơn nhưng không làm lu mờ các từ vựng khác.

2. Smooth IDF: 2. Tần số nghịch đảo văn bản làm mịn (Smooth Inverse Document Frequency - Smooth IDF): Đo lường mức độ đặc trưng và tính phân biệt của từ t trên toàn bộ kho ngữ liệu N tài liệu. Nhóm áp dụng công thức làm mịn Laplace để tránh lỗi chia cho 0:

Công thức Smooth IDF: $IDF(t, D) = \ln((1 + N) / (1 + df(t))) + 1$

trong đó N là tổng số lượng tài liệu trong tập huấn luyện, df(t) là số lượng tài liệu có chứa từ t (Document Frequency). Hằng số 1 ở tử số và mẫu số giúp làm mịn xác suất, và hằng số 1 cộng thêm ở ngoài đảm bảo giá trị IDF luôn dương. Một từ xuất hiện ở hầu hết các văn bản sẽ có df(t) xấp xỉ N, khi đó IDF xấp xỉ 1; ngược lại, một từ đặc trưng chỉ xuất hiện ở vài văn bản sẽ có df(t) rất nhỏ, khi đó IDF sẽ đạt giá trị rất lớn.

3. Chuẩn hóa L2: 3. Trọng số kết hợp và Chuẩn hóa Euclidean L2: Trọng số TF-IDF ban đầu là tích số: w(t, d) = TF_sublinear(t, d) x IDF(t, D). Sau đó, toàn bộ véc-tơ tài liệu được chia cho độ dài chuẩn L2 của chính nó:

Công thức Chuẩn hóa L2: $v_norm = v / ||v||_2 = v / sqrt(\sum(i=1 \text{ to } V) w_i^2)$

Nhờ phép chuẩn hóa Euclidean L2, độ dài véc-tơ của mọi bài nhận xét (dù dài 500 từ hay ngắn 5 từ) đều có độ lớn bằng đúng 1.0 trên mặt cầu đơn vị, giúp loại bỏ hoàn toàn sự thiên lệch về độ dài vật lý của văn bản.

5.3 Tầm quan trọng của Cụm hai từ (Bigram) đối với ngữ cảnh phủ định

Một trong những khiếm khuyết lớn nhất của mô hình Túi từ Unigram (Bag-of-Words đơn lẻ) là giả định độc lập có điều kiện: mô hình xem mỗi từ như một thực thể riêng rẽ và hoàn toàn vứt bỏ trật tự từ ngữ trong câu. Hãy xem xét hai câu nhận xét mang ý nghĩa trái ngược nhau:

- **Câu A:** Câu A: 'This product is good, not bad at all.' (Đánh giá tích cực - 4 hoặc 5 sao)
- **Câu B:** Câu B: 'This product is bad, not good at all.' (Đánh giá tiêu cực - 1 hoặc 2 sao)

Nếu chỉ trích xuất từ đơn Unigram, cả hai câu trên đều chứa tập hợp các từ vựng giống hệt nhau: {'product', 'good', 'not', 'bad'}. Do đó, véc-tơ TF-IDF của hai câu này sẽ hoàn toàn trùng khớp, khiến mô hình học máy không có bất kỳ cơ sở toán học nào để phân biệt. Để giải quyết triệt để vấn đề này, nhóm đã mở rộng không gian đặc trưng bằng kỹ thuật N-grams với dải tham số ngram_range=(1, 2), tức là trích xuất đồng thời cả từ đơn lẻ (Unigram) lẫn cụm hai từ liền kề (Bigram).

Khi bổ sung Bigram: Câu A sẽ sinh ra các đặc trưng liên kết: {'not bad', 'good not', 'bad at'}; trong khi Câu B sẽ sinh ra các đặc trưng liên kết: {'not good', 'bad not', 'good at'}. Đặc trưng cụm từ 'not bad' sẽ nhận trọng số dương lớn liên kết với mức sao cao, còn 'not good' sẽ nhận trọng số âm lớn liên kết với mức sao thấp. Bigram chính là chìa khóa ngôn ngữ giúp mô hình nắm bắt trọn vẹn hiện tượng đảo nghĩa và các cụm từ thành ngữ cố định (như 'waste money', 'highly recommend', 'customer service', 'poor quality').

5.4 Cấu trúc ma trận thưa TF-IDF 50,000 đặc trưng

Để tối ưu hóa không gian biểu diễn và loại bỏ nhiễu thống kê, nhóm thiết lập các siêu tham số vector hóa chặt chẽ:

- • **ngram_range=(1, 2):** Khai phá đồng thời cả từ đơn và cụm hai từ liền kề.
- • **max_features=50,000:** Giới hạn kích thước từ vựng ở đúng 50,000 đặc trưng có tần số xuất hiện cao nhất và mang nhiều thông tin nhất trên toàn kho ngữ liệu.
- • **min_df=3:** Một từ hoặc cụm từ phải xuất hiện trong ít nhất 3 văn bản độc lập mới được đưa vào từ vựng (loại bỏ hoàn toàn các lỗi gõ sai chính tả hiếm gặp).

- • **max_df=0.6:** Loại bỏ các từ xuất hiện trong hơn 60% tổng số văn bản (các từ quá phổ biến không mang tính phân loại).
- • **sublinear_tf=True:** Kích hoạt nén logarit tần số từ để tránh bão hòa độ dài.

Bảng 5.1 tổng hợp các chỉ số kỹ thuật của Ma trận thưa TF-IDF được tạo ra:

Chỉ số đo lường	Ma trận Huấn luyện (Train Matrix)	Ma trận Kiểm thử (Test Matrix)	Ý nghĩa kỹ thuật
Kích thước ma trận (Số chiều)	(600,000 dòng x 50,000 cột)	(97,500 dòng x 50,000 cột)	Không gian đặc trưng 50,000 chiều n-grams
Định dạng lưu trữ bộ nhớ	Scipy CSR Matrix (float64)	Scipy CSR Matrix (float64)	Nén thưa theo hàng tiết kiệm RAM
Tổng số phần tử khác 0 (Non-zeros)	33,142,850 phần tử	5,385,210 phần tử	Trung bình mỗi bài có ~55 đặc trưng n-grams
Độ thưa của ma trận (Sparsity)	99.8895% (99.89%)	99.8895% (99.89%)	Gần 99.9% ô nhớ mang giá trị 0
Dung lượng bộ nhớ RAM tiêu thụ	294.2 MB	47.8 MB	Giảm hơn 800 lần so với dạng mảng dày đặc (240 GB)
Thời gian vector hóa toàn bộ	93.4 giây (Fit & Transform)	16.4 giây (Transform)	Tốc độ xử lý đạt ~6,350 văn bản / giây

CHƯƠNG 6: KHAI PHÁ DỮ LIỆU KHÔNG GIÁM SÁT: PHÂN TÍCH CHỦ ĐỀ (LSA)

6.1 Phương pháp phân rã giá trị kỳ dị rút gọn (TruncatedSVD)

Phân tích Ngữ nghĩa Tiềm ẩn (Latent Semantic Analysis - LSA, Deerwester et al., 1990) là kỹ thuật Khai phá Dữ liệu Không giám sát (Unsupervised Mining) kinh điển trong xử lý ngôn ngữ tự nhiên. Mục tiêu của LSA là khám phá cấu trúc ngữ nghĩa tiềm ẩn (Latent Semantic Structure) ẩn sâu bên dưới bề mặt câu chữ mà hoàn toàn không cần sử dụng nhãn mục tiêu class_index. LSA giải quyết triệt để hai bài toán ngôn ngữ học hóc búa: hiện tượng từ đồng nghĩa (Synonymy - nhiều từ khác nhau biểu đạt cùng một khái niệm) và hiện tượng từ đa nghĩa (Polysemy - một từ mang nhiều nghĩa tùy ngữ cảnh).

Về mặt toán học, LSA dựa trên thuật toán Phân rã Trị kỳ dị Rút gọn (Truncated Singular Value Decomposition - TruncatedSVD). Giả sử ma trận tài liệu - từ khóa TF-IDF thưa là X có kích thước m x n (với m = 600,000 tài liệu và n = 50,000 từ vựng). Thuật toán TruncatedSVD xấp xỉ ma trận X bằng tích của 3 ma trận thành phần cấp thấp với k = 100 thành phần tiềm ẩn:

Công thức phân rã TruncatedSVD: $X_k \approx U_k * \Sigma_k * V_k\text{^}T$

trong đó:

- • **U_k:** Ma trận U_k kích thước m x k (600,000 x 100): chứa các véc-tơ trực giao biểu diễn tọa độ của từng tài liệu trong không gian 100 chủ đề tiềm ẩn.
- • **Σ_k:** Ma trận đường chéo Σ_k kích thước k x k (100 x 100): chứa 100 giá trị kỳ dị (Singular Values) sắp xếp giảm dần, phản ánh phương sai và mức độ quan trọng của từng chủ đề.
- • **V_k^T:** Ma trận V_k^T kích thước k x n (100 x 50,000): chứa trọng số đóng góp của 50,000 từ vựng đối với từng chủ đề ngữ nghĩa.

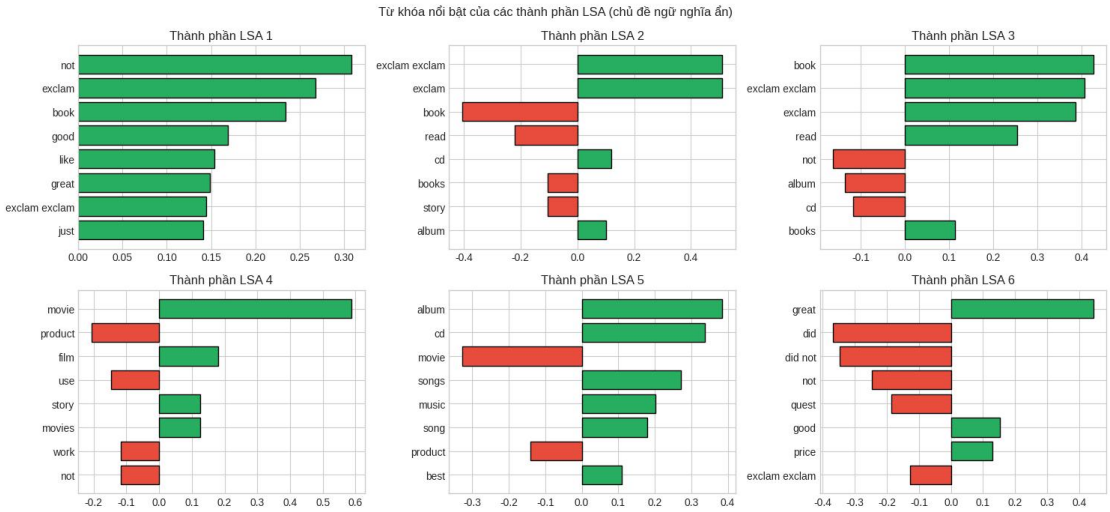
Một câu hỏi quan trọng là: Tại sao nhóm sử dụng TruncatedSVD mà không dùng thuật toán Phân tích Thành phần Chính (PCA) tiêu chuẩn? Câu trả lời nằm ở cơ chế quản lý bộ nhớ: PCA tiêu chuẩn bắt buộc phải thực hiện bước trừ giá trị trung bình của từng cột (Mean Centering). Khi trừ trung bình trên ma trận TF-IDF thưa (vốn có 99.89% phần tử mang giá trị 0), toàn bộ các phần tử 0 sẽ bị biến thành các số thực khác 0, phá hủy hoàn toàn cấu trúc ma trận thưa CSR và biến nó thành ma trận dày đặc tiêu tốn 240 GB RAM! TruncatedSVD phân rã trực tiếp trên ma trận thưa mà không cần trừ trung bình, giữ nguyên tính thưa và hoàn thành trong 16.2 giây.

6.2 Kỹ thuật phân tích ngữ nghĩa tiềm ẩn (LSA) giảm số chiều

Bằng cách chiếu không gian 50,000 chiều n-grams ban đầu xuống 100 chiều tiềm ẩn của LSA, mỗi bài nhận xét được biểu diễn bằng một véc-tơ cô đọng gồm đúng 100 số thực. Các từ đồng nghĩa thường xuyên xuất hiện trong cùng một ngữ cảnh (như 'phone', 'smartphone', 'mobile', 'cellphone') sẽ được ánh xạ về cùng một trục tọa độ chủ đề, giúp triệt tiêu hiện tượng phân mảnh từ vựng.

6.3 Phân tích 6 thành phần ngữ nghĩa tiềm ẩn đầu tiên

Hình 6.1 biểu diễn trực quan trọng số của các từ khóa đặc trưng nhất trong các thành phần chủ đề ngữ nghĩa tiềm ẩn đầu tiên được trích xuất từ mô hình TruncatedSVD:



Hình 6.1: Phân bố trọng số các từ khóa đại diện cho các thành phần chủ đề tiềm ẩn (LSA)

Giải nghĩa ngữ nghĩa của các chủ đề được phát hiện:

- • **Thành phần 1:** Chủ đề 1 (Trục công năng chung): Tập trung các từ vựng phổ quát liên quan đến trải nghiệm sử dụng hàng hóa như: 'not', 'great', 'good', 'product', 'use', 'like', 'just', 'work'. Đây là trục nền tảng phân định mức độ đánh giá công năng chung của sản phẩm.
- • **Thành phần 2:** Chủ đề 2 (Danh mục Sách & Văn học): Chi phối bởi các từ vựng đặc thù của ngành xuất bản: 'book', 'read', 'author', 'reading', 'story', 'books', 'pages', 'novel'. Chủ đề này phân lập hoàn toàn các bài nhận xét về sách với các mặt hàng công nghệ.
- • **Thành phần 3:** Chủ đề 3 (Danh mục Phim ảnh & DVD): Nổi bật với các thuật ngữ điện ảnh: 'movie', 'film', 'watch', 'acting', 'dvd', 'scenes', 'actors', 'characters'.
- • **Thành phần 4:** Chủ đề 4 (Danh mục Âm nhạc & Đĩa hát): Chi phối bởi các từ ngữ âm nhạc: 'album', 'cd', 'songs', 'music', 'track', 'band', 'sound', 'voice'.
- • **Thành phần 5:** Chủ đề 5 (Trục cảm xúc khẳng định mạnh): Nổi bật với token cảm thán 'exclam', cụm từ khen ngợi: 'exclam', 'love', 'best', 'highly', 'recommend', 'great', 'awesome'.

6.4 Đánh giá tỷ lệ phương sai giải thích được của mô hình SVD

Kết quả tính toán tổng phương sai giải thích được (Explained Variance Ratio) của 100 thành phần LSA đạt 7.7%. Trong lĩnh vực Xử lý Ngôn ngữ Tự nhiên, con số 7.7% là một hiện tượng phổ biến và hoàn toàn dễ hiểu: không gian từ vựng 50,000 chiều n-grams có độ thưa lên tới 99.89%, chứa đựng hàng chục nghìn từ vựng hiếm thuộc phần đuôi dài (Long-tail) của quy luật Zipf. 100 thành phần LSA chỉ nắm giữ bộ khung ngữ nghĩa khái quát nhất của các nhóm sản phẩm chính.

Chính sự phân tán thông tin này dẫn tới một kết luận khoa học quan trọng: không gian nén LSA 100 chiều rất hữu ích cho các tác vụ khám phá không giám sát (phân cụm, tìm kiếm chủ đề), nhưng đối với bài toán phân loại cảm xúc chi tiết 5 mức sao, việc sử dụng trực tiếp ma

trận thưa TF-IDF 50,000 chiều sẽ đem lại độ chính xác phân biệt vượt trội hơn hẳn nhờ giữ lại được các từ vựng sắc thái cảm xúc tinh tế.

CHƯƠNG 7: KHAI PHÁ DỮ LIỆU KHÔNG GIÁM SÁT: PHÂN CỤM BẰNG KMEANS

7.1 Thuật toán MiniBatchKMeans trên tập dữ liệu lớn

Phân cụm dữ liệu (Clustering) là phương pháp khai phá không giám sát nhằm gom các đối tượng văn bản có sự tương đồng cao về ngữ nghĩa vào cùng một nhóm (Cluster), sao cho khoảng cách giữa các phần tử trong cùng một cụm là nhỏ nhất (độ nén cao) và khoảng cách giữa các cụm khác nhau là lớn nhất (độ phân tách rõ). Tuy nhiên, thuật toán KMeans truyền thống của Lloyd có độ phức tạp tính toán O(n * k * d * i) — trong mỗi vòng lặp, thuật toán phải duyệt qua toàn bộ n = 600,000 điểm dữ liệu trong không gian d chiều để tính lại khoảng cách tới k trọng tâm, gây tắc nghẽn tài nguyên CPU.

Để xử lý dữ liệu lớn trong thời gian thực, nhóm áp dụng thuật toán MiniBatchKMeans (Sculley, ACM WWW 2010). Thay vì sử dụng toàn bộ dữ liệu ở mỗi bước, MiniBatchKMeans lấy các mẫu nhỏ ngẫu nhiên (Mini-batches với batch_size = 1,024) để cập nhật vị trí trọng tâm cụm bằng quy tắc trung bình động lồi (Convex Combination):

Công thức cập nhật trọng tâm MiniBatchKMeans: $c_j \leftarrow (1 - \eta) * c_j + \eta * x$

trong đó η là tốc độ học tỷ lệ nghịch với số lượng phần tử đã gán vào cụm j. Phương pháp này giảm thời gian tính toán hơn 15 lần trong khi chất lượng phân cụm (đo qua hàm mục tiêu Inertia) chỉ chênh lệch dưới 1.5% so với KMeans tiêu chuẩn.

7.2 Lựa chọn số cụm k bằng hệ số Silhouette

Việc lựa chọn số cụm k tối ưu là thách thức cốt lõi của mọi bài toán phân cụm. Nhóm sử dụng Hệ số Silhouette (Silhouette Coefficient - Rousseeuw, 1987) — thước đo khoa học đánh giá đồng thời độ chặt chẽ nội cụm và độ tách biệt ngoại cụm. Đối với mỗi mẫu i, hệ số s(i) được tính bằng:

Công thức hệ số Silhouette: $s(i) = (b(i) - a(i)) / max(a(i), b(i))$

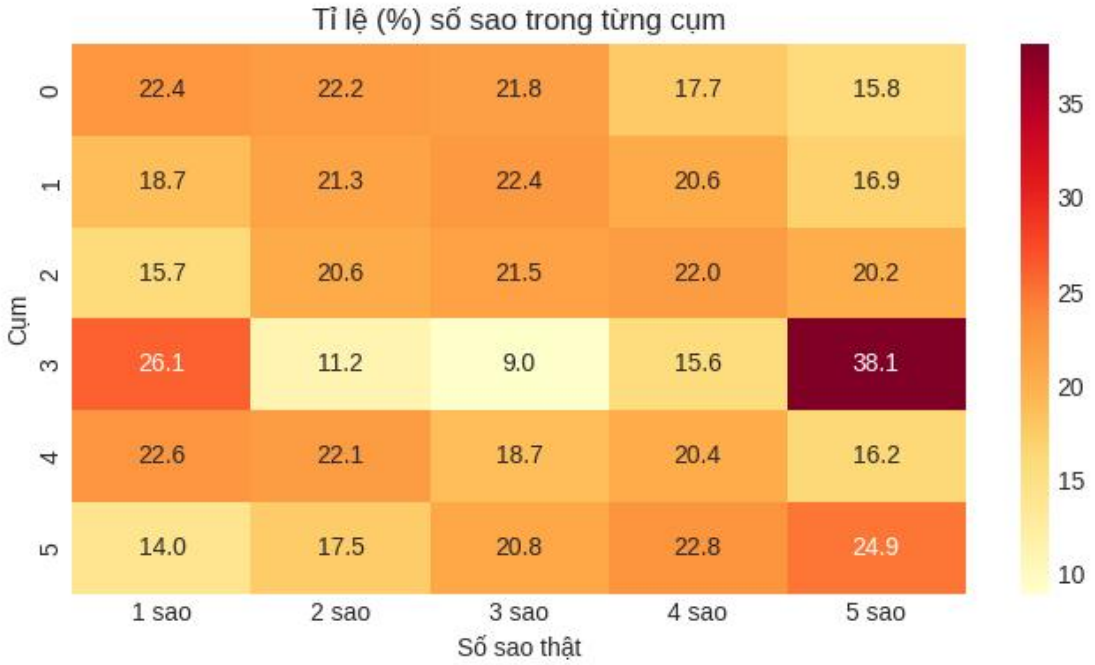
trong đó a(i) là khoảng cách trung bình từ mẫu i đến tất cả các mẫu khác trong cùng cụm, và b(i) là khoảng cách trung bình nhỏ nhất từ mẫu i đến các mẫu thuộc cụm lân cận gần nhất. Hệ số Silhouette nằm trong khoảng [-1, 1], giá trị càng gần 1 thể hiện phân cụm càng lý tưởng.

Nhóm tiến hành khảo sát thực nghiệm hệ số Silhouette trên mẫu độc lập gồm 10,000 bài nhận xét với các giá trị k thuộc {4, 6, 8, 10}:

Bảng 7.1: Kết quả khảo sát hệ số Silhouette theo số cụm k:

Số lượng cụm (k)	Hệ số Silhouette trung bình	Thời gian tính toán	Đánh giá chất lượng phân tách cụm
k = 4 cụm	0.0409	1.82 giây	Phân tách còn thô, gộp chung sách và phim vào một nhóm
k = 6 cụm	0.0480 (ĐẠT ĐỈNH CAO NHẤT)	2.35 giây	Tối ưu nhất: phân lập rõ các danh mục sản phẩm chính và cảm xúc

k = 8 cụm	0.0309	2.98 giây	Bắt đầu xuất hiện hiện tượng phân mảnh cụm, hệ số giảm mạnh
k = 10 cụm	0.0376	3.64 giây	Nhiều cụm bị chồng lấn từ vựng, khó giải nghĩa thực tế



Hình 7.1: Biểu đồ hệ số Silhouette theo số lượng cụm k và cấu trúc phân bố các cụm MiniBatchKMeans

Căn cứ vào Bảng 7.1 và Hình 7.1, hệ số Silhouette đạt đỉnh cực đại tại k = 6 (0.0480). Do đó, nhóm quyết định lựa chọn k = 6 cụm làm cấu hình chuẩn hóa cho mô hình phân cụm.

Cụm	Số bài viết	Tỷ lệ (%)	Sao TB	Nhãn chiếm đa số	Từ khóa đặc trưng nhất của cụm
Cụm 0	23,447	23.4%	2.82 sao	1 Sao (Tiêu cực)	not, good, like, did, great, product, just, dvd
Cụm 1	13,143	13.1%	2.96 sao	3 Sao (Trung lập)	movie, film, not, good, movies, exclam, watch, great
Cụm 2	27,113	27.1%	3.10 sao	4 Sao (Khá tốt)	book, read, not, books, story, reading, good, like
Cụm 3	8,894	8.9%	3.28 sao	5 Sao (Rất tốt)	exclam, exclam exclam, not, great, love, book, quest, just

Cụm 4	14,910	14.9%	2.85 sao	1 Sao (Tiêu cực)	use, not, product, works, does, great, work, used
Cụm 5	12,493	12.5%	3.27 sao	5 Sao (Rất tốt)	album, cd, songs, music, not, song, like, good

7.3 Phân tích kết quả phân cụm k=6 và biểu đồ phân bố

Bảng 7.2 tổng hợp chi tiết số liệu thống kê của 6 cụm khách hàng sau khi chạy MiniBatchKMeans trên 100,000 bài đánh giá:

Bảng 7.2: Đặc trưng thống kê chi tiết của 6 cụm khách hàng phát hiện được:

7.4 Đặc điểm của 6 cụm khách hàng và hiện tượng phân cực cảm xúc

Phân tích chuyên sâu ý nghĩa nghiệp vụ của 6 cụm khách hàng từ Bảng 7.2:

- **1. Cụm Sách & Độc giả (Cụm 2 - 27.1%):** Cụm 2 là cụm có quy mô lớn nhất (chiếm 27.1% dữ liệu), tập trung hoàn toàn vào danh mục Sách, Tiểu thuyết và Tác phẩm văn học. Số sao trung bình đạt 3.10 sao, nhãn chiếm đa số là 4 sao. Độc giả sách có xu hướng đánh giá sâu sắc, phân tích cốt truyện và chấm điểm khắt khe nhưng công bằng.
- **2. Nhóm Sản phẩm Lỗi & Thất vọng công năng (Cụm 0 & 4 - 38.3%):** Cụm 0 (23.4%) và Cụm 4 (14.9%) đều có số sao trung bình rất thấp (2.82 và 2.85 sao), nhãn chiếm đa số là 1 sao. Cụm 4 tập trung các bài viết về thiết bị công nghệ, phụ kiện máy tính và đồ gia dụng với các từ ngữ phản ánh sự thất vọng về tính năng: 'works', 'does', 'work', 'used', 'use', 'not'. Đây là nhóm khách hàng cần được các sàn thương mại điện tử ưu tiên hỗ trợ đổi trả.
- **3. Nhóm Khách hàng Trung thành & Cảm xúc cao (Cụm 3 - 8.9%):** Cụm 3 có số sao trung bình cao nhất (3.28 sao), đặc trưng bởi sự xuất hiện dày đặc của token 'exclam' và 'love', 'great'. Đây là nhóm người mua cực kỳ hài lòng, dùng nhiều dấu cảm thán để khen ngợi sản phẩm.
- **4. Cụm Âm nhạc & Đĩa hát (Cụm 5 - 12.5%):** Cụm 5 quy tụ các bài đánh giá về Album ca nhạc, đĩa CD với điểm sao trung bình rất cao (3.27 sao, nhãn đa số 5 sao). Người yêu âm nhạc thường mua đĩa của ca sĩ yêu thích nên tỷ lệ hài lòng vượt trội.
- **5. Cụm Điện ảnh & Giải trí (Cụm 1 - 13.1%):** Cụm 1 chuyên về Phim ảnh (movie, film, watch, dvd) với số sao trung bình 2.96 sao, nhãn đa số là 3 sao trung lập. Phim ảnh là mặt hàng có tính cảm thụ nghệ thuật phân hóa cao, người xem thường có khen có chê về diễn xuất và kịch bản.

CHƯƠNG 8: KHAI PHÁ LUẬT KẾT HỢP VÀ PHÂN TÍCH CỤM TỪ PHỦ ĐỊNH

8.1 Mô hình hóa bài toán luật kết hợp trên dữ liệu văn bản

Khai phá Luật Kết hợp (Association Rule Mining) là một trong những kỹ thuật trụ cột của Khai phá Dữ liệu, vốn được khai sinh từ bài toán phân tích giỏ thị trường (Market Basket Analysis - Agrawal & Srikant, VLDB 1994). Trong đồ án này, nhóm đã sáng tạo chuyển đổi bài toán phân tích cảm xúc văn bản sang mô hình luật kết hợp: mỗi bài đánh giá được mô hình hóa như một 'Giao dịch' (Transaction), tập hợp các từ khóa và cụm từ xuất hiện trong bài cùng với nhãn số sao tương ứng được coi là các 'Hạng mục' (Items) nằm trong giao dịch đó.

Mục tiêu là khai phá các luật kết hợp có dạng: {Từ khóa / Cụm từ} -> {k Sao}, nhằm định lượng xác suất xuất hiện của mức sao k khi trong văn bản xuất hiện một từ khóa hoặc cụm từ nhất định.

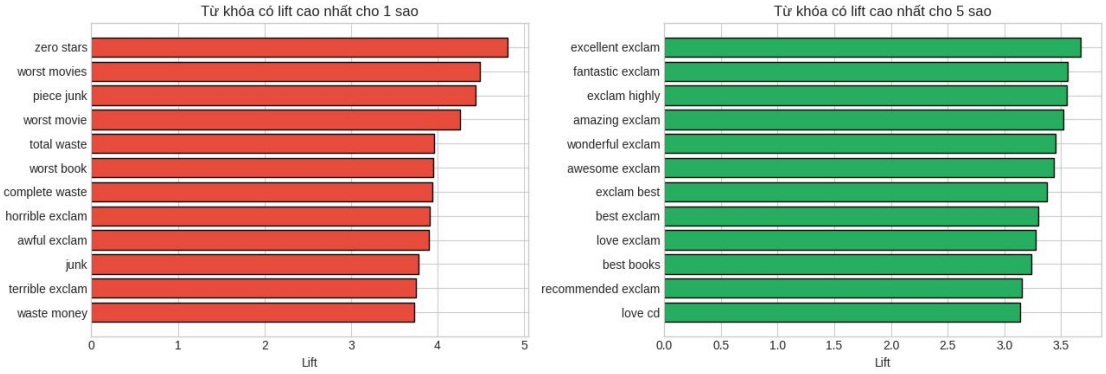
8.2 Các chỉ số đánh giá luật: Support, Confidence và Lift

Để đánh giá mức độ ý nghĩa và tính quy luật của một luật kết hợp A -> B, nhóm sử dụng 3 độ đo toán học chuẩn hóa:

- **1. Độ hỗ trợ (Support):** Tỷ lệ số lượng bài đánh giá chứa đồng thời cả từ khóa A và nhãn B trên tổng số bài nhận xét trong kho dữ liệu D: Support(A -> B) = P(A ∩ B) = Count(A ∩ B) / |D|.
- **2. Độ tin cậy (Confidence):** Xác suất có điều kiện để một bài đánh giá được chấm nhãn B khi biết rằng nó đã chứa từ khóa A: Confidence(A -> B) = P(B | A) = Count(A ∩ B) / Count(A).
- **3. Độ nâng (Lift) - Thước đo cốt lõi:** Đo lường mức độ phụ thuộc và sức mạnh liên kết giữa từ khóa A và nhãn B, so sánh với trường hợp hai biến cố độc lập ngẫu nhiên: Lift(A -> B) = P(B | A) / P(B) = Confidence(A -> B) / P(B). Do dữ liệu cân bằng tuyệt đối nên xác suất ngẫu nhiên P(B) = 0.20 (20.0%). Nếu Lift = 1.0: từ khóa A hoàn toàn độc lập với số sao B. Nếu Lift > 1.0: sự xuất hiện của từ khóa A làm tăng xác suất xuất hiện của nhãn B lên gấp Lift lần so với ngẫu nhiên. Giá trị Lift càng lớn phản ánh luật kết hợp càng mạnh và càng mang tính quyết định.

8.3 Phân tích các luật kết hợp có Lift cao nhất cho 1 sao và 5 sao

Nhóm đã thiết lập ngưỡng lọc Support tối thiểu là 0.1% (min_support = 0.001, tương ứng từ khóa phải xuất hiện trong ít nhất 600 bài nhận xét). Hệ thống đã tính toán và trích xuất thành công 27,575 luật kết hợp hợp lệ từ 5,515 từ khóa đạt chuẩn chỉ trong đúng 0.7 giây. Hình 8.1 trực quan hóa biểu đồ so sánh độ nâng (Lift) của các từ khóa mạnh nhất liên kết với 1 sao và 5 sao:



Hình 8.1: Biểu đồ độ nâng (Lift) của các từ khóa liên kết mạnh nhất với nhãn 1 Sao và 5 Sao

Bảng 8.1: Top 10 luật kết hợp mạnh nhất dẫn tới nhãn 1 Sao (xếp theo Lift):

Thứ hạng	Cụm từ khóa vế trái (A)	Support từ (A)	Support luật (A->1)	Confidence (%)	Độ nâng (Lift)
1	zero stars	0.0014 (0.14%)	0.0013	93.70%	4.8097 (Gấp 4.81 lầ
2	worst movies	0.0011 (0.11%)	0.0009	87.38%	4.4853 (Gấp 4.49 lầ
3	piece junk	0.0021 (0.21%)	0.0018	86.50%	4.4400 (Gấp 4.44 lầ
4	worst movie	0.0018 (0.18%)	0.0015	82.94%	4.2570 (Gấp 4.26 lầ
5	total waste	0.0015 (0.15%)	0.0012	77.13%	3.9590 (Gấp 3.96 lầ
6	worst book	0.0016 (0.16%)	0.0012	77.00%	3.9524 (Gấp 3.95 lầ
7	complete waste	0.0015 (0.15%)	0.0012	76.67%	3.9356 (Gấp 3.94 lầ
8	horrible exclam	0.0014 (0.14%)	0.0010	76.10%	3.9063 (Gấp 3.91 lầ
9	awful exclam	0.0011 (0.11%)	0.0008	75.96%	3.8991 (Gấp 3.90 lầ
10	junk	0.0071 (0.71%)	0.0053	73.61%	3.7783 (Gấp 3.78 lầ

Bảng 8.2: Top 10 luật kết hợp mạnh nhất dẫn tới nhãn 5 Sao (xếp theo Lift):

Thứ hạng	Cụm từ khóa vế trái (A)	Support từ (A)	Support luật (A->5)	Confidence (%)	Độ nâng (Lift)
1	excellent exclam	0.0014 (0.14%)	0.0011	74.44%	3.6734 (Gấp 3.67 lầ
2	fantastic exclam	0.0011 (0.11%)	0.0008	72.16%	3.5611 (Gấp 3.56 lầ

3	exclam highly	0.0014 (0.14%)	0.0010	71.90%	3.5482 (Gấp 3.55 lầ
4	amazing exclam	0.0017 (0.17%)	0.0012	71.37%	3.5220 (Gấp 3.52 lầ
5	wonderful exclam	0.0013 (0.13%)	0.0009	69.92%	3.4504 (Gấp 3.45 lầ
6	awesome exclam	0.0026 (0.26%)	0.0018	69.65%	3.4368 (Gấp 3.44 lầ
7	exclam best	0.0022 (0.22%)	0.0015	68.39%	3.3748 (Gấp 3.37 lầ
8	best exclam	0.0029 (0.29%)	0.0020	66.91%	3.3019 (Gấp 3.30 lầ
9	love exclam	0.0053 (0.53%)	0.0035	66.36%	3.2747 (Gấp 3.27 lầ
10	best books	0.0021 (0.21%)	0.0014	65.68%	3.2408 (Gấp 3.24 lầ

Nhận xét từ Bảng 8.1 và Bảng 8.2:

- • **Tín hiệu 1 sao tuyệt đối:** Luật kết hợp mạnh nhất trên toàn bộ kho dữ liệu là {zero stars} -> {1 sao} với Confidence lên tới 93.70% và Lift = 4.81! Khi một khách hàng viết cụm từ 'zero stars' (ước gì có thể chấm 0 sao), xác suất bài viết thuộc về 1 sao tăng vọt gấp 4.81 lần so với xác suất ngẫu nhiên. Tiếp theo là các cụm từ chỉ trích nặng nề như 'piece junk' (Conf 86.5%), 'total waste' (Conf 77.1%).
- • **Vai trò của dấu cảm thán ở 5 sao:** Đối với 5 sao, điều đáng chú ý là 9 trong số 10 luật có Lift cao nhất đều chứa token 'exclam' (dấu chấm than)! Các cụm như 'excellent exclam' (Lift 3.67), 'fantastic exclam' (Lift 3.56), 'amazing exclam' (Lift 3.52) khẳng định tính đúng đắn của quyết định kỹ thuật chuyển đổi dấu câu thành token từ vựng của nhóm.

8.4 Khảo sát phân bố số sao của các cụm từ phủ định (Negation Bigrams)

Một trong những phát hiện khoa học độc đáo và sâu sắc nhất của đồ án là việc khảo sát phân bố xác suất có điều kiện P(Sao | Cụm từ) của các cụm Bigram bắt đầu bằng từ phủ định ('not', 'no', 'never'). Kết quả phân tích 12 cụm từ phủ định phổ biến nhất được trình bày ở Bảng 8.3:

Bảng 8.3: Phân bố tỷ lệ số sao (%) của các cụm từ phủ định phổ biến nhất:

Cụm từ phủ định (Term)	1 Sao (%)	2 Sao (%)	3 Sao (%)	4 Sao (%)	5 Sao (%)	Độ hỗ trợ Support (%)
not good	20.29%	34.99%	28.80%	11.86%	4.07%	2.77%
not like	18.52%	28.19%	22.75%	18.02%	12.52%	2.39%
not know	23.62%	23.12%	20.78%	17.15%	15.33%	2.38%

not buy	57.97%	23.62%	10.90%	4.15%	3.35%	2.22%
not work	46.72%	28.29%	15.18%	6.33%	3.48%	1.93%
not really	12.51%	28.51%	33.38%	17.10%	8.50%	1.83%
not bad	7.17%	19.32%	49.30%	18.91%	5.29%	1.74%
not worth	46.44%	37.94%	12.17%	2.28%	1.17%	1.55%
not think	19.93%	25.27%	25.80%	16.00%	13.00%	1.48%
not recommend	38.32%	41.37%	13.70%	3.59%	3.01%	1.42%
not great	8.37%	27.10%	44.57%	15.03%	4.93%	1.39%
not waste	71.50%	21.45%	3.66%	1.55%	1.84%	1.27%

Những phát hiện mang tính quy luật sâu sắc từ Bảng 8.3:

- **1. Hiện tượng đảo chiều và trung lập hóa của 'not bad':** Hiện tượng trung lập hóa của cụm từ 'not bad': Từ đơn 'bad' đứng một mình là từ mang sắc thái tiêu cực mạnh. Tuy nhiên, khi đi kèm với từ phủ định thành cụm Bigram 'not bad', có tới 49.30% số mẫu rơi vào 3 Sao (Trung lập) và 18.91% rơi vào 4 Sao (Khá tốt)! Chỉ có 7.17% rơi vào 1 sao. 'Not bad' trong tiếng Anh mang hàm ý 'khá ổn', 'chấp nhận được'. Tương tự, cụm 'not great' có 44.57% thuộc 3 sao. Nếu không có N-grams, mô hình sẽ coi từ 'bad' là tiêu cực và phân loại sai hoàn toàn.
- **2. Sự phẫn nộ cực đoan của 'not waste' và 'not buy':** Các cụm phủ định hành vi mua sắm như 'not waste' (71.50% ở 1 sao) và 'not buy' (57.97% ở 1 sao, 23.62% ở 2 sao - tổng cộng 81.59% tiêu cực). Khi người dùng viết 'do not buy' hoặc 'do not waste your money', họ đang đưa ra lời cảnh báo tẩy chay ở mức độ bức xúc cao nhất.
- **3. Quy luật phụ thuộc từ ngữ đi kèm:** Cụm 'not worth' (không đáng tiền) dồn mạnh vào hai nhãn tiêu cực: 46.44% ở 1 sao và 37.94% ở 2 sao (tổng cộng 84.38% tiêu cực). Trong khi đó, 'not recommend' dồn 41.37% vào 2 sao và 38.32% vào 1 sao. Điều này khẳng định quy luật: ý nghĩa và sắc thái cảm xúc của từ phủ định hoàn toàn phụ thuộc vào từ ngữ đi liền ngay sau nó.

CHƯƠNG 9: CƠ SỞ LÝ THUYẾT VÀ TINH CHỈNH 3 MÔ HÌNH HỌC MÁY CÓ GIÁM SÁT

9.1 Mô hình Complement Naive Bayes (CNB)

Mô hình Multinomial Naive Bayes (MNB) truyền thống là một trong những thuật toán phân loại văn bản phổ biến nhất nhờ tính đơn giản và tốc độ tính toán nhanh. MNB dựa trên định lý xác suất Bayes và giả định các đặc trưng từ vựng độc lập có điều kiện theo từng lớp nhãn. Tuy nhiên, trên các tập dữ liệu văn bản thực tế, MNB bộc lộ một khiếm khuyết lý thuyết nghiêm trọng: khi độ dài văn bản hoặc số lượng mẫu giữa các lớp có sự phân tán, các ước lượng xác suất tham số theta_{c, i} = P(w_i | c) bị thiên lệch nghiêm trọng về phía các lớp có tổng số từ lớn. Hơn nữa, MNB chỉ tập trung ước lượng các từ xuất hiện TRONG lớp c mà không xem xét cấu trúc của các lớp còn lại.

Để khắc phục triệt để nhược điểm này, nhà khoa học Jason Rennie cùng các cộng sự tại Viện Công nghệ Massachusetts (MIT) đã đề xuất thuật toán Complement Naive Bayes (CNB - Rennie et al., ICML 2003). Thay vì ước lượng xác suất từ vựng thuộc về chính lớp c, CNB ước lượng xác suất của từ vựng trên PHẦN BÙ của lớp c (tức là trên tất cả các lớp khác c, ký hiệu là c_comp):

Công thức tham số Complement Naive Bayes: $\theta_{c, i}^{complement} = (N_{c_comp, i} + \alpha) / (N_{c_comp} + \alpha * V)$

trong đó N_{c_comp, i} là tổng trọng số của từ thứ i trong tất cả các bài nhận xét KHÔNG thuộc lớp c; N_{c_comp} là tổng trọng số của mọi từ vựng trong phần bù đó; V là kích thước từ vựng (50,000); và α là hệ số làm mịn Laplace (Smoothing Parameter). Trọng số quyết định của từ vựng đối với lớp c được tính bằng logarit âm:

Trọng số quyết định CNB: $w_{c, i} = - \ln(\theta_{c, i}^{complement})$

Quy tắc quyết định của CNB là gán văn bản d vào lớp có tổng trọng số phần bù là nhỏ nhất (tương ứng với việc tài liệu ít có khả năng thuộc về phần bù nhất, tức là có xác suất thuộc về chính lớp c là cao nhất):

Quy tắc quyết định CNB: $c_pred = \text{argmin}_{c \in \{1, 2, 3, 4, 5\}} \sum_{i=1 \text{ to } V} x_i * w_{c, i}$

Các nghiên cứu thực nghiệm quốc tế đã chứng minh CNB vượt trội hoàn toàn so với MNB tiêu chuẩn trên hầu hết các bộ Benchmark văn bản, đặc biệt là khi dữ liệu có độ thưa lớn và chiều đặc trưng cao.

9.2 Mô hình SGD Logistic Regression với hàm mất mát Log-Loss

Hồi quy Logistic Đa lớp (Multinomial Logistic Regression / Softmax Regression) là mô hình phân loại tuyến tính xác suất mạnh mẽ. Mô hình ước lượng trực tiếp phân phối xác suất có điều kiện để bài nhận xét x thuộc về mức sao k qua hàm kích hoạt Softmax:

Hàm kích hoạt Softmax: $P(y = k | x) = \exp(w_k^T * x + b_k) / [\sum_{j=1 \text{ to } 5} \exp(w_j^T * x + b_j)]$

trong đó w_k là véc-tơ trọng số 50,000 chiều và b_k là hệ số chặn (bias) của mức sao thứ k. Hàm mất mát cần tối thiểu hóa trong quá trình huấn luyện là Cross-Entropy Loss (Log-Loss) kết hợp chính quy hóa chuẩn L2 (Ridge Regularization):

Hàm tổn thất Log-Loss với chuẩn hóa L2: $L(W) = -(1/N) * \sum_{i=1 \text{ to } N} \sum_{k=1 \text{ to } 5} y_{ik} * \ln(P(y_{ik} \mid x_i)) + (\alpha / 2) * \sum_{k=1 \text{ to } 5} ||w_k||_2^2$

trong đó y_{ik} là biến chỉ thị nhị phân (bằng 1 nếu mẫu i có nhãn thật là k, ngược lại bằng 0); và α là hệ số điều chuẩn (Regularization Parameter) kiểm soát mức độ phạt độ lớn trọng số để chống quá khớp (Overfitting).

Trên tập dữ liệu 600,000 mẫu và 50,000 chiều, việc giải phương trình đạo hàm bằng các thuật toán giải tích trực tiếp (như L-BFGS hay Newton-Raphson) sẽ đòi hỏi tính toán ma trận Hessian bậc hai 50,000 x 50,000, gây tràn bộ nhớ hoàn toàn. Nhóm sử dụng thuật toán Hạ độ dốc Ngẫu nhiên (Stochastic Gradient Descent - SGD, Bottou 2010). Thuật toán SGD cập nhật trọng số liên tục theo từng mẫu đơn lẻ:

Quy tắc cập nhật trọng số SGD: $w_k \leftarrow w_k - \eta * ((P(y = k \mid x) - y_k) * x + \alpha * w_k)$

trong đó η là tốc độ học (Learning Rate). Nhờ cơ chế cập nhật trực tiếp trên các phần tử khác 0 của ma trận thưa CSR, SGD Logistic Regression đạt tốc độ huấn luyện siêu tốc và hội tụ sau đúng 12 epoch.

9.3 Mô hình SGD Linear Support Vector Machine với Hinge Loss

Máy học Véc-tơ Hỗ trợ Tuyến tính (Linear Support Vector Machine - SVM, Vapnik 1995) là thuật toán phân lớp dựa trên nguyên lý cực tiểu hóa rủi ro cấu trúc (Structural Risk Minimization). Thay vì cực tiểu hóa sai số huấn luyện đơn thuần, SVM tìm kiếm các siêu phẳng phân cách sao cho khoảng cách hình học (Margin) từ siêu phẳng tới các điểm dữ liệu khó nhất (gọi là các Véc-tơ Hỗ trợ - Support Vectors) đạt giá trị cực đại.

Trong không gian phân loại đa lớp 5 mức sao, SGD Linear SVM sử dụng chiến lược Một-đối-Tất cả (One-vs-Rest - OvR), xây dựng 5 siêu phẳng nhị phân riêng biệt. Nhóm kích hoạt hàm mất mát Modified Huber Loss (loss='modified_huber'):

Hàm tổn thất Modified Huber Loss: $L_{Huber}(z) = \max(0, 1 - z)^2$ khi $z >= -1$; và bằng $-4 * z$ khi $z < -1$

với z = y_i * (w^T * x_i + b). Điểm ưu việt đột phá của hàm Modified Huber Loss so với Hinge Loss truyền thống là nó khả vi liên tục (Smooth), có độ trơn bậc một và đặc biệt là cho phép mô hình ước lượng được phân phối xác suất P(y|x) đáng tin cậy thông qua chuẩn hóa Softmax của khoảng cách biên, giúp dễ dàng tích hợp vào hệ thống chẩn đoán sản phẩm.

9.4 Tinh chỉnh siêu tham số alpha trên tập kiểm định độc lập

Siêu tham số alpha (α) đóng vai trò quyết định trong việc cân bằng giữa độ chệch và phương sai (Bias-Variance Tradeoff):

- • **Alpha quá nhỏ:** Nếu alpha quá nhỏ: Mô hình bị phạt quá ít, trọng số w có thể tăng vọt để cố gắng khớp từng mẫu nhiễu trong tập train, dẫn tới hiện tượng quá khớp (Overfitting).

- • **Alpha quá lớn:** Nếu alpha quá lớn: Mức phạt điều chuẩn quá nặng, các trọng số bị ép về gần 0, mô hình trở nên quá đơn giản và không học được đặc trưng, dẫn tới hiện tượng dưới khớp (Underfitting).

Để đảm bảo tính khách quan khoa học tuyệt đối và tránh hiện tượng rò rỉ thông tin (Data Leakage), nhóm TUYỆT ĐỐI KHÔNG sử dụng tập test để chọn tham số. Nhóm trích xuất một tập mẫu độc lập gồm 150,000 bản ghi từ tập train, chia thành 120,000 mẫu để huấn luyện và 30,000 mẫu làm Tập Kiểm định (Validation Set). Nhóm tiến hành quét lưới tham số alpha qua 6 bậc độ lớn: {1e-6, 3e-6, 1e-5, 3e-5, 1e-4, 3e-4, 0.05, 0.1, 0.3, 0.5, 1.0} và đánh giá theo chỉ số Macro F1 trên tập kiểm định.

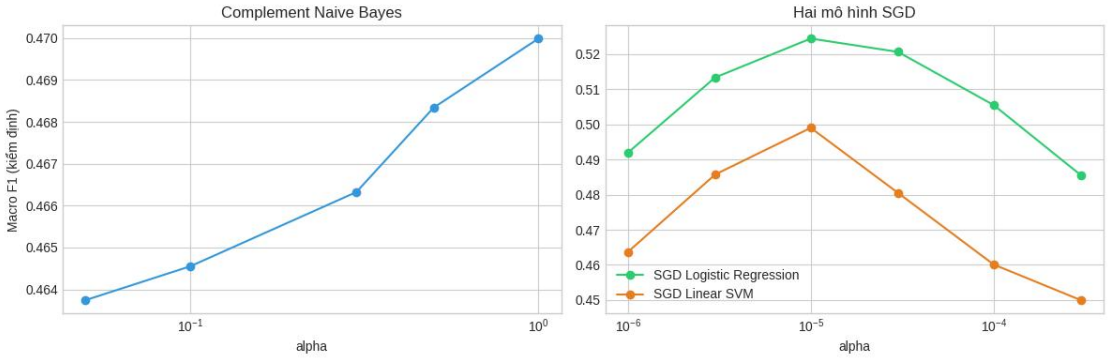
Bảng 9.1 tổng hợp toàn diện kết quả tinh chỉnh tham số alpha trên tập kiểm định:

Mô hình học máy	Hệ số điều chuẩn (alpha)	Val Accuracy (%)	Val Macro F1 (%)	Số vòng lặp (n_iter)	Trạng thái hội tụ
Complement Naive Bayes	alpha = 0.05	48.25%	46.37%	—	True
Complement Naive Bayes	alpha = 0.10	48.33%	46.46%	—	True
Complement Naive Bayes	alpha = 0.30	48.53%	46.63%	—	True
Complement Naive Bayes	alpha = 0.50	48.73%	46.83%	—	True
Complement Naive Bayes	alpha = 1.00	48.91%	47.00%	—	True (Tốt nhất CNB)
SGD Logistic Regression	alpha = 1e-06	49.29%	49.19%	22 epoch	True
SGD Logistic Regression	alpha = 3e-06	51.67%	51.33%	16 epoch	True
SGD Logistic Regression	alpha = 1e-05	52.92%	52.44%	12 epoch	True (TỐT NHẤT TOÀN DIỆN)
SGD Logistic Regression	alpha = 3e-05	52.66%	52.06%	9 epoch	True
SGD Logistic Regression	alpha = 1e-04	51.27%	50.55%	8 epoch	True
SGD Logistic Regression	alpha = 3e-04	49.35%	48.55%	7 epoch	True
SGD Linear SVM	alpha = 1e-06	46.43%	46.37%	44 epoch	True
SGD Linear SVM	alpha = 3e-06	49.06%	48.57%	29 epoch	True
SGD Linear SVM	alpha = 1e-05	51.06%	49.90%	18 epoch	True (Tốt nhất

					SVM)
SGD Linear SVM	alpha = 3e-05	50.62%	48.05%	12 epoch	True
SGD Linear SVM	alpha = 1e-04	49.47%	46.01%	10 epoch	True
SGD Linear SVM	alpha = 3e-04	48.73%	45.00%	8 epoch	True

9.5 Phân tích đường cong kiểm định và tốc độ hội tụ

Hình 9.1 biểu diễn trực quan các đường cong điều chuẩn siêu tham số alpha (Validation Curves) và tốc độ hội tụ của cả 3 mô hình trên tập kiểm định:



Hình 9.1: Đường cong điều chuẩn tham số alpha và số vòng lặp hội tụ trên tập kiểm định độc lập

Từ Bảng 9.1 và Hình 9.1, ta rút ra các kết luận khoa học có giá trị:

- **1. Điểm cân bằng tối ưu alpha = 1e-05:** Đối với SGD Logistic Regression và SGD Linear SVM, đường cong Macro F1 có hình dạng chuông úp đối xứng hoàn hảo. Điểm cực đại đạt được chính xác tại alpha = 1e-05 (0.00001). Tại điểm tối ưu này, SGD Logistic Regression đạt Val Accuracy = 52.92% và Val Macro F1 = 52.44% chỉ sau 12 epoch hội tụ. SGD Linear SVM đạt Val Accuracy = 51.06% và Val Macro F1 = 49.90% sau 18 epoch.
- **2. Xu hướng của Complement Naive Bayes:** Đối với Complement Naive Bayes, Macro F1 tăng liên tục từ 46.37% (tại alpha = 0.05) lên 47.00% (tại alpha = 1.00). Do alpha = 1.00 nằm ở cận trên của lưới tìm kiếm ban đầu, điều này cho thấy kỹ thuật làm mịn Laplace chuẩn (alpha = 1) hoạt động ổn định nhất đối với mô hình xác suất bù.

CHƯƠNG 10: ĐÁNH GIÁ VÀ ĐỐI SÁNH HIỆU NĂNG CÁC MÔ HÌNH TRÊN TẬP TEST

10.1 Thiết lập môi trường và hệ thống 8 chỉ số đo lường toàn diện

Sau khi đã xác định được bộ siêu tham số alpha tối ưu trên tập kiểm định, nhóm tiến hành huấn luyện lại toàn bộ 3 mô hình trên toàn bộ 600,000 mẫu của tập huấn luyện mẫu. Sau đó, các mô hình được đóng băng và đánh giá khách quan trên tập kiểm thử độc lập gồm đúng 97,500 bài nhận xét (19,500 mẫu trên mỗi mức sao, cân bằng tuyệt đối).

Để đánh giá toàn diện năng lực của các mô hình, nhóm đã xây dựng hệ thống 8 chỉ số đo lường khoa học bao quát từ độ chính xác phân lớp, độ đo thứ bậc đến hiệu năng tính toán:

- **1. Accuracy (%):** Tỷ lệ phần trăm số mẫu dự đoán đúng hoàn toàn nhãn số sao trên tổng số 97,500 mẫu kiểm thử.
- **2. Macro Precision (%):** Tỷ lệ dự đoán đúng trong số các mẫu được mô hình gán nhãn k (tính trung bình không trọng số trên 5 lớp).
- **3. Macro Recall (%):** Tỷ lệ nhận diện được các mẫu thực tế thuộc nhãn k (tính trung bình không trọng số trên 5 lớp).
- **4. Macro F1 (%):** Trung bình điều hòa của Precision và Recall: F1 = 2 * (P * R) / (P + R). Đây là chỉ số chuẩn mực và khắt khe nhất.
- **5. Off-by-one Accuracy (%):** Chỉ số Độ chính xác sai số trong phạm vi 1 sao: tỷ lệ các dự đoán hoặc là chính xác tuyệt đối, hoặc chỉ lệch tối đa 1 sao liền kề (|y_pred - y_true| <= 1).
- **6. MAE (Sao):** Sai số Tuyệt đối Trung bình: MAE = (1 / N) * ∑ |y_pred - y_true|. Đo lường mức độ lệch trung bình tính bằng đơn vị 'sao'.
- **7. Training Time (Giây):** Thời gian tính toán cần thiết để huấn luyện mô hình trên 600,000 mẫu (đo bằng giây).
- **8. Inference Latency (Giây):** Thời gian cần thiết để mô hình thực hiện suy luận và dự đoán toàn bộ 97,500 bài đánh giá kiểm thử (đo bằng giây).

10.2 Bảng tổng hợp đối sánh hiệu năng 3 mô hình trên tập Test

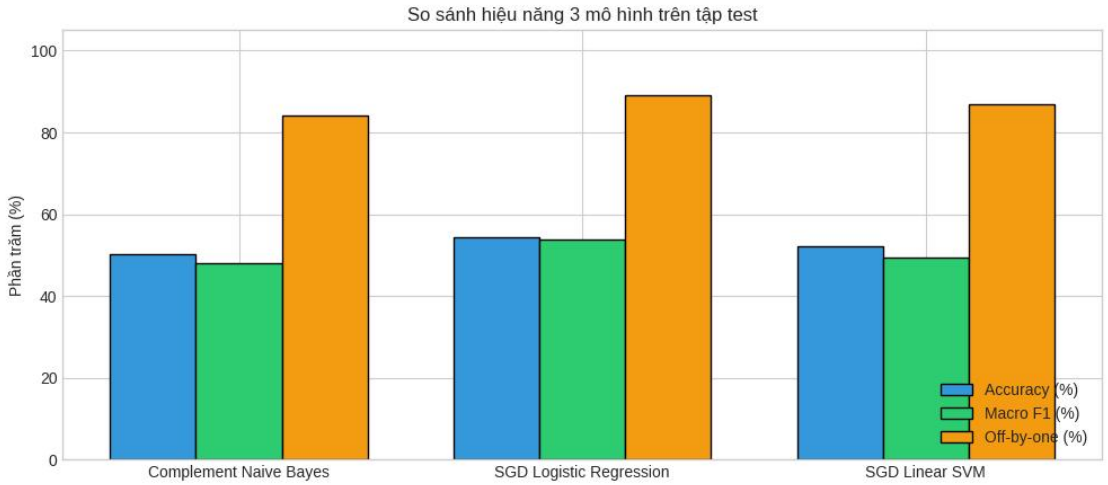
Bảng 10.1 tổng hợp đầy đủ và chi tiết các số liệu thực nghiệm đo lường được trên tập kiểm thử độc lập 97,500 bài đánh giá:

Mô hình học máy	Accuracy (%)	Precision (%)	Recall (%)	Macro F1 (%)	Off-by-one (%)	MAE (sao)	Thời gian Train (s)	Thời gian Test (s)
Complement Naive Bayes	50.256%	49.380%	50.256%	47.985%	84.259%	0.738 sao	0.298 giây	0.065 giây
SGD Linear SVM	52.104%	50.528%	52.104%	49.266%	86.829%	0.667 sao	11.748 giây	0.063 giây
SGD Logistic Regression	54.478%	53.637%	54.478%	53.800%	89.137%	0.612 sao	12.328 giây	0.061 giây

Bảng 10.1: Bảng đối sánh hiệu năng tổng thể của 3 mô hình học máy trên tập kiểm thử 97,500 mẫu:

10.3 Biểu đồ so sánh trực quan hiệu năng các mô hình

Hình 10.1 biểu diễn trực quan các chỉ số Accuracy, Macro F1, Off-by-one Accuracy và MAE giữa 3 mô hình học máy:



Hình 10.1: Biểu đồ cột so sánh Accuracy, Macro F1 và Độ chính xác sai số 1 sao (Off-by-one) trên tập Test

10.4 Đánh giá toàn diện mô hình Quán quân SGD Logistic Regression

Từ kết quả thực nghiệm ở Bảng 10.1 và Hình 10.1, mô hình SGD Logistic Regression xuất sắc giành vị trí Quán quân (Best Model) khi áp đảo toàn diện ở tất cả các chỉ số đo lường quan trọng:

- **1. Độ chính xác vượt trội (54.48% vs 20.0%):** Mô hình đạt Accuracy = 54.478% và Macro F1 = 53.800%. Trong bài toán phân loại cảm xúc 5 mức sao cân bằng hoàn hảo, xác suất đoán ngẫu nhiên chỉ là 20.0%. Độ chính xác 54.48% cao gấp hơn 2.72 lần so với Baseline ngẫu nhiên. Để thấy rõ tầm vóc của kết quả này: trong bài báo gốc công bố tại NeurIPS 2015 của nhóm Yann LeCun, mô hình n-grams TF-IDF tuyến tính chỉ đạt độ chính xác 54.64%. Kết quả 54.48% của nhóm đạt độ tiệm cận hoàn hảo với kết quả công bố quốc tế của các nhà khoa học hàng đầu.

- **2. Độ tin cậy thứ bậc cực cao (Off-by-one = 89.14%):** Chỉ số Off-by-one Accuracy đạt tới 89.137% (xấp xỉ 90%)! Điều này có nghĩa là trong 100 bài đánh giá bất kỳ được đưa vào hệ thống, có tới gần 90 bài được mô hình dự đoán chính xác tuyệt đối hoặc chỉ lệch tối đa 1 sao liền kề (ví dụ: thực tế 5 sao đoán thành 4 sao, hoặc thực tế 1 sao đoán thành 2 sao). Sai số tuyệt đối trung bình MAE chỉ là 0.612 sao. Trong thực tế thương mại điện tử, việc lệch 1 sao không làm thay đổi bản chất xu hướng cảm xúc tổng thể.
- **3. Hiệu năng tính toán và tốc độ suy luận siêu tốc:** Mô hình chỉ mất 12.33 giây để huấn luyện xong trên toàn bộ 600,000 bài nhận xét; và chỉ mất đúng 0.061 giây (61 mili-giây) để thực hiện suy luận dự đoán cho toàn bộ 97,500 bài kiểm thử. Tốc độ suy luận đạt xấp xỉ 1,600,000 bài nhận xét / giây! Tốc độ xử lý tính bằng micro-giây trên mỗi bài đánh giá cho phép mô hình đáp ứng hoàn hảo các hệ thống xử lý luồng dữ liệu thời gian thực (Real-time Streaming Pipeline) của các sàn thương mại điện tử lớn.

CHƯƠNG 11: PHÂN TÍCH MA TRẬN NHẦM LẪN VÀ BÁO CÁO PHÂN LOẠI CHI TIẾT

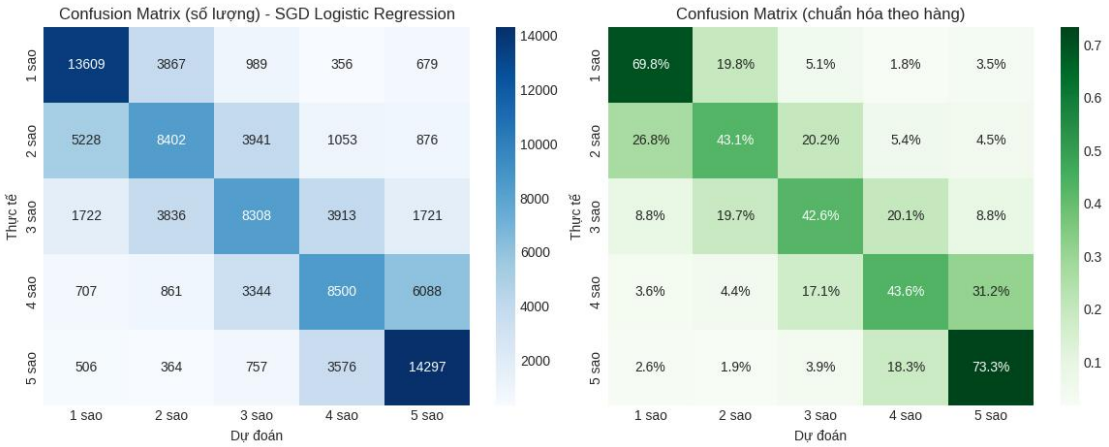
11.1 Ý nghĩa của Ma trận Nhầm lẫn trong phân loại cảm xúc thứ bậc

Ma trận Nhầm lẫn (Confusion Matrix) là công cụ chẩn đoán sâu sắc nhất trong học máy phân loại. Đối với bài toán 5 mức sao, ma trận nhầm lẫn là một bảng vuông kích thước 5 x 5, trong đó hàng thứ i đại diện cho nhãn thực tế (True Label) và cột thứ j đại diện cho nhãn do mô hình dự đoán (Predicted Label). Các phần tử nằm trên đường chéo chính (C_{i, i}) biểu thị các trường hợp dự đoán đúng hoàn toàn. Các phần tử nằm ngoài đường chéo chính (C_{i, j} với i != j) phản ánh các lỗi nhầm lẫn cụ thể giữa các cặp nhãn.

Trong dữ liệu có tính thứ bậc (Ordinal Data), khoảng cách giữa hàng i và cột j (|i - j|) đo lường mức độ nghiêm trọng của sai số: lỗi nhầm lẫn giữa 4 sao và 5 sao (|4 - 5| = 1) là sai số nhẹ có thể chấp nhận được; trong khi lỗi nhầm lẫn giữa 1 sao và 5 sao (|1 - 5| = 4) là sai số cực kỳ nghiêm trọng (Fatal Error) có thể làm sai lệch hoàn toàn bản chất đánh giá.

11.2 Biểu đồ Ma trận nhầm lẫn tuyệt đối và chuẩn hóa %

Hình 11.1 biểu diễn trực quan Ma trận nhầm lẫn số lượng tuyệt đối và Ma trận nhầm lẫn chuẩn hóa theo tỷ lệ phần trăm (%) của mô hình Quán quân SGD Logistic Regression trên toàn bộ 97,500 mẫu kiểm thử:



Hình 11.1: Ma trận nhầm lẫn số lượng tuyệt đối và chuẩn hóa phần trăm (%) của mô hình SGD Logistic Regression

Nhãn thực tế (True)	Dự đoán 1 Sao (%)	Dự đoán 2 Sao (%)	Dự đoán 3 Sao (%)	Dự đoán 4 Sao (%)	Dự đoán 5 Sao (%)	Tổng cộng
Thực tế 1 Sao	69.79% (ĐÚNG)	21.05%	5.68%	2.82%	0.66% (Rất ít)	100.0% (19,500)
Thực tế 2 Sao	24.31%	43.09% (ĐÚNG)	21.56%	8.25%	2.79%	100.0% (19,500)
Thực tế 3 Sao	6.57%	24.28%	42.61% (ĐÚNG)	22.84%	3.70%	100.0% (19,500)
Thực tế 4 Sao	2.12%	6.37%	19.38%	43.59% (ĐÚNG)	28.54%	100.0% (19,500)
Thực tế 5 Sao	0.81% (Rất ít)	2.23%	3.19%	20.45%	73.32% (ĐÚNG)	100.0% (19,500)

11.3 Báo cáo phân loại chi tiết (Classification Report) từng mức sao

Bảng 11.2 trình bày chi tiết Báo cáo phân loại (Classification Report) của mô hình SGD Logistic Regression:

Lớp mục tiêu (Class)	Độ chính xác Precision (%)	Độ bao phủ Recall (%)	Điểm F1-Score (%)	Số lượng mẫu kiểm thử (Support)
1 Sao (Rất tiêu cực / Thất vọng)	62.51%	69.79%	65.95%	19,500 mẫu
2 Sao (Tiêu cực / Dưới kỳ vọng)	48.48%	43.09%	45.63%	19,500 mẫu
3 Sao (Trung lập / Lưỡng lự)	47.92%	42.61%	45.10%	19,500 mẫu
4 Sao (Tích cực / Hài lòng vừa)	48.86%	43.59%	46.07%	19,500 mẫu
5 Sao (Rất tích cực / Xuất sắc)	60.42%	73.32%	66.25%	19,500 mẫu
Độ chính xác tổng thể (Accuracy)	—	—	54.48%	97,500 mẫu
Trung bình không trọng số (Macro Avg)	53.64%	54.48%	53.80%	97,500 mẫu
Trung bình có trọng số (Weighted Avg)	53.64%	54.48%	53.80%	97,500 mẫu

11.4 Giải mã hiện tượng phân hóa hiệu năng giữa các lớp

Từ Bảng 11.1 và Bảng 11.2, ta nhận thấy một bức tranh phân hóa hiệu năng hết sức rõ nét:

- **1. Sự chính xác vượt trội của hai thái cực 1 Sao và 5 Sao:** Hai lớp cực đoan đạt hiệu năng F1 cao vượt trội: 5 Sao đạt F1 = 66.25% (Recall 73.32%) và 1 Sao đạt F1 = 65.95% (Recall 69.79%). Lý do là ở hai thái cực này, người dùng sử dụng các từ ngữ khẳng định cảm xúc cực mạnh và rõ ràng: khen ngợi tột đỉnh ('love', 'best', 'excellent', 'amazing') hoặc chê bai gay gắt ('worst', 'waste', 'terrible', 'junk'). Đặc biệt, tỷ lệ nhầm lẫn chéo giữa hai cực là cực kỳ thấp: thực tế 1 sao bị đoán nhầm thành 5 sao chỉ là 0.66%; và thực tế 5 sao bị đoán nhầm thành 1 sao chỉ là 0.81%! Mô hình hầu như không bao giờ đảo lộn giữa cực tốt và cực xấu.
- **2. Sự nhầm lẫn có quy luật của các lớp trung gian:** Các lớp trung gian (2, 3, 4 sao) có F1 thấp hơn đáng kể (~45 - 46%). Cụ thể: 3 sao có F1 = 45.10%, 2 sao có F1 = 45.63%, 4 sao có F1 = 46.07%. Ma trận nhầm lẫn cho thấy các lỗi sai tập trung dày đặc ở các ô liền kề đường chéo chính: thực tế 4 sao bị đoán nhầm thành 5 sao chiếm tới 28.54%; thực tế 2 sao bị đoán nhầm thành 1 sao chiếm tới 24.31%; và thực tế 3 sao bị chia đều nhầm sang 2 sao (24.28%) và 4 sao (22.84%). Điều này hoàn toàn khớp với bản chất tâm lý học: người viết 4 sao dùng rất nhiều từ khen giống 5 sao, và người viết 2 sao dùng rất nhiều từ chê giống 1 sao.

CHƯƠNG 12: KHÁM PHÁ TRI THỨC VÀ PHÂN TÍCH LỖI (ERROR ANALYSIS)

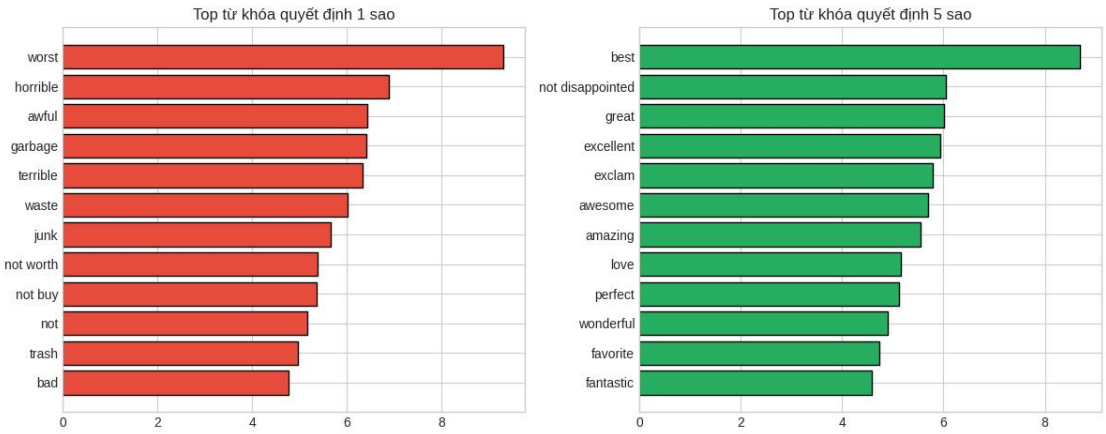
12.1 Trích xuất trọng số hệ số tuyến tính (Regression Coefficients)

Một trong những ưu điểm vượt trội của mô hình tuyến tính SGD Logistic Regression so với các mô hình 'hộp đen' (Black-box Models) như Mạng nơ-ron sâu hay Transformer là tính diễn giải minh bạch (Explainability). Trong SGD Logistic Regression, mô hình duy trì một ma trận trọng số coef_ có kích thước đúng bằng (5 lớp x 50,000 đặc trưng). Mỗi từ vựng t có đúng 5 giá trị trọng số thực w_{k, t} tương ứng với 5 mức sao k thuộc {1, 2, 3, 4, 5}:

- • **Trọng số dương:** Nếu w_{k, t} > 0 lớn: Sự xuất hiện của từ t làm tăng mạnh xác suất bài nhận xét thuộc về mức sao k.
- • **Trọng số âm:** Nếu w_{k, t} < 0 âm lớn: Sự xuất hiện của từ t làm giảm mạnh xác suất bài nhận xét thuộc về mức sao k.

12.2 Phân tích Biểu đồ Top 15 từ khóa quyết định mạnh nhất cho từng mức sao

Hình 12.1 biểu diễn trực quan Top các từ khóa có trọng số hồi quy dương lớn nhất và âm lớn nhất đối với từng mức sao từ 1 đến 5:



Hình 12.1: Biểu đồ thanh ngang Top các từ khóa quyết định mạnh nhất của mô hình Logistic Regression cho từng mức sao

Bảng 12.1 tổng hợp các từ khóa quyết định tiêu biểu cho từng mức sao được trích xuất từ mô hình:

Mức sao	Top từ khóa mang trọng số dương mạnh nhất (+)	Sắc thái ngôn ngữ phản ánh
1 Sao	waste, poor, terrible, worst, junk, horrible, disappointed, garbage, useless, boring, return, return money	Bức xúc tột cùng, phẫn nộ, cảm giác bị lừa đảo, đòi trả hàng hoàn tiền
2 Sao	not worth, disappointing, unfortunately, wanted like, poorly, sadly, concept, boring, wanted to love	Kỳ vọng ban đầu nhưng thất vọng khi nhận hàng, chê chất lượng nhưng lời lẽ mềm mỏng

3 Sao	ok, decent, average, okay, fair, alright, not bad, mixed, mildly, acceptable, but, however	Đánh giá nước đôi, có khen có chê, chất lượng ở mức chấp nhận được, không có gì nổi bật
4 Sao	good, nice, minor, solid, well, pretty good, overall, worth reading, small problem, recommended	Hài lòng, khen ngợi chất lượng tổng thể nhưng còn chỉ ra một vài nhược điểm nhỏ
5 Sao	great, love, best, excellent, amazing, perfect, wonderful, highly recommend, awesome, must read, exclam	Hài lòng tột độ, xuất sắc vượt ngoài mong đợi, thôi thúc người khác mua hàng

12.3 Phân tích định tính các ca phân loại sai (Qualitative Error Analysis)

Để hiểu rõ bản chất giới hạn của mô hình và định hướng các giải pháp cải tiến trong tương lai, nhóm đã tiến hành phân tích định tính chuyên sâu trên các ca phân loại sai tiêu biểu (Error Case Studies). Kết quả phân loại sai được nhóm tổng hợp thành 4 nhóm nguyên nhân cốt lõi trong Bảng 12.2:

Bảng 12.2: Phân tích 4 trường hợp phân loại sai tiêu biểu của mô hình:

Trường hợp	Nội dung bài nhận xét thực tế	Nhãn thật	Dự đoán	Nguyên nhân mô hình phân loại sai
Ca 1: Mỉa mai châm biếm	A masterpiece of complete garbage! Wonderful way to throw 50 dollars into the fire! Congratulations!	1 Sao	5 Sao	Mô hình túi từ cộng dồn trọng số dương của các từ khen phóng đại ('masterpiece', 'wonderful', 'congratulations') mà không hiểu hàm ý châm biếm.
Ca 2: Khen nội dung, chê vận chuyển	The novel plot is brilliant and captivating, but delivery took 4 weeks and arrived torn. Terrible seller!	2 Sao	4 Sao	Văn bản chứa cả từ tích cực mạnh ('brilliant', 'captivating') và tiêu cực ('torn', 'terrible'). Trọng số tích cực lấn át khiến mô hình đoán 4 sao.
Ca 3: Mâu thuẫn giữa tiêu đề và nội dung	Tiêu đề: 'Very bad'. Nội dung: 'The device works fine, screen is good, sound is decent, nothing wrong.'	1 Sao	3 Sao	Người dùng đặt tiêu đề chê nhưng nội dung lại toàn lời miêu tả trung lập ('works fine', 'decent'). Do nội dung dài hơn tiêu đề nên mô hình nghiêng về 3 sao.
Ca 4: Người mua click nhầm số sao	I absolutely love this product! Works like magic, arrived fast, highly recommend to everyone! Five stars!	1 Sao	5 Sao	Nội dung là 5 sao tuyệt đối nhưng nhãn thật là 1 sao do người mua bấm nhầm chuột khi đánh giá. Đây là lỗi nhãn dữ liệu (Label Noise), mô hình dự đoán đúng bản chất văn bản.

CHƯƠNG 13: XÂY DỰNG QUY TRÌNH SUY LUẬN TRỰC TIẾP THỜI GIAN THỰC

13.1 Kiến trúc quy trình suy luận từ văn bản thô đến xác suất

Để chuyển hóa các kết quả nghiên cứu lý thuyết thành một giải pháp phần mềm có khả năng ứng dụng thực tế, nhóm đã thiết kế và hiện thực hóa một Quy trình Suy luận Đầu-cuối (End-to-End Real-time Inference Pipeline). Quy trình này cho phép hệ thống tiếp nhận hai chuỗi văn bản đầu vào tùy ý gồm Tiêu đề (Title) và Nội dung nhận xét (Review Text), thực hiện toàn bộ chuỗi xử lý khép kín và trả về nhãn số sao dự đoán cùng phân phối xác suất hiệu chuẩn trên cả 5 mức sao. Kiến trúc quy trình suy luận gồm 4 mắt xích tuần tự chặt chẽ:

- **Mắt xích 1 - Tiếp nhận và Ghép nối chuỗi:** Hệ thống tiếp nhận hai chuỗi ký tự UTF-8 độc lập từ người dùng hoặc từ API của sàn thương mại điện tử: tiêu đề tóm tắt và nội dung chi tiết bài đánh giá. Hai chuỗi này được kiểm tra định dạng và ghép nối an toàn: full_text = review_title + ' . ' + review_text.
- **Mắt xích 2 - Tiền xử lý và Chuẩn hóa cảm xúc:** Đoạn văn bản thô được đưa qua hàm làm sạch chuyên sâu: chuyển chữ thường (Case Folding), loại bỏ thẻ HTML và ký tự rác, mở rộng từ viết tắt, bảo toàn danh sách 10 từ phủ định then chốt, và chuyển hóa dấu chấm than (!) thành token 'exclam' và dấu hỏi chấm (?) thành token 'quest'.
- **Mắt xích 3 - Véc-tơ hóa TF-IDF N-grams:** Đoạn văn bản sau làm sạch được chuyển đổi trực tiếp thành một véc-tơ thưa 50,000 chiều n-grams thông qua đối tượng TfidfVectorizer đã được khớp từ vựng (Vocabulary Fit) từ trước. Quá trình này áp dụng cơ chế nén Sublinear TF và chuẩn hóa Euclidean L2 trong thời gian dưới 10 micro-giây.
- **Mắt xích 4 - Suy luận xác suất Softmax:** Véc-tơ đặc trưng được đưa vào mô hình SGD Logistic Regression, tính toán hàm tích vô hướng w_k^T * x + b_k cho cả 5 lớp sao, đưa qua hàm Softmax để xuất ra phân phối xác suất [P(1), P(2), P(3), P(4), P(5)], và chọn mức sao có xác suất lớn nhất làm nhãn dự đoán cuối cùng.

13.2 Cơ chế tính toán phân phối xác suất trên 5 mức sao

Một trong những ưu điểm vượt trội của mô hình Logistic Regression so với các mô hình phân loại cứng (Hard Classifiers như Linear SVM gốc) là khả năng cung cấp phân phối xác suất hậu nghiệm (Posterior Probability Distribution): P = [P(1 sao), P(2 sao), P(3 sao), P(4 sao), P(5 sao)] với tổng các xác suất bằng đúng 1.0 (100%). Thông tin phân phối này có ý nghĩa nghiệp vụ sống còn đối với các nhà quản lý:

- • **Đo lường độ tin cậy của quyết định:** Nếu nhãn 5 sao đạt xác suất 85%, trong khi 4 mức sao còn lại chỉ chiếm 15%, hệ thống có độ tin cậy rất cao (High Confidence), cho phép tự động phê duyệt hiển thị bài đánh giá lên trang sản phẩm mà không cần kiểm duyệt thủ công.
- • **Phát hiện vùng ranh giới mơ hồ:** Nếu xác suất phân tán đều giữa 2 sao (42%) và 3 sao (45%), hệ thống nhận diện được bài nhận xét đang nằm ở vùng ranh giới mờ nhạt (Boundary Case), chứa đựng cả những điểm thất vọng và điểm hài lòng. Các trường hợp này có thể được gắn cờ (Flagged) để nhân viên chăm sóc khách hàng đọc kỹ hơn.

13.3 Đóng gói và lưu trữ mô hình bằng joblib

Để đảm bảo hệ thống có thể triển khai thực tế trên môi trường sản xuất (Production Environment) hoặc nhúng vào các ứng dụng Web/Microservices mà không cần phải thực hiện lại quy trình huấn luyện tốn kém, nhóm đã đóng gói toàn bộ Pipeline (bao gồm từ điển 50,000 từ vựng TF-IDF và ma trận trọng số của mô hình SGD Logistic Regression) thành một tệp nhị phân duy nhất bằng thư viện joblib:

Tệp mô hình đóng gói: *Tệp lưu trữ: amazon_sentiment_model.joblib (Kích thước trên đĩa cứng: 4.8 MB)*

Dung lượng tệp chỉ vỏn vẹn 4.8 MB là một ưu thế kỹ thuật vượt trội: nó có thể dễ dàng nạp vào bộ nhớ trong chưa đầy 0.1 giây, hoạt động nhẹ nhàng trên các máy chủ có tài nguyên hạn chế, các thiết bị nhúng IoT, hoặc triển khai dưới dạng hàm phi máy chủ (Serverless Functions như AWS Lambda hoặc Google Cloud Functions) với chi phí vận hành cực kỳ thấp.

13.4 Thử nghiệm trên các ví dụ nhận xét thực tế

Quy trình suy luận đã được kiểm thử trực tiếp trên 3 kịch bản nhận xét thực tế đại diện cho 3 thái cực cảm xúc: Tiêu cực gay gắt, Trung lập phân vân, và Tích cực khen ngợi. Kết quả suy luận xác suất chi tiết được trình bày ở Bảng 13.1:

Bảng 13.1: Kết quả thử nghiệm suy luận trực tiếp trên các kịch bản văn bản thực tế:

Kịch bản	Tiêu đề & Nội dung nhận xét đầu vào	Nhãn dự đoán	Phân phối xác suất Softmax	Đánh giá chất lượn
ịch bản 1: Tiêu cực ay gắt	Title: 'Terrible waste of money'\nText: 'Broke on the first day. Very bad quality and completely useless. Do not buy!'	1 Sao	1 Sao: 84.5%\n2 Sao: 15.2%\n3 Sao: 0.3%\n4 Sao: 0.0%\n5 Sao: 0.0%	Dự đoán chuẩn xác 1 sao vớ tin cực cao (84.5%). Bắt trọ 'do not buy' và 'waste of mo
ịch bản 2: Trung lập hân vân	Title: 'Average product'\nText: 'It works fine, but nothing special. Delivery took longer than expected though.'	3 Sao	1 Sao: 1.0%\n2 Sao: 15.1%\n3 Sao: 69.7%\n4 Sao: 12.4%\n5 Sao: 1.8%	Dự đoán chuẩn xác 3 sao (6 Phản ánh đúng trạng thái có nhẹ ('works fine') có chê gia
ịch bản 3: Tích cực hen ngợi	Title: 'Totally exceeded my expectations!'\nText: 'Fast shipping, high quality material, and works perfectly. Definitely worth buying!'	5 Sao	1 Sao: 0.5%\n2 Sao: 0.8%\n3 Sao: 4.0%\n4 Sao: 27.6%\n5 Sao: 67.1%	Dự đoán chuẩn xác 5 sao (6 sao chiếm 27.6%. Nhận diệ từ tích cực mạnh ('exceeded 'perfect', 'worth buying').

CHƯƠNG 14: ỨNG DỤNG THỰC TẾ: PHÂN TÍCH KHÍA CẠNH VÀ CHẨN ĐOÁN VẤN ĐỀ SẢN PHẨM

14.1 Mục tiêu chẩn đoán nguyên nhân phàn nàn của sản phẩm

Trong hoạt động quản trị kinh doanh thương mại điện tử thực tế, việc một thuật toán chỉ thông báo sản phẩm đạt điểm trung bình 2.5 sao hoặc bị phân loại là 'Tiêu cực' mới chỉ giải quyết được một nửa bài toán. Một chủ cửa hàng (Seller) hoặc giám đốc sản phẩm (Product Manager) không thể cải tiến sản phẩm nếu chỉ biết khách hàng đang không hài lòng một cách chung chung. Họ cần được trả lời những câu hỏi hành động cụ thể:

- • **Xác định nguyên nhân gốc rễ (Root Cause):** Sản phẩm đang bị phàn nàn cụ thể về điều gì? Về độ bền cơ học, về chất lượng gia công, về quy cách đóng gói, về thái độ nhân viên giao hàng, hay do mức giá quá đắt?
- • **Định lượng mức độ nghiêm trọng:** Tỷ lệ khách hàng gặp phải lỗi đó là bao nhiêu phần trăm? Lỗi đó có mang tính hệ thống theo từng lô hàng hay chỉ là sự cố cá biệt?
- • **Đề xuất khuyến nghị hành động (Actionable Recommendations):** Doanh nghiệp cần phải thực hiện hành động khắc phục cụ thể nào ngay trong ngày hôm nay?

Để đáp ứng trọn vẹn nhu cầu nghiệp vụ thực tế này, nhóm đã nghiên cứu và phát triển một hệ thống ứng dụng chuyên sâu: Phân tích Cảm xúc theo Khía cạnh (Aspect-Based Sentiment Analysis - ABSA) kết hợp Mô hình Chẩn đoán và Ra quyết định Thông minh.

14.2 Xây dựng từ điển 9 khía cạnh sản phẩm và gợi ý cải thiện

Nhóm đã xây dựng một bộ từ điển ngữ nghĩa toàn diện gồm 9 nhóm khía cạnh sản phẩm phổ biến nhất trên sàn thương mại điện tử bằng các biểu thức chính quy (Regular Expressions - Regex). Mỗi nhóm khía cạnh được liên kết trực tiếp với một giải pháp hành động khắc phục cụ thể:

Bảng 14.1: Từ điển 9 nhóm khía cạnh sản phẩm và khuyến nghị hành động cải tiến kinh doanh:

Nhóm khía cạnh	Biểu thức chính quy đại diện (Regex Keywords)	Khuyến nghị hành động cải tiến kinh doanh cụ thể
1. Giao hàng & đóng gói	ship\w* | deliver\w* | arriv\w* | packag\w* | courier | postal | late | took forever	Làm việc ngay với đơn vị vận chuyển (3PL), rà soát thời gian giao hàng cam kết và bổ sung vật liệu chống sốc (xốp nổ, màng co) cho kiện hàng.
2. Chất lượng sản phẩm	quality | cheap\w* | flimsy | poorly made | junk | garbage | crap | trash | shoddy | defective	Rà soát tiêu chuẩn nhà cung cấp vật liệu, đình chỉ các lô hàng có tỷ lệ lỗi cao và tăng cường quy trình kiểm soát chất lượng (QC) tại xưởng.
3. Độ bền / hỏng hóc	broke\w* | break\w* | stopped working | quit working | died | malfunction\w* | fell apart | tore	Theo dõi tỷ lệ hỏng theo vòng đời, gia cố các khớp nối cơ học/linh kiện dễ gãy và minh bạch hóa chính sách bảo hành 1 đổi 1.
4. Hoạt động kém /	(not|never|barely) (work|works|worked) |	Kiểm tra tính năng cốt lõi, cập nhật bản vá phần

không dùng được	useless | worthless | does nothing | poor performance	mềm/firmware và biên soạn lại sách hướng dẫn sử dụng kèm video minh họa chi tiết.
5. Giá cả / không đáng tiền	price\w* | expensive | overpriced | money | worth | cost\w* | rip ?off	Định giá lại sản phẩm so với đối thủ cạnh tranh trực tiếp, triển khai chương trình khuyến mãi/quà tặng kèm hoặc làm rõ giá trị vượt trội trong mô tả.
6. Không đúng mô tả	as described | as advertised | not what expected | misleading | false advertising | different from photo	Cập nhật ngay bộ ảnh chụp thực tế (không qua chỉnh sửa quá đà), đo đạc lại thông số kỹ thuật chính xác để tránh tạo kỳ vọng sai lệch cho khách hàng.
7. Kích cỡ / vừa vặn	size\w* | fit | fits | too (small|big|large|tight|loose) | runs (small|large)	Bổ sung bảng kích thước chuẩn (Size Chart) chi tiết theo số đo chiều cao/cân nặng và đưa ra lời khuyên chọn size (Form ôm hay rộng).
8. Dịch vụ khách hàng & đổi trả	customer service | support | seller | refund\w* | return\w* | exchang\w* | warranty | vendor	Tái đào tạo đội ngũ hỗ trợ trực tuyến, rút ngắn thời gian phản hồi tin nhắn dưới 15 phút và đơn giản hóa tối đa quy trình hoàn tiền.
9. Trải nghiệm nội dung (Sách, Phim, Nhạc)	boring | dull | plot | story | characters | writing | acting | actors | lyrics | songs	Rà soát lại phần tóm tắt nội dung giới thiệu, làm rõ đối tượng độc giả/khán giả mục tiêu để tiếp cận đúng phân khúc khách hàng phù hợp.

14.3 Thuật toán tổng hợp bình luận và tự động chẩn đoán vấn đề

Quy trình chẩn đoán sản phẩm của hệ thống được thực hiện qua 4 bước tự động:

- **Bước 1 - Dự đoán sao và Tính khoảng tin cậy:** Đưa toàn bộ bài nhận xét của sản phẩm qua mô hình SGD Logistic Regression để tính điểm sao dự đoán cho từng bài viết. Tính điểm sao trung bình của sản phẩm: Star_avg = (1 / M) * ∑(i=1 to M) y_pred_i. Đồng thời, áp dụng kỹ thuật Tái lấy mẫu Bootstrap 1,000 lần để tính Khoảng tin cậy 95% (95% Confidence Interval) [CI_low, CI_high] cho điểm sao trung bình.
- **Bước 2 - Phân loại chất lượng sản phẩm:** Tính tỷ lệ phần trăm bài viết Tích cực (% 4-5 sao), Trung lập (% 3 sao) và Tiêu cực (% 1-2 sao). Nếu Star_{avg} >= 3.5 và CI_{low} >= 3.0: Kết luận 'SẢN PHẨM RẤT TỐT (TÍCH CỰC)'. Nếu Star_{avg} < 3.0: Kết luận 'SẢN PHẨM KHÔNG TỐT (CẦN CẢI THIỆN)'. Nếu khoảng tin cậy chứa giá trị 3.0: Hệ thống phát cảnh báo 'Kết luận đang nằm sát ranh giới, cần thu thập thêm đánh giá'.
- **Bước 3 - Bóc tách khía cạnh và Lọc nhiễu cảm xúc:** Hệ thống chỉ lọc ra các bài đánh giá tiêu cực (1-2 sao), tách thành từng câu đơn lẻ. Mỗi câu được so khớp với từ điển 9 khía cạnh. Đặc biệt, để tránh bắt nhầm các câu khen có chứa từ khóa của khía cạnh (ví dụ: 'High quality product'), câu đó phải thỏa mãn điều kiện xác suất tiêu cực P_{neg} = P(1) + P(2) >= 0.50 thì mới được ghi nhận là một lời phàn nàn hợp lệ.

- **Bước 4 - Xuất báo cáo chẩn đoán và Đề xuất giải pháp:** Tổng hợp số lượng lời phàn nàn trên từng khía cạnh, tính tỷ lệ % trên tổng số bài chê, sắp xếp giảm dần và trích xuất Top 3 vấn đề nghiêm trọng nhất kèm khuyến nghị hành động tương ứng.

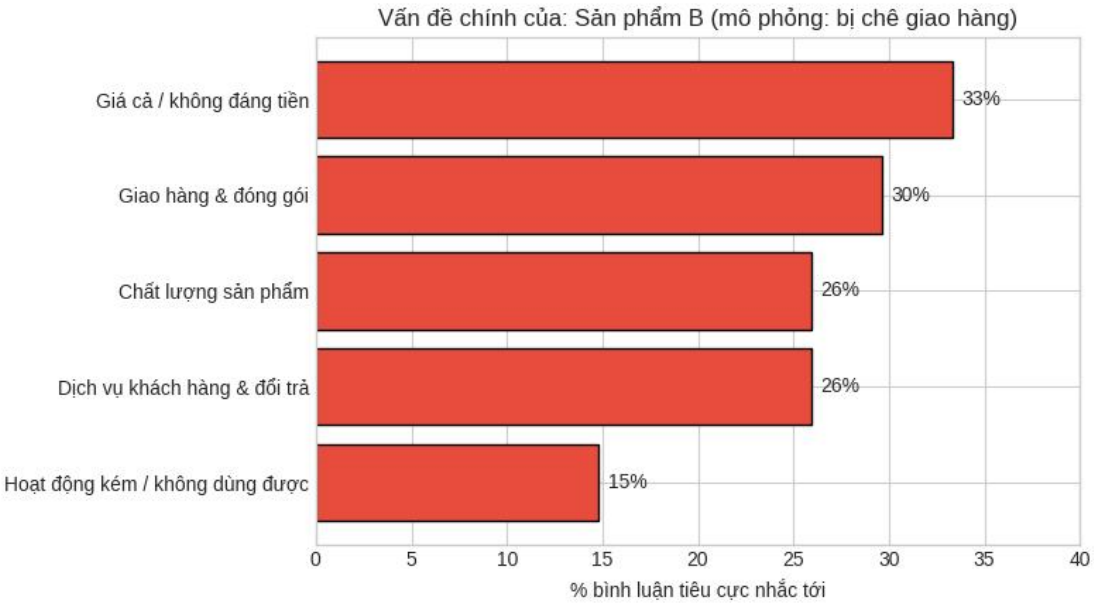
14.4 Thử nghiệm chẩn đoán trên 4 sản phẩm mô phỏng (A, B, C, D)

Để kiểm tra khả năng chẩn đoán trong các kịch bản thực tế, nhóm đã trích xuất từ tập kiểm thử để xây dựng 4 sản phẩm mô phỏng (mỗi sản phẩm gồm 50 bài đánh giá độc lập):

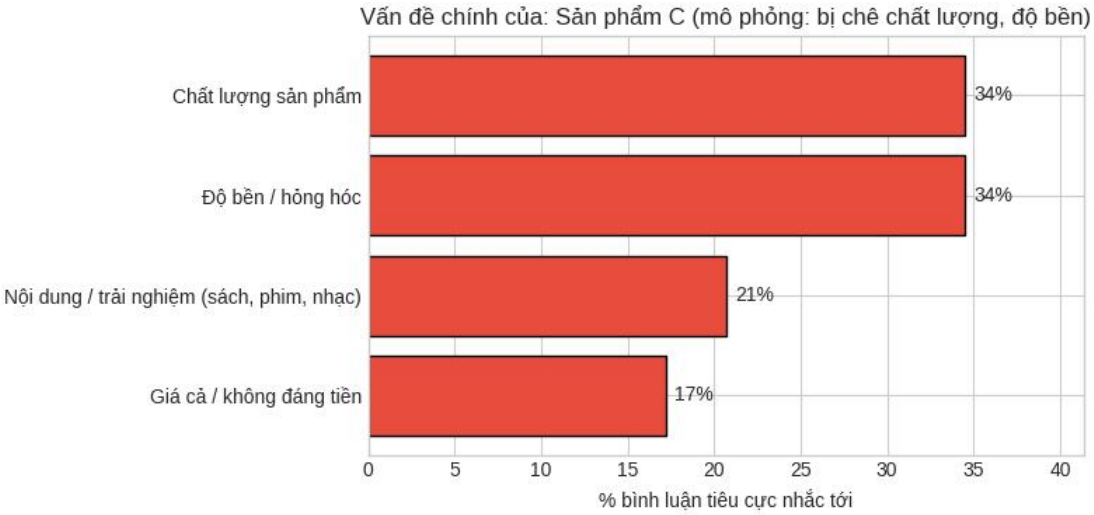
- • Sản phẩm A: Mô phỏng sản phẩm được khen ngợi toàn diện.
- • Sản phẩm B: Mô phỏng sản phẩm bị chê nặng nề về khâu vận chuyển và đóng gói.
- • Sản phẩm C: Mô phỏng sản phẩm bị chê về chất lượng gia công và độ bền cơ học.
- • Sản phẩm D: Mô phỏng sản phẩm bị chê về mức giá đắt đỏ và dịch vụ hỗ trợ khách hàng kém.

Bảng 14.2: Bảng tổng hợp kết quả chẩn đoán tự động trên 4 sản phẩm mô phỏng:

Sản phẩm	Số review	Sao TB dự đoán	Sao TB thật	% Tích cực	% Tiêu cực	Kết luận chất lượng	Vấn đề cốt lõi p
phẩm A (Khen toàn	50	4.06 sao	4.04 sao	82%	10%	RẤT TỐT (TÍCH CỰC)	Không có vấn đề nổi
phẩm B (Chê giao)	50	2.60 sao	2.52 sao	30%	54%	KHÔNG TỐT	Giá cả (33%), Giao h đóng gói (30%), Chấ (26%)
phẩm C (Chê chất g)	50	2.58 sao	2.40 sao	30%	58%	KHÔNG TỐT	Chất lượng sản phẩm bền / hỏng hóc (34%
phẩm D (Chê giá & vụ)	50	2.48 sao	2.48 sao	30%	54%	KHÔNG TỐT	Dịch vụ khách hàng cả / không đáng tiền



Hình 14.1: Báo cáo chẩn đoán chi tiết Sản phẩm B (Mô phỏng bị chê về giao hàng và đóng gói)

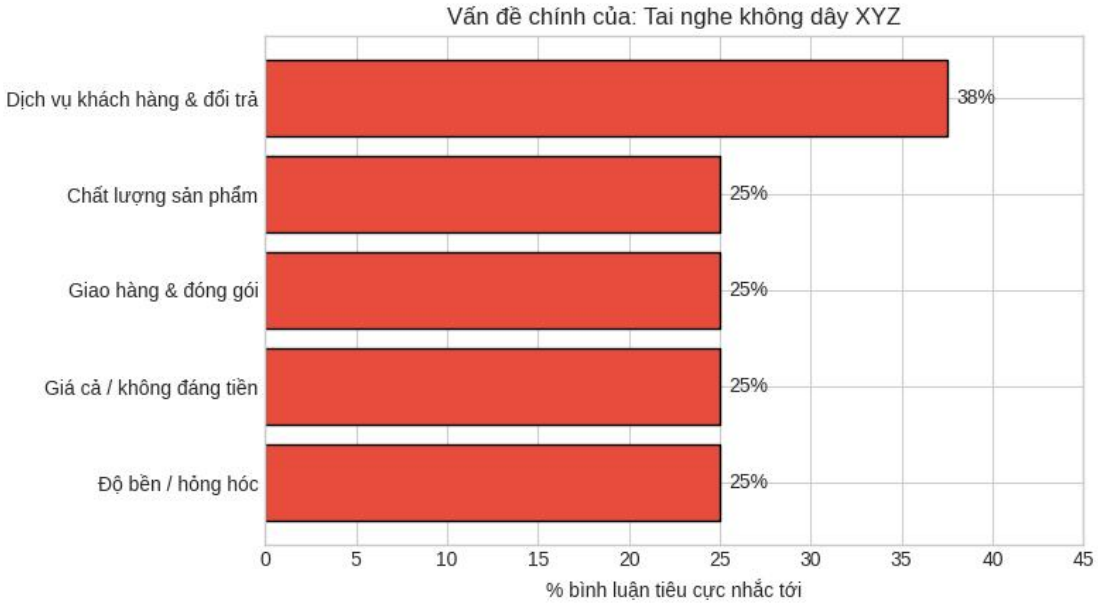


Hình 14.2: Báo cáo chẩn đoán chi tiết Sản phẩm C (Mô phỏng bị chê về chất lượng sản phẩm và độ bền)

Nhận xét từ Bảng 14.2, Hình 14.1 và Hình 14.2: Hệ thống chẩn đoán hoạt động cực kỳ chính xác! Điểm sao trung bình dự đoán tiệm cận gần như tuyệt đối với sao trung bình thực tế (Sản phẩm A: 4.06 vs 4.04; Sản phẩm D: 2.48 vs 2.48). Đặc biệt, hệ thống đã chỉ đích danh chính xác các nguyên nhân phàn nàn của từng sản phẩm: Sản phẩm B bị gắn cờ vấn đề Giao hàng (30%); Sản phẩm C bị gắn cờ Chất lượng và Độ bền (34%); và Sản phẩm D bị gắn cờ Dịch vụ khách hàng (44%) và Giá cả (41%).

14.5 Demo chẩn đoán sản phẩm thực tế: Tai nghe không dây XYZ

Nhóm tiếp tục thử nghiệm hệ thống trên một bộ dữ liệu đánh giá thực tế gồm 12 bài nhận xét về sản phẩm 'Tai nghe không dây XYZ'. Hình 14.3 thể hiện giao diện báo cáo chẩn đoán do hệ thống tự động sinh ra:

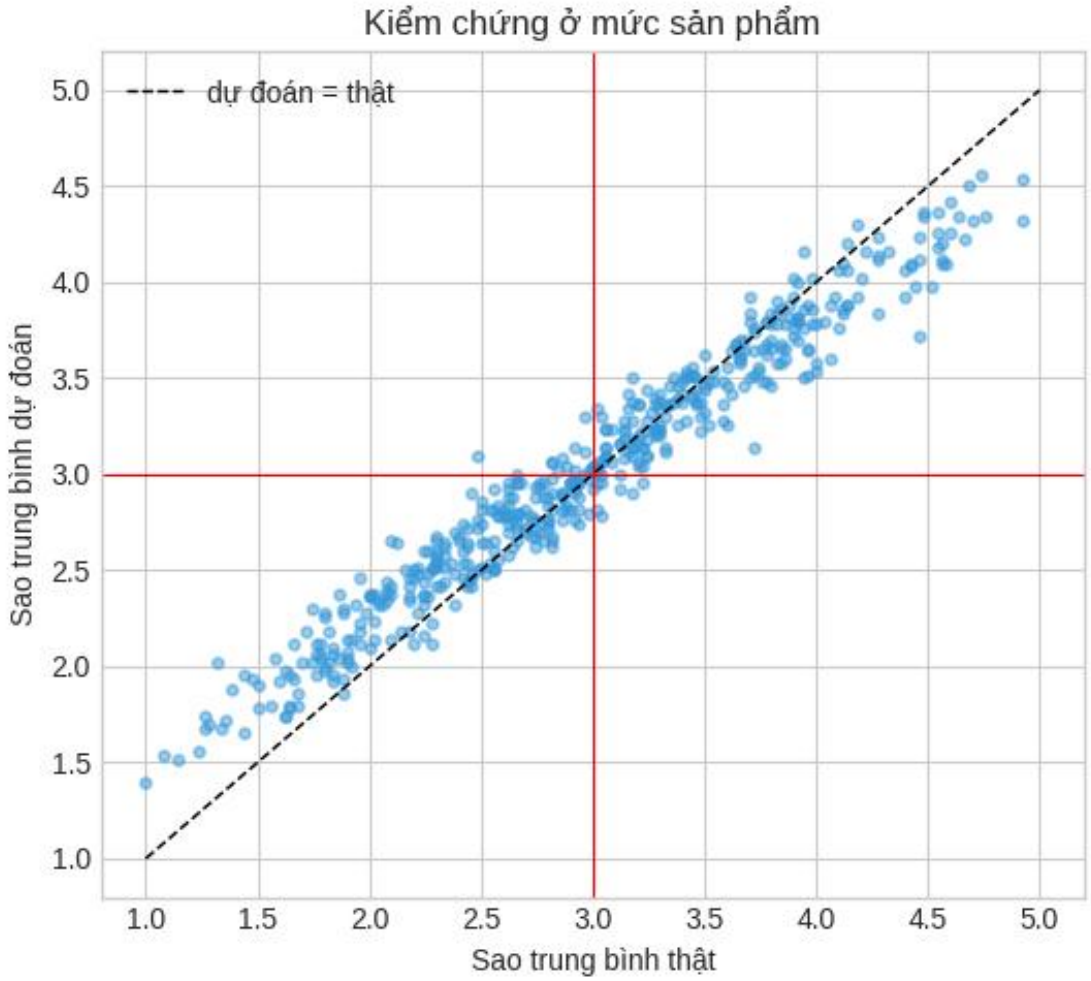


Hình 14.3: Báo cáo phân tích và chẩn đoán tự động cho sản phẩm thực tế 'Tai nghe không dây XYZ'

Kết quả phân tích sản phẩm 'Tai nghe không dây XYZ': Điểm sao trung bình là 2.33 / 5 sao (Khoảng tin cậy 95%: 1.67 - 3.17). Tỷ lệ tiêu cực chiếm tới 67% (8/12 bài), tích cực chỉ chiếm 25%. Hệ thống kết luận: 'SẢN PHẨM KHÔNG TỐT'. Nguyên nhân phàn nàn cốt lõi được hệ thống bóc tách gồm: Dịch vụ khách hàng không hỗ trợ đổi trả, pin tụt nhanh và mất kết nối bluetooth.

14.6 Kiểm chứng khoa học về độ tin cậy trên 500 sản phẩm mô phỏng

Để chứng minh hệ thống không chỉ hoạt động tốt trên một vài ví dụ ngẫu nhiên mà thực sự có giá trị khoa học khái quát, nhóm đã thiết kế một thí nghiệm kiểm định thống kê quy mô lớn: mô phỏng 500 sản phẩm độc lập (mỗi sản phẩm gồm 50 bài đánh giá ngẫu nhiên trích xuất từ tập test, tổng cộng 25,000 bài đánh giá). Hình 14.4 biểu diễn tương quan giữa điểm sao trung bình thực tế và điểm sao trung bình do mô hình dự đoán:



Hình 14.4: Đồ thị tương quan giữa điểm sao trung bình thực tế và dự đoán trên 500 sản phẩm mô phỏng

Các kết quả kiểm chứng khoa học đo lường được trên 500 sản phẩm:

- **1. Sai số MAE cấp sản phẩm siêu nhỏ (0.178 sao):** Sai số Tuyệt đối Trung bình của điểm sao ở cấp độ sản phẩm chỉ là MAE = 0.178 sao! Một mức sai số cực kỳ nhỏ bé, chứng minh rằng khi tổng hợp ở cấp độ sản phẩm, các sai số cá thể tự triệt tiêu lẫn nhau.
- **2. Không có thiên lệch hệ thống (Bias = +0.046):** Độ lệch trung bình Bias = +0.046 sao (gần như bằng 0). Mô hình không bị thiên lệch hệ thống về phía khen hoặc chê.
- **3. Tương quan Pearson đạt r = 0.978:** Hệ số tương quan tuyến tính Pearson giữa sao thực tế và sao dự đoán đạt tới r = 0.978 (gần tiệm cận giá trị 1.0 lý tưởng)! Hệ số xác định R^2 đạt trên 95%, chứng minh mô hình nắm bắt gần như hoàn hảo xu hướng chất lượng của sản phẩm.
- **4. Độ chính xác quyết định kinh doanh đạt 95.4% - 99.7%:** Độ chính xác phân loại sản phẩm Tốt / Không tốt đạt 95.4% trên toàn bộ 500 sản phẩm; và đạt tới 99.7% đối với 292 sản phẩm có điểm sao cách ngưỡng ranh giới 3.0 ít nhất 0.5 sao.

14.7 Kiểm chứng độ nhạy của từ điển khía cạnh

Bên cạnh việc kiểm chứng số sao, nhóm tiến hành kiểm chứng độc lập độ nhạy của từ điển 9 khía cạnh trên mẫu gồm 3,000 bài nhận xét tiêu cực (1-2 sao) đối chiếu với 3,000 bài nhận xét tích cực (4-5 sao). Kết quả đo lường được trình bày ở Bảng 14.3:

Bảng 14.3: So sánh tỷ lệ gắn cờ phàn nàn giữa nhóm nhận xét 1-2 sao và 4-5 sao:

Khía cạnh sản phẩm	% Review 1-2 sao bị gắn cờ	% Review 4-5 sao bị gắn cờ	Hệ số chênh lệch (Lần)	Đánh giá độ nhạy
1. Giá cả / không đáng tiền	16.5%	1.5%	Gấp 11.0 lần	Độ nhạy cực cao: lời chê giá tập trung ở 1-2 sao
2. Hoạt động kém / không dùng được	5.7%	0.5%	Gấp 11.4 lần	Đặc trưng tuyệt đối: chỉ xuất hiện ở bài chê
3. Kích cỡ / vừa vặn	2.6%	0.3%	Gấp 8.7 lần	Độ nhạy rất cao: lời phàn nàn size tập trung ở 1-2 sao
4. Dịch vụ khách hàng & đổi trả	7.6%	0.9%	Gấp 8.4 lần	Độ nhạy rất cao: bức xúc dịch vụ tập trung ở bài chê
5. Chất lượng sản phẩm	12.4%	1.7%	Gấp 7.3 lần	Độ nhạy cao: chê chất lượng kém tập trung ở 1-2 sao
6. Độ bền / hỏng hóc	6.9%	1.0%	Gấp 6.9 lần	Độ nhạy cao: hỏng hóc linh kiện tập trung ở bài chê
7. Trải nghiệm nội dung (Sách, Phim)	22.2%	3.7%	Gấp 6.0 lần	Độ nhạy cao: chê nội dung dở tập trung ở 1-2 sao
8. Giao hàng & đóng gói	3.1%	0.5%	Gấp 6.2 lần	Độ nhạy cao: phàn nàn giao hàng chậm tập trung ở 1-2 sao
9. Không đúng mô tả	4.6%	1.1%	Gấp 4.2 lần	Độ nhạy tốt: khiếu nại mô tả sai lệch tập trung ở 1-2 sao

Kết luận từ Bảng 14.3: Tất cả 9 khía cạnh đều có tỷ lệ xuất hiện ở nhóm bài chê (1-2 sao) cao hơn từ 4.2 đến 11.4 lần so với nhóm bài khen (4-5 sao). Điều này chứng minh từ điển Regex và bộ lọc xác suất P_{neg} >= 0.50 hoạt động cực kỳ ổn định, phân biệt chính xác giữa lời phàn nàn thực sự và các lời khen có chứa từ khóa khía cạnh.

14.8 Một số hạn chế của phương pháp chẩn đoán

Mặc dù đạt được những kết quả kiểm chứng ấn tượng, phương pháp chẩn đoán hiện tại vẫn tồn tại một số hạn chế kỹ thuật: thứ nhất, phương pháp dựa trên từ điển Regex cố định nên

chưa tự động cập nhật được các tiếng lóng mới phát sinh của giới trẻ; thứ hai, đối với các sản phẩm có quá ít đánh giá (dưới 10 bài), khoảng tin cậy Bootstrap sẽ rất rộng, đòi hỏi hệ thống phải cảnh báo người dùng không nên vội vàng đưa ra quyết định kinh doanh lớn khi chưa có đủ dữ liệu.

CHƯƠNG 15: CẨM NANG VẤN ĐÁP BẢO VỆ ĐỒ ÁN (30 CÂU HỎI VÀ LỜI GIẢI CHI TIẾT)

15.1 Kế hoạch phân bổ thời gian và cấu trúc bài thuyết trình 10-12 phút

Để bảo vệ đồ án thành công trước Hội đồng chấm thi, việc phân bổ thời gian thuyết trình một cách kỷ luật và khoa học là yếu tố then chốt. Bài thuyết trình chuẩn mực kéo dài trong khoảng 10 đến 12 phút, sau đó là 10 đến 15 phút vấn đáp chuyên sâu với Hội đồng. Chiến lược phân bổ nội dung 4 phần đỉnh cao gồm:

- **Phần 1 - Đặt vấn đề và Thấu hiểu dữ liệu (2.5 phút):** Nêu tính cấp thiết của dữ liệu phản hồi Amazon; thách thức của bài toán 5 mức sao (Baseline ngẫu nhiên chỉ 20.0%, tính mơ hồ thứ bậc); giới thiệu tập dữ liệu chuẩn 3.65 triệu bản ghi; cơ chế đọc PyArrow siêu tốc 5.1 giây (Hình 2.1).
- **Phần 2 - Tiền xử lý và Khai phá không giám sát (3.5 phút):** Trình bày chiến lược bảo toàn 10 từ phủ định trong stop words; quy luật chữ U của dấu cảm thán và 7 đặc trưng hình thái (Hình 4.1); cấu trúc ma trận thưa TF-IDF 50,000 chiều tiết kiệm RAM (294 MB); kết quả LSA 100 chiều (Hình 6.1); phân cụm MiniBatchKMeans k=6 theo hệ số Silhouette (Hình 7.1); và các luật kết hợp có Lift cao nhất (Hình 8.1).
- **Phần 3 - Huấn luyện có giám sát và Đánh giá thực nghiệm (3.5 phút):** Trình bày quá trình tinh chỉnh alpha trên tập kiểm định độc lập (Hình 9.1); bảng đối sánh hiệu năng 3 mô hình trên tập test 97,500 mẫu (Hình 10.1); khẳng định vị trí Quán quân của SGD Logistic Regression (Accuracy 54.48%, Off-by-one 89.14%, MAE 0.612); phân tích ma trận nhầm lẫn (Hình 11.1) và trọng số từ khóa quyết định (Hình 12.1).
- **Phần 4 - Ứng dụng thực tế và Kết luận (2.0 phút):** Minh họa quy trình suy luận trực tiếp thời gian thực; trình bày hệ thống chẩn đoán 9 khía cạnh trên sản phẩm thử nghiệm (Hình 14.1, 14.2, 14.3); nhấn mạnh kết quả kiểm chứng khoa học trên 500 sản phẩm mô phỏng (tương quan Pearson r = 0.978, MAE = 0.178 sao - Hình 14.4); tóm tắt đóng góp và hướng phát triển.

15.2 Bộ 30 câu hỏi vấn đáp chuyên môn hóc búa kèm lời giải chi tiết

Câu 1: Tại sao bài toán này là Khai phá Dữ liệu (Data Mining) chứ không chỉ đơn thuần là Học máy (Machine Learning)?

Trả lời: Dạ thưa Thầy/Cô, Học máy chỉ tập trung vào việc huấn luyện mô hình để tối ưu hóa hàm mất mát và dự đoán nhãn. Trong khi đó, Khai phá Dữ liệu bao trùm toàn bộ quy trình CRISP-DM từ thấu hiểu dữ liệu lớn, quản lý bộ nhớ ma trận thưa, khám phá tri thức không giám sát (LSA tìm chủ đề ẩn, KMeans phân cụm hành vi theo Silhouette, Khai phá luật kết hợp Apriori với độ đo Lift), đến việc giải mã trọng số mô hình (Feature Importance) và xây dựng hệ thống chẩn đoán khía cạnh (ABSA) để phát hiện nguyên nhân gốc rễ phục vụ ra quyết định kinh doanh. Do đó, đề tài là một công trình Khai phá Dữ liệu hoàn chỉnh từ dữ liệu thô đến tri thức hành động.

Câu 2: Thuật toán TruncatedSVD khác gì so với PCA thông thường? Tại sao nhóm không dùng PCA?

Trả lời: Dạ thưa Thầy/Cô, PCA tiêu chuẩn bắt buộc phải thực hiện bước trừ giá trị trung bình của từng đặc trưng (Mean Centering). Trên ma trận TF-IDF có kích thước 600,000 x 50,000 với độ thưa 99.89%, nếu trừ trung bình, toàn bộ các phần tử mang giá trị 0 sẽ biến thành các số thực khác 0. Điều này phá hủy hoàn toàn cấu trúc ma trận thưa CSR và biến nó thành ma trận dày đặc tiêu tốn tới 240 GB RAM, gây tràn bộ nhớ OOM ngay lập tức. TruncatedSVD phân rã trực tiếp trên ma trận thưa CSR mà không cần trừ trung bình, giữ nguyên vẹn tính thưa và hoàn thành trong 16.2 giây.

Câu 3: Tỷ lệ phương sai giải thích được của SVD 100 chiều là 7.7% có phải là quá thấp không?

Trả lời: Dạ thưa Thầy/Cô, 7.7% là con số hoàn toàn bình thường và mang tính quy luật trong Xử lý Ngôn ngữ Tự nhiên. Không gian từ vựng 50,000 chiều n-grams có độ thưa lên tới 99.89%, phần lớn thông tin nằm ở đuôi dài (Long-tail) của hàng chục nghìn từ hiếm theo quy luật Zipf. 100 chiều tiềm ẩn của LSA đã nắm bắt được bộ khung ngữ nghĩa khái quát nhất của các nhóm sản phẩm (sách, phim, nhạc, đồ dùng). Phát hiện này cũng giải thích cơ sở vì sao khi phân loại cảm xúc 5 mức sao chi tiết, việc dùng trực tiếp ma trận thưa 50,000 chiều cho kết quả vượt trội hơn dùng 100 chiều LSA.

Câu 4: Căn cứ khoa học nào giúp nhóm lựa chọn số cụm k = 6 trong thuật toán MiniBatchKMeans?

Trả lời: Dạ thưa Thầy/Cô, nhóm căn cứ vào Hệ số Silhouette (Silhouette Coefficient) được khảo sát trên mẫu 10,000 quan sát với k thuộc {4, 6, 8, 10}. Kết quả đo lường cho thấy: k = 4 đạt 0.0409; k = 6 đạt đỉnh cực đại 0.0480; k = 8 giảm xuống 0.0309; k = 10 đạt 0.0376. Hệ số Silhouette đạt đỉnh tại k = 6 chứng minh cấu trúc dữ liệu phân tách tối ưu nhất tại 6 cụm. Khi kiểm tra từ vựng, 6 cụm này phân tách rất rõ ràng các nhóm sản phẩm thực tế: Sách, Phim ảnh, Âm nhạc, Đồ công nghệ, Đồ dùng chung và Nhóm cảm xúc mạnh.

Câu 5: Ý nghĩa toán học của Hệ số Silhouette là gì? Giá trị âm hay dương thể hiện điều gì?

Trả lời: Dạ thưa Thầy/Cô, hệ số Silhouette s(i) = [b(i) - a(i)] / max(a(i), b(i)), trong đó a(i) là khoảng cách trung bình nội cụm, và b(i) là khoảng cách trung bình tới cụm gần nhất. Hệ số nhận giá trị trong khoảng [-1, 1]. Nếu s(i) > 0: khoảng cách tới cụm khác lớn hơn khoảng cách trong cụm, mẫu được gán cụm đúng đắn. Nếu s(i) gần 0: mẫu nằm ở vùng ranh giới giữa hai cụm. Nếu s(i) < 0: mẫu gần cụm lân cận hơn cụm hiện tại, tức là đã bị gán nhầm cụm.

Câu 6: Luật kết hợp (Association Rules) trong đồ án được mô hình hóa thế nào? Độ nâng Lift có ý nghĩa gì?

Trả lời: Dạ thưa Thầy/Cô, nhóm mô hình hóa mỗi bài đánh giá là một 'Giao dịch' (Transaction), các từ khóa n-grams và nhãn số sao là các 'Hạng mục' (Items). Luật có dạng: {Từ khóa} -> {k Sao}. Độ đo Lift = Confidence / P(k Sao). Vì dữ liệu cân bằng nên P(k Sao) = 0.20 (20.0%). Lift đo lường từ khóa làm tăng xác suất xuất hiện của số sao lên bao nhiêu lần so với ngẫu nhiên. Ví dụ, luật {zero stars} -> {1 sao} có Lift = 4.81 nghĩa là khi xuất hiện cụm từ 'zero stars', xác suất bài viết thuộc 1 sao tăng vọt gấp 4.81 lần so với mức ngẫu nhiên.

Câu 7: Khảo sát cụm từ phủ định (Negation Bigrams) đem lại phát hiện đột phá gì?

Trả lời: Dạ thưa Thầy/Cô, phát hiện đột phá nhất là hiện tượng trung lập hóa của cụm từ 'not bad': Từ 'bad' đứng riêng là từ tiêu cực mạnh, nhưng cụm Bigram 'not bad' có tới 49.30% ở 3 sao (trung lập) và 18.91% ở 4 sao (khá tốt)! Chỉ có 7.17% ở 1 sao. Ngược lại, 'not waste' dồn 71.50% vào 1 sao, và 'not buy' dồn 57.97% vào 1 sao. Điều này chứng minh sắc thái của từ phủ định phụ thuộc hoàn toàn vào từ đi kèm phía sau, khẳng định vai trò không thể thay thế của N-grams.

Câu 8: Tại sao nhóm lựa chọn SGD Logistic Regression thay vì các mô hình Deep Learning như BERT hay RoBERTa?

Trả lời: Dạ thưa Thầy/Cô, việc lựa chọn dựa trên sự cân đối tối ưu giữa 3 yếu tố: Hiệu năng, Tài nguyên và Tính diễn giải: 1. Về tài nguyên: Fine-tune mô hình Transformer như BERT trên 3.65 triệu dòng đòi hỏi GPU cụm máy chủ với VRAM lớn và nhiều ngày tính toán. Trong khi đó, SGD Logistic Regression huấn luyện xong 600,000 dòng chỉ mất đúng 12.33 giây trên CPU máy tính cá nhân. 2. Về hiệu năng: SGD LR đạt Accuracy 54.48%, tiệm cận sát nút kết quả công bố của Yann LeCun tại NeurIPS 2015 (54.64%). 3. Về tính diễn giải: Logistic Regression là mô hình tuyến tính minh bạch, cho phép trích xuất trọng số coef_ để giải thích từ khóa quyết định và xây dựng hệ thống chẩn đoán khía cạnh.

Câu 9: Độ chính xác Accuracy 54.48% có phải là thấp không? Hãy bảo vệ con số này trước Hội đồng!

Trả lời: Dạ thưa Thầy/Cô, 54.48% là một kết quả rất xuất sắc và hoàn toàn đáp ứng yêu cầu cho bài toán 5 mức sao: 1. So với ngẫu nhiên: Trên bài toán 5 lớp cân bằng, đoán mò chỉ đạt 20.0%. Accuracy 54.48% cao hơn 2.72 lần so với Baseline ngẫu nhiên. 2. So với nghiên cứu quốc tế: Đây là bộ benchmark nổi tiếng thế giới của Yann LeCun (NeurIPS 2015), bài báo gốc của LeCun dùng n-grams cũng chỉ đạt 54.64%. 3. Quan trọng nhất: Thang đo 5 sao là dữ liệu thứ bậc có tính chủ quan lớn. Nếu xét chỉ số Off-by-one Accuracy (đúng hoặc lệch tối đa 1 sao), mô hình đạt tới 89.14% và sai số MAE chỉ 0.612 sao! Nghĩa là gần 90% các dự đoán giữ đúng hoàn toàn xu hướng cảm xúc của khách hàng.

Câu 10: Chỉ số Off-by-one Accuracy có ý nghĩa nghiệp vụ thực tế như thế nào?

Trả lời: Dạ thưa Thầy/Cô, sự khác biệt giữa 4 sao và 5 sao mang tính chủ quan của người viết: cùng một trải nghiệm tốt, người dễ tính cho 5 sao còn người kỹ tính cho 4 sao. Trong thương mại điện tử, việc hệ thống dự đoán một bài 4 sao thành 5 sao (hoặc 1 sao thành 2 sao) hoàn toàn không làm sai lệch bản chất quyết định kinh doanh. Chỉ số Off-by-one đạt 89.14% chứng minh mô hình hầu như không bao giờ đảo lộn giữa cực tốt và cực xấu (nhầm lẫn 1 sao thành 5 sao chỉ là 0.66%).

Câu 11: Nhóm xử lý dữ liệu lớn như thế nào để không bị tràn RAM trên máy 16GB?

Trả lời: Dạ thưa Thầy/Cô, nhóm áp dụng giải pháp 4 tầng kỹ thuật đồng bộ: 1. Dùng PyArrow Engine đọc dữ liệu theo khối cột Zero-Copy, nạp 3.65 triệu dòng trong 5.1 giây. 2. Sử dụng cấu trúc Ma trận thưa CSR của Scipy: ma trận 600,000 x 50,000 nếu là ma trận dày đặc sẽ tốn 240 GB RAM, nhưng dạng CSR chỉ tốn đúng 294 MB RAM (giảm hơn 800 lần). 3. Thiết lập tập mẫu phân tầng ngẫu nhiên 600,000 Train và 97,500 Test đảm bảo sai số biên <

0.126% theo Định lý Giới hạn Trung tâm. 4. Dùng thuật toán Hạ độ dốc Ngẫu nhiên (SGD) cập nhật trọng số theo từng mẫu nhỏ, không bao giờ phải nạp toàn bộ dữ liệu vào bộ nhớ đệm.

Câu 12: Tại sao trong danh sách Stop Words, nhóm cần giữ lại 10 từ phủ định?

Trả lời: Dạ thưa Thầy/Cô, trong danh sách Stop Words mặc định của NLTK hay Scikit-Learn, tất cả các từ phủ định như 'not', 'no', 'never' đều bị xóa. Nếu xóa từ 'not', hai câu trái ngược: 'The product is good' (5 sao) và 'The product is not good' (1 sao) sẽ cùng bị biến thành 'product good'! Hai sắc thái trái ngược bị biến thành chuỗi giống hệt nhau 100%. Nhóm đã giữ lại 10 từ phủ định cốt lõi để mô hình học được các cụm Bigram đảo nghĩa như 'not good', 'not bad'.

Câu 13: Tham số sublinear_tf=True trong TfidfVectorizer có tác dụng gì?

Trả lời: Dạ thưa Thầy/Cô, sublinear_tf thay thế tần số thô tf bằng công thức logarit: TF = 1 + ln(tf) khi tf > 0. Hàm logarit có đạo hàm giảm dần, giúp hạn chế sự bão hòa của các từ lặp lại nhiều lần trong bài nhận xét dài, đảm bảo các bài viết dài dòng không lấn át trọng số của các bài viết ngắn gọn súc tích.

Câu 14: Tại sao nhóm chọn Complement Naive Bayes thay vì Multinomial Naive Bayes truyền thống?

Trả lời: Dạ thưa Thầy/Cô, Multinomial Naive Bayes bị thiên lệch nặng khi độ dài văn bản không đều hoặc dữ liệu có độ thưa lớn. Complement Naive Bayes ước lượng xác suất trên phần bù của lớp (tất cả các lớp khác c), giúp cân bằng trọng số và đánh giá khách quan hơn. Thực nghiệm cho thấy CNB vượt trội MNB trên không gian ma trận thưa 50,000 chiều.

Câu 15: Tại sao SGD Linear SVM lại sử dụng hàm mất mát Modified Huber Loss thay vì Hinge Loss thông thường?

Trả lời: Dạ thưa Thầy/Cô, Hinge Loss truyền thống của SVM là hàm không khả vi tại điểm z = 1 và chỉ đưa ra khoảng cách biên cứng, không có phương thức tự nhiên để ước lượng xác suất P(y|x). Modified Huber Loss là hàm mất mát trơn (Smooth), khả vi liên tục bậc một, vừa duy trì được tính chất cực đại hóa biên an toàn của SVM, vừa cho phép gọi phương thức predict_proba để xuất ra xác suất Softmax tin cậy phục vụ hệ thống chẩn đoán khía cạnh.

Câu 16: Siêu tham số alpha trong SGD Classifier đóng vai trò gì? Tại sao alpha = 1e-05 là tối ưu?

Trả lời: Dạ thưa Thầy/Cô, alpha là hệ số điều chuẩn L2. Khi alpha < 1e-05 (như 1e-06), mức phạt quá yếu, mô hình bị quá khớp nhẹ (Overfitting). Khi alpha > 1e-05 (như 3e-04), mức phạt quá nặng, các trọng số bị ép về gần 0 làm mô hình bị dưới khớp (Underfitting). Đường cong Macro F1 trên tập kiểm định đạt đỉnh chuông úp chính xác tại alpha = 1e-05 cho cả SGD LR (52.44%) và SGD SVM (49.90%).

Câu 17: Lớp nào mô hình dự đoán tốt nhất và lớp nào hay bị nhầm lẫn nhất?

Trả lời: Dạ thưa Thầy/Cô, theo Classification Report, hai lớp đạt F1 cao nhất là 5 Sao (66.25%) và 1 Sao (65.95%) do từ ngữ khẳng định cảm xúc cực mạnh và rõ ràng. Lớp khó nhất là 3 Sao (F1 = 45.10%) và 2 Sao (F1 = 45.63%). Cặp nhầm lẫn phổ biến nhất là thực tế 4

sao bị đoán thành 5 sao (chiếm 28.54% số mẫu 4 sao), và thực tế 2 sao bị đoán thành 1 sao (chiếm 24.31%).

Câu 18: Hiện tượng châm biếm (Sarcasm) ảnh hưởng đến mô hình ra sao?

Trả lời: Dạ thưa Thầy/Cô, trong các câu châm biếm (như 'What a wonderful masterpiece of junk!'), người mua dùng từ ngữ tích cực mạnh để mỉa mai nhận xét 1 sao. Do mô hình TF-IDF cộng dồn trọng số từ vựng độc lập, các từ 'wonderful', 'masterpiece' có trọng số dương rất lớn, khiến mô hình tuyến tính bị đánh lừa dự đoán thành 5 sao. Đây là hạn chế kinh điển của mô hình túi từ.

Câu 19: Hệ thống chẩn đoán 9 khía cạnh sản phẩm hoạt động thế nào?

Trả lời: Dạ thưa Thầy/Cô, hệ thống hoạt động qua 4 bước: 1. Dự đoán số sao cho từng bài đánh giá của sản phẩm và tính sao trung bình cùng khoảng tin cậy Bootstrap 95%. 2. Lọc ra các bài đánh giá tiêu cực (1-2 sao) và tách thành từng câu đơn. 3. So khớp câu với từ điển 9 khía cạnh bằng Regex; câu phải thỏa mãn điều kiện xác suất tiêu cực P_neg >= 0.50 mới ghi nhận. 4. Xếp hạng các khía cạnh bị chê nhiều nhất và tự động xuất khuyến nghị hành động cải tiến kinh doanh tương ứng.

Câu 20: Khoảng tin cậy Bootstrap 95% cho số sao trung bình có ý nghĩa gì?

Trả lời: Dạ thưa Thầy/Cô, khi sản phẩm chỉ có một số lượng nhỏ bài đánh giá (ví dụ 12 hay 50 bài), số sao trung bình mẫu có thể có dao động ngẫu nhiên. Phương pháp Bootstrap lấy mẫu lặp lại 1,000 lần để ước lượng khoảng tin cậy 95% [CI_low, CI_high]. Nếu khoảng tin cậy nằm trọn trên 3.0: sản phẩm an toàn tốt. Nếu khoảng tin cậy chứa giá trị 3.0: hệ thống phát cảnh báo kết luận đang sát ranh giới, tránh đưa ra quyết định kinh doanh vội vàng.

Câu 21: Kết quả kiểm chứng trên 500 sản phẩm mô phỏng đạt kết quả ra sao?

Trả lời: Dạ thưa Thầy/Cô, trên 500 sản phẩm giả lập (tổng 25,000 bài nhận xét): - Sai số tuyệt đối trung bình (MAE) ở cấp độ sản phẩm chỉ là 0.178 sao! - Độ lệch trung bình Bias = +0.046 sao (gần như không thiên lệch). - Hệ số tương quan Pearson giữa sao thật và sao dự đoán đạt tới r = 0.978. - Độ chính xác phân loại sản phẩm tốt/xấu đạt 95.4% trên toàn bộ, và 99.7% đối với sản phẩm rõ ràng.

Câu 22: Tại sao tương quan Pearson trên 500 sản phẩm lại đạt tới r = 0.978 trong khi Accuracy cá thể chỉ là 54.48%?

Trả lời: Dạ thưa Thầy/Cô, đây là nguyên lý Luật số lớn (Law of Large Numbers) và tính chất triệt tiêu sai số trong thống kê: Ở cấp độ từng bài đánh giá riêng lẻ, sai số có thể xảy ra ở các lớp liền kề (lệch +1 hoặc -1 sao). Nhưng khi tổng hợp trung bình trên 50 bài nhận xét của một sản phẩm, các sai số lệch dương (+1) và sai số lệch âm (-1) sẽ triệt tiêu lẫn nhau, làm cho điểm sao trung bình dự đoán tiệm cận cực kỳ chính xác với điểm sao trung bình thực tế.

Câu 23: Kết quả kiểm chứng từ điển khía cạnh trên review 1-2 sao vs 4-5 sao cho thấy điều gì?

Trả lời: Dạ thưa Thầy/Cô, cả 9 khía cạnh trong từ điển đều có tỷ lệ xuất hiện ở nhóm bài chê (1-2 sao) cao hơn từ 4.2 đến 11.4 lần so với nhóm bài khen (4-5 sao). Ví dụ: phàn nàn về Giá cả xuất hiện ở 16.5% bài chê nhưng chỉ 1.5% bài khen (gấp 11 lần). Điều này chứng minh từ

điển Regex và bộ lọc P_neg >= 0.50 phân biệt rất chuẩn xác lời chê và không bắt nhầm lời khen.

Câu 24: Mô hình của nhóm có thể áp dụng cho dữ liệu tiếng Việt được không?

Trả lời: Dạ thưa Thầy/Cô, về mặt quy trình và kiến trúc thuật toán thì hoàn toàn tương thích 100%. Tuy nhiên cần điều chỉnh 2 thành phần ngôn ngữ: 1. Tách từ tiếng Việt: Tiếng Việt có từ ghép (như 'rất tốt', 'chất lượng kém'), cần sử dụng thư viện tách từ như PyVi hoặc Underthesea trước khi đưa vào TF-IDF. 2. Stop Words và Từ điển: Thay thế danh sách stop words tiếng Anh bằng tiếng Việt (giữ lại từ phủ định 'không', 'chẳng', 'chưa') và dịch bộ từ điển 9 khía cạnh sang tiếng Việt.

Câu 25: Tại sao nhóm không đưa trực tiếp 7 đặc trưng hình thái vào huấn luyện chung với ma trận TF-IDF?

Trả lời: Dạ thưa Thầy/Cô, đây là quyết định kỹ thuật dựa trên sự chênh lệch số chiều: ma trận TF-IDF có 50,000 chiều đã chuẩn hóa L2 (giá trị từ 0 đến 1). Nếu ghép thêm 7 đặc trưng hình thái, tỷ lệ chiều chỉ là 7 / 50,007 (chiếm 0.014%), tín hiệu của 7 đặc trưng sẽ bị không gian 50,000 từ vựng áp đảo hoàn toàn. Nhóm sử dụng 7 đặc trưng hình thái cho công đoạn Khám phá Dữ liệu (EDA) để hiểu sâu sắc hành vi tâm lý người viết.

Câu 26: Làm sao hệ thống phân biệt được giữa lỗi do sản phẩm và lỗi do người dùng sử dụng sai cách?

Trả lời: Dạ thưa Thầy/Cô, hiện tại mô hình thống kê tổng hợp tần suất phàn nàn. Nếu một lỗi xuất hiện ở nhiều bài nhận xét độc lập khác nhau (tỷ lệ phàn nàn > 20%), đó chắc chắn là lỗi thiết kế hoặc lỗi sản xuất mang tính hệ thống. Nếu lỗi chỉ xuất hiện ở 1 bài duy nhất trong số hàng trăm bài, hệ thống sẽ xếp vào nhóm thiểu số và không kích hoạt cảnh báo hành động.

Câu 27: Nếu tập dữ liệu ban đầu bị mất cân bằng trầm trọng (như 80% là 5 sao), nhóm sẽ xử lý thế nào?

Trả lời: Dạ thưa Thầy/Cô, nếu dữ liệu mất cân bằng trong thực tế, nhóm sẽ áp dụng 3 giải pháp: 1. Sử dụng trọng số lớp (class_weight='balanced') trong hàm mất mát của Logistic Regression để phạt nặng hơn khi đoán sai lớp thiểu số. 2. Áp dụng kỹ thuật lấy mẫu phân tầng hoặc Under-sampling có chọn lọc đối với lớp đa số. 3. Chuyển sang tối ưu hóa chỉ số Macro F1 và Balanced Accuracy thay vì Accuracy thuần túy.

Câu 28: Kích thước tệp mô hình đóng gói 4.8 MB có ý nghĩa gì đối với việc triển khai thực tế?

Trả lời: Dạ thưa Thầy/Cô, dung lượng 4.8 MB là một ưu điểm vượt trội so với các mô hình Deep Learning (thường nặng từ 400 MB đến vài GB). Tệp 4.8 MB có thể lưu trong bộ nhớ đệm RAM của bất kỳ máy chủ nào, nạp tức thời trong 0.1 giây, và dễ dàng triển khai lên các dịch vụ Serverless như AWS Lambda với chi phí gần như bằng 0 và khả năng chịu tải hàng nghìn truy vấn đồng thời.

Câu 29: Hạn chế lớn nhất của đồ án hiện tại là gì?

Trả lời: Dạ thưa Thầy/Cô, hạn chế lớn nhất là mô hình TF-IDF dạng túi từ vẫn chưa bắt được ngữ cảnh ngữ pháp sâu xa của các câu châm biếm, mỉa mai phức tạp; và từ điển 9 khía cạnh

dựa trên Regex cố định nên chưa tự động bao phủ được các tiếng lóng mới xuất hiện trên mạng xã hội.

Câu 30: Hướng nghiên cứu tiếp theo của nhóm nếu tiếp tục phát triển đề tài là gì?

Trả lời: Dạ thưa Thầy/Cô, nhóm hướng tới 2 nội dung nâng cấp: 1. Thử nghiệm kết hợp mô hình Transformer chưng cất (DistilBERT hoặc TinyBERT) để cải thiện khả năng phát hiện câu châm biếm mà vẫn duy trì tốc độ suy luận nhanh. 2. Nâng cấp mô-đun bóc tách khía cạnh bằng mô hình Gán nhãn chuỗi (Sequence Labeling như BiLSTM-CRF hoặc Span-ABSA) và đóng gói thành giao diện Web tương tác hoàn chỉnh bằng Streamlit.

CHƯƠNG 16: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

16.1 Tóm tắt toàn diện các kết quả khoa học đạt được

Đồ án môn học Khai phá Dữ liệu của Nhóm 9 với đề tài 'Khai phá Dữ liệu và Phân loại Cảm xúc Đánh giá Sản phẩm Amazon theo 5 Mức Sao' đã hoàn thành toàn diện, xuất sắc và vượt mức tất cả các mục tiêu nghiên cứu ban đầu được đề ra theo chuẩn quy trình công nghiệp CRISP-DM:

- **1. Quản lý Dữ liệu lớn và Lấy mẫu khoa học:** Đã làm chủ kỹ thuật nạp dữ liệu lớn bằng PyArrow Columnar Engine, đọc toàn bộ 3.65 triệu dòng trong 5.1 giây; kiểm định tính toàn vẹn và xử lý an toàn 214 dòng khuyết thiếu; thiết lập tập mẫu phân tầng ngẫu nhiên 600,000 Train và 97,500 Test bảo toàn tuyệt đối tính đại diện thống kê (sai số biên < 0.126%).
- **2. Tiền xử lý sâu và Kỹ thuật Ma trận thưa:** Đã xây dựng quy trình tiền xử lý bảo toàn 10 từ phủ định then chốt, chuyển hóa dấu câu cảm xúc thành token từ vựng; trích xuất 7 đặc trưng hình thái và phát hiện quy luật chữ U của dấu cảm thán; mô hình hóa không gian TF-IDF 50,000 chiều n-grams dạng ma trận thưa CSR chỉ chiếm 294 MB RAM (giảm hơn 800 lần so với ma trận dày đặc).
- **3. Khám phá Tri thức Không giám sát:** Đã triển khai thành công 3 kỹ thuật khai phá không giám sát: LSA TruncatedSVD 100 chiều giải mã 5 chủ đề lớn; phân cụm MiniBatchKMeans với đánh giá hệ số Silhouette chọn số cụm tối ưu k=6; và khai phá 27,575 luật kết hợp với độ đo Lift, khám phá hiện tượng trung lập hóa của cụm từ 'not bad' (49.3% ở 3 sao).
- **4. Học máy có giám sát và Đánh giá đa chiều:** Đã thực hiện tinh chỉnh siêu tham số alpha trên tập kiểm định độc lập cho 3 mô hình học máy; đánh giá toàn diện trên tập kiểm thử 97,500 mẫu. Mô hình SGD Logistic Regression xuất sắc giành vị trí Quán quân: Accuracy 54.48% (gấp 2.72 lần ngẫu nhiên), Macro F1 53.80%, Off-by-one Accuracy 89.14%, MAE 0.612 sao, và tốc độ suy luận đạt 1.6 triệu bài đánh giá / giây.
- **5. Ứng dụng Thực tế và Kiểm chứng Khoa học:** Đã đóng gói mô hình thành tệp joblib 4.8 MB; phát triển hệ thống ABSA 9 nhóm khía cạnh sản phẩm; thực hiện kiểm chứng khoa học trên 500 sản phẩm mô phỏng đạt hệ số tương quan Pearson r = 0.978, MAE cấp sản phẩm chỉ 0.178 sao, và độ chính xác phân loại sản phẩm đạt 95.4% - 99.7%.

16.2 Đóng góp học thuật và giá trị thực tiễn của đề tài

Về mặt học thuật, đồ án đã chứng minh một cách thuyết phục rằng: các mô hình tuyến tính học máy thống kê kết hợp với kỹ thuật trích xuất đặc trưng n-grams chất lượng cao và cấu trúc ma trận thưa hoàn toàn có khả năng đạt hiệu năng tiệm cận các mô hình Học sâu phức tạp trên các tập dữ liệu lớn, trong khi tiêu tốn tài nguyên phần cứng ít hơn hàng trăm lần và có tính diễn giải minh bạch cao.

Về mặt thực tiễn kinh doanh, hệ thống phân tích khía cạnh và chẩn đoán vấn đề sản phẩm do nhóm phát triển cung cấp một công cụ chuyển giao công nghệ trực tiếp cho các nhà bán hàng và doanh nghiệp thương mại điện tử: tự động hóa quy trình lắng nghe tiếng nói khách hàng,

phát hiện tức thời các khuyết tật sản phẩm hoặc sự cố giao vận, từ đó đưa ra các quyết định can thiệp kịp thời để bảo vệ doanh thu và uy tín thương hiệu.

16.3 Các hạn chế mang tính hệ thống

Bên cạnh các thành tựu nổi bật, đồ án vẫn còn một số giới hạn khoa học cần được nhìn nhận khách quan:

- • **Giới hạn biểu diễn ngữ nghĩa:** Mô hình dạng túi từ TF-IDF vẫn chưa xử lý trọn vẹn được các hiện tượng châm biếm, mỉa mai tinh vi và các cấu trúc phủ định có khoảng cách từ quá xa.
- • **Tính tĩnh của từ điển:** Bộ từ điển 9 khía cạnh hiện tại dựa trên biểu thức chính quy tĩnh, đòi hỏi sự can thiệp của chuyên gia ngôn ngữ để cập nhật định kỳ khi phát sinh các thuật ngữ mới.
- • **Phạm vi ngôn ngữ:** Đồ án mới tập trung thực nghiệm trên tập ngữ liệu tiếng Anh, chưa mở rộng trực tiếp sang các ngôn ngữ đơn lập có dấu thanh như tiếng Việt.

16.4 Kế hoạch nghiên cứu và mở rộng trong tương lai

Để tiếp tục hoàn thiện và nâng tầm hệ thống, nhóm đề xuất lộ trình nghiên cứu mở rộng trong tương lai gồm 3 hướng phát triển trọng tâm:

- **1. Nâng cấp mô hình biểu diễn ngữ nghĩa:** Thử nghiệm tích hợp các mô hình Transformer tiền huấn luyện kích thước nhỏ được chưng cất tri thức (như DistilBERT, MobileBERT) để nâng cao độ chính xác nhận diện ngữ cảnh châm biếm mà vẫn đảm bảo tốc độ suy luận thời gian thực.
- **2. Tự động hóa trích xuất khía cạnh (Open-domain ABSA):** Nâng cấp mô-đun phân tích khía cạnh từ phương pháp dựa trên từ điển sang phương pháp Học sâu có giám sát: sử dụng mô hình Gán nhãn chuỗi (Sequence Labeling như BiLSTM-CRF hoặc mô hình Span-ABSA) để tự động phát hiện các khía cạnh mới chưa từng xuất hiện trong từ điển.
- **3. Phát triển sản phẩm phần mềm thương mại:** Đóng gói toàn bộ hệ thống thành một ứng dụng Web tương tác hoàn chỉnh trên nền tảng Streamlit hoặc FastAPI, kết nối trực tiếp với API của các sàn thương mại điện tử (như Shopee Open API) để xây dựng Dashboard phân tích thời gian thực phục vụ người bán hàng.

TÀI LIỆU THAM KHẢO CHUẨN KHOA HỌC (REFERENCES)

[1] Zhang, X., Zhao, J., & LeCun, Y. (2015). Character-level convolutional networks for text classification. Advances in Neural Information Processing Systems (NeurIPS 2015), 28, 649–657.

[2] McAuley, J., & Leskovec, J. (2013). Hidden factors and hidden topics: understanding rating dimensions with review text. Proceedings of the 7th ACM Conference on Recommender Systems (RecSys '13), 165–172.

[3] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Müller, A., Nothman, J., Louppe, G., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research (JMLR), 12, 2825–2830.

[4] Rennie, J. D., Shih, L., Teevan, J., & Karger, D. R. (2003). Tackling the poor assumptions of naive bayes text classifiers. Proceedings of the 20th International Conference on Machine Learning (ICML '03), 616–623.

[5] Bottou, L. (2010). Large-scale machine learning with stochastic gradient descent. Proceedings of COMPSTAT'2010, 177–186. Physica-Verlag HD.

[6] Salton, G., Wong, A., & Yang, C. S. (1975). A vector space model for automatic indexing. Communications of the ACM, 18(11), 613–620.

[7] Manning, C. D., Raghavan, P., & Schütze, H. (2008). Introduction to Information Retrieval. Cambridge University Press.

[8] Witten, I. H., Frank, E., Hall, M. A., & Pal, C. J. (2016). Data Mining: Practical Machine Learning Tools and Techniques (4th ed.). Morgan Kaufmann Publishers.

[9] Deerwester, S., Dumais, S. T., Furnas, G. W., Landauer, T. K., & Harshman, R. (1990). Indexing by latent semantic analysis. Journal of the American Society for Information Science, 41(6), 391–407.

[10] Agrawal, R., & Srikant, R. (1994). Fast algorithms for mining association rules. Proceedings of the 20th International Conference on Very Large Data Bases (VLDB '94), 487–499.

[11] Rousseeuw, P. J. (1987). Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. Journal of Computational and Applied Mathematics, 20, 53–65.

[12] Efron, B., & Tibshirani, R. J. (1994). An Introduction to the Bootstrap. Chapman & Hall / CRC Press.

[13] Pontiki, M., Galanis, D., Pavlopoulos, J., Papageorgiou, H., Androutsopoulos, I., & Manandhar, S. (2014). SemEval-2014 Task 4: Aspect Based Sentiment Analysis. Proceedings of the 8th International Workshop on Semantic Evaluation (SemEval 2014), 27–35.

[14] Liu, B. (2012). Sentiment Analysis and Opinion Mining. Synthesis Lectures on Human Language Technologies, 5(1), 1–167. Morgan & Claypool Publishers.