Phân loại đánh giá sản phẩm Amazon theo 5 mức sao



Đồ án môn Khai phá dữ liệu

Nguyễn Huỳnh Anh Tuấn | Lê Văn Tính | Nguyễn Anh Vũ

Lớp S26-65CNTT | GVHD: ThS. Vũ Thị Hạnh

Trường Đại học Thủy lợi, Bộ môn Công nghệ thông tin

Nội dung trình bày

1

Bài toán và dữ liệu

Vì sao bài toán khó, 3.65 triệu review

2

Tiền xử lý và biểu diễn văn bản

Giữ từ phủ định, TF-IDF với bigram

3

Khai phá không giám sát

LSA, KMeans, luật kết hợp

4

Mô hình, đánh giá và ứng dụng

3 mô hình, phân tích lỗi, chẩn đoán sản phẩm

Vì sao cần tự động đọc review

93%

người mua online nói review của người dùng trước ảnh hưởng đến quyết định mua

5–9%

doanh thu có thể mất khi điểm trung bình giảm 1 sao

80%+

dữ liệu số là văn bản tự do, cần text mining để chuyển thành số

Review quá nhiều để đọc tay, nên cần tự động hóa.

Nguồn: BrightLocal và Viện Nghiên cứu Tiếp thị Hoa Kỳ, theo báo cáo của nhóm.

Đoán số sao từ lời nhận xét

20%

xác suất đoán trúng nếu chọn ngẫu nhiên, vì 5 mức sao chia đều nhau

Đầu vào
Tiêu đề và nội dung review tiếng Anh

Đầu ra
Một nhãn từ 1 đến 5 sao

Ranh giới mờ

“Good product” được 5 sao, còn “Very good, highly recommend, but nothing in this world is truly perfect” chỉ được 4 sao.

Mỉa mai

“What a brilliant masterpiece of junk!” là review 1 sao, nhưng câu chữ toàn từ khen.

Phủ định

“not buy” rất tiêu cực, còn “not bad” gần như trung lập.

Quy trình CRISP-DM trong đồ án

1 Thấu hiểu nghiệp vụ

Biến thang 5 sao thành bài toán phân loại

2 Thấu hiểu dữ liệu

Khám phá 3.65 triệu bản ghi

3 Chuẩn bị dữ liệu

Tiền xử lý, đặc trưng, TF-IDF

4 Mô hình hóa

LSA, KMeans, 3 mô hình học máy

5 Đánh giá

8 chỉ số trên 97,500 mẫu test

6 Triển khai

Suy luận và chẩn đoán sản phẩm

Dữ liệu: 3.65 triệu review, chia đều 5 mức sao

3.65 triệu

review Amazon từ 1996 đến 2014 (Amazon Review Full Score, NeurIPS 2015)

Cân bằng sẵn: mỗi mức sao chiếm đúng 20%, không cần lấy mẫu lại.

Ít dữ liệu thiếu: chỉ 214 dòng thiếu tiêu đề, đã thay bằng chuỗi rỗng.

Cách chia dữ liệu

Phần dữ liệu	Số mẫu	Mỗi lớp
Train (mẫu)	600,000	120,000
Kiểm định	30,000	6,000
Test độc lập	97,500	19,500

Dữ liệu gốc: 3,000,000 mẫu train và 650,000 mẫu test, nhóm lấy mẫu phân tầng.

Xử lý dữ liệu lớn trên máy cá nhân

240 GB

nếu lưu ma trận TF-IDF 600,000 × 50,000 dạng dày

vài trăm MB

khi lưu dạng thưa CSR, chỉ giữ giá trị khác 0

Đọc nhanh

PyArrow đọc 3.65 triệu dòng trong 5.1 giây, nhanh gần 9 lần Pandas mặc định.

Lấy mẫu phân tầng

120,000 mẫu mỗi lớp ở train, 19,500 mẫu mỗi lớp ở test.

Sai số nhỏ

Sai số biên chỉ khoảng 0.126% ở độ tin cậy 95%.

Làm sạch nhưng giữ lại tín hiệu cảm xúc

Văn bản gốc

```
DO NOT BUY! Total garbage! Stopped working
after 2 days.
```



Sau tiền xử lý

```
do not buy exclam total garbage exclam
stopped working after 2 days
```

Ví dụ lấy từ Bảng 4.1 của báo cáo.

1 Làm sạch nhẹ

Chữ thường, bỏ thẻ HTML, URL và ký tự thừa.

2 Giữ từ phủ định

10 từ như not, never không bị xóa như stop word.

3 Dấu câu thành từ

“!” thành exclam, “?” thành quest để đi vào n-gram.

Không xóa từ phủ định khỏi stop words

The product is good.

Nhãn thật: 5 sao

Sau khi xóa stop words mặc định:

`product good`

The product is not good.

Nhãn thật: 1 đến 2 sao

Sau khi xóa stop words mặc định:

`product good`

Hai câu trái nghĩa thành một chuỗi giống hệt nhau.

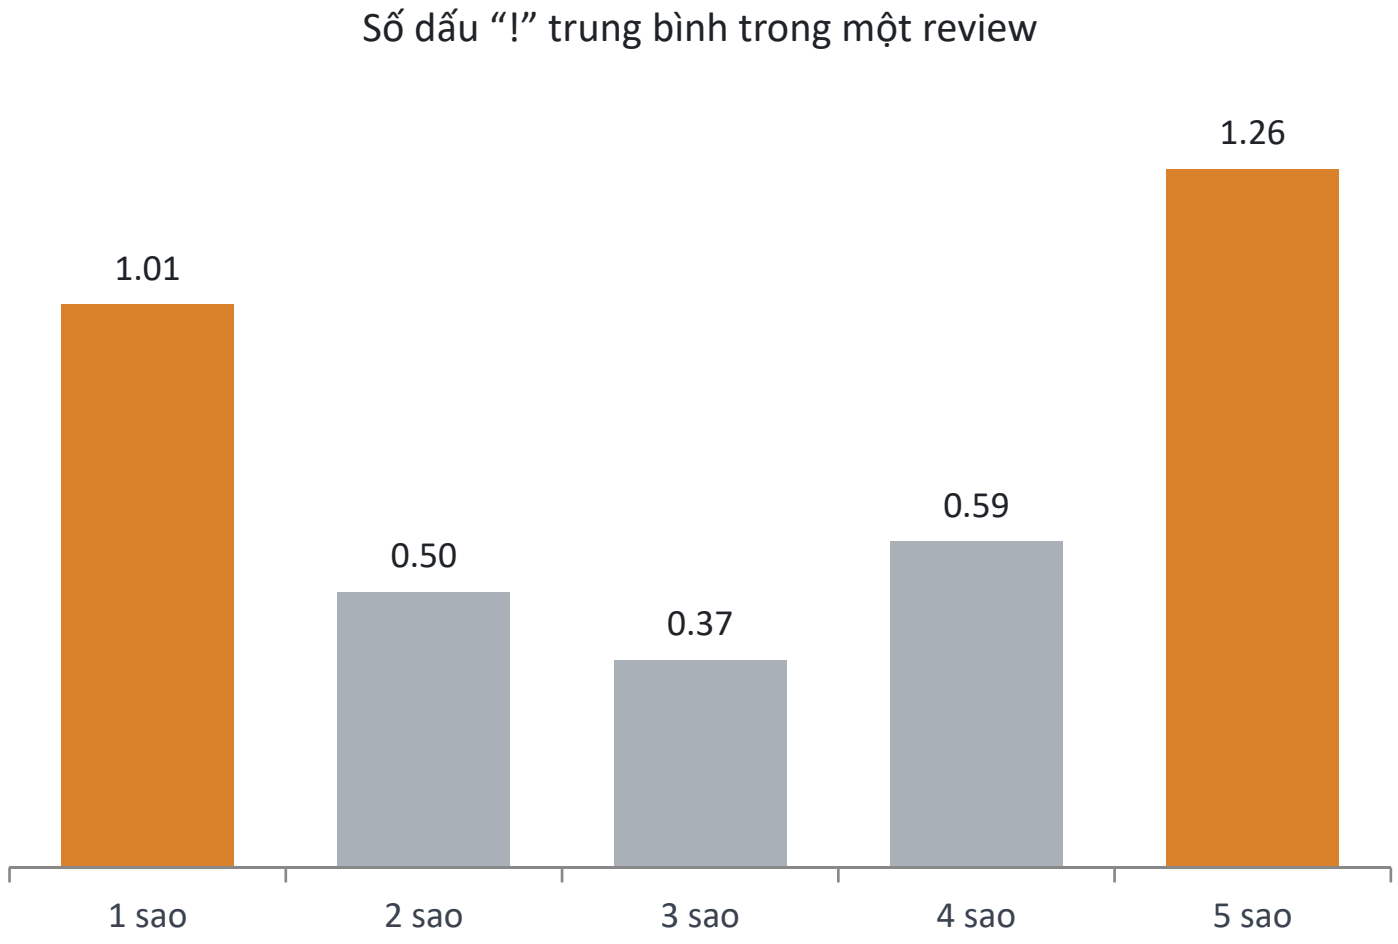
10 từ phủ định được giữ lại

```
cannot, neither, never, no,
nobody, none, nor, not,
nothing, without
```

+3.2%

Macro F1 tăng khi giữ từ phủ định cùng bigram.
Còn 308 stop words trung tính.

Dấu chấm than cao ở cả 1 sao lẫn 5 sao



Hình chữ U

Ở 1 sao và 5 sao, dấu “!” nhiều gấp 2.7 đến 3.4 lần so với 3 sao.

Dấu “?” giảm dần

Từ 0.320 ở 1 sao xuống 0.125 ở 5 sao.

Review 5 sao ngắn nhất

Trung bình 72 từ, trong khi 2 và 3 sao khoảng 87 từ.

Công thức TF-IDF trong đồ án

$$TF = 1 + \ln(tf)$$

$$IDF = \ln((1 + N) / (1 + df)) + 1$$

$$v = v / \sqrt{(\Sigma w^2)}$$

Sublinear TF

Từ lặp 20 lần không quan trọng gấp 20 lần, nên nén bằng logarit.

Smooth IDF

Từ hiếm có IDF lớn, từ phổ biến gần 1. Hằng số 1 tránh chia cho 0.

Chuẩn hóa L2

Mọi vector dài bằng 1, nên review dài hay ngắn đều công bằng.

Bigram giúp phân biệt “not bad” và “not good”

This product is good, not bad at all

Tích cực, 4 đến 5 sao

This product is bad, not good at all

Tiêu cực, 1 đến 2 sao

Chỉ dùng từ đơn thì hai câu có cùng tập từ, vector gần như giống nhau. Thêm bigram thì “not bad” và “not good” thành hai đặc trưng khác nhau.

50,000

đặc trưng từ đơn và bigram (1–2 gram)

99.89%

số ô bằng 0 trong ma trận, nên phải dùng ma trận thưa

Tham số: ngram (1, 2), max_features 50,000, min_df 3, max_df 0.6, sublinear_tf.

LSA: các chủ đề ẩn trong review

Chủ đề	Từ khóa tiêu biểu
Trải nghiệm chung	not, great, good, product
Sách	book, read, author, story
Phim và DVD	movie, film, watch, dvd
Âm nhạc	album, cd, songs, music
Cảm xúc mạnh	exclam, love, best, recommend

TruncatedSVD thay PCA

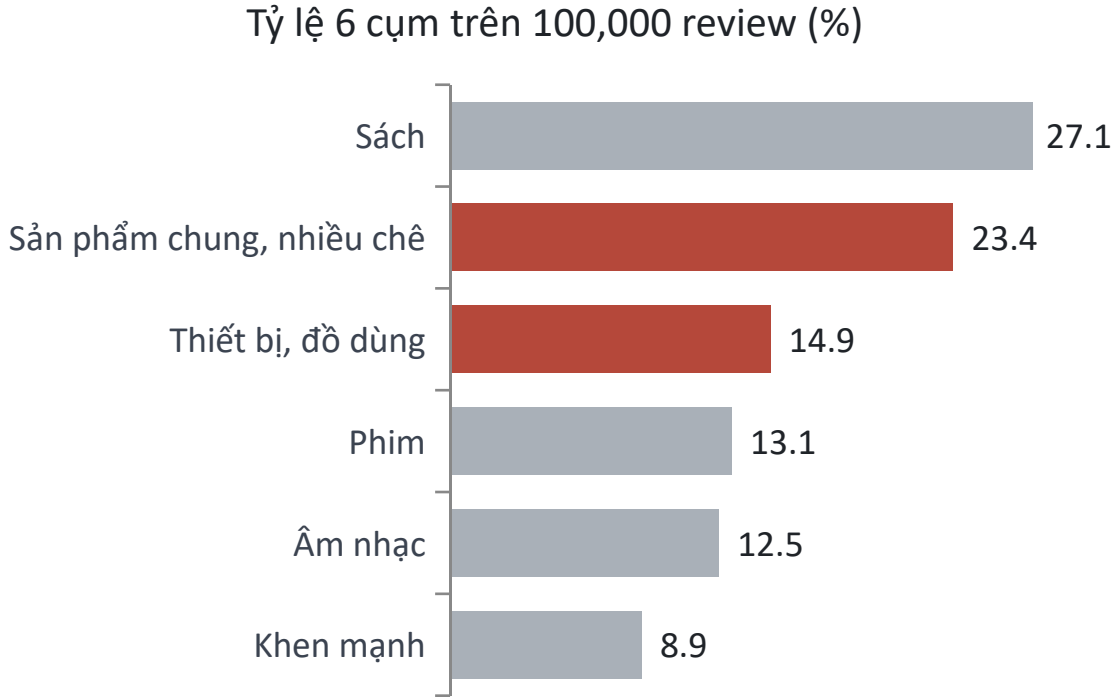
PCA làm ma trận thưa thành dày (240 GB). SVD chạy thẳng trên ma trận thưa, xong trong 16.2 giây.

Chỉ giữ 7.7% phương sai

LSA hợp để khám phá chủ đề, không dùng để phân loại sao.

MiniBatchKMeans: chọn k = 6 cụm





Cụm 0 và 4 (38.3% dữ liệu) chủ yếu là review 1 sao, nên ưu tiên hỗ trợ đổi trả.

Luật kết hợp: từ nào kéo theo mấy sao

Dẫn tới 1 sao

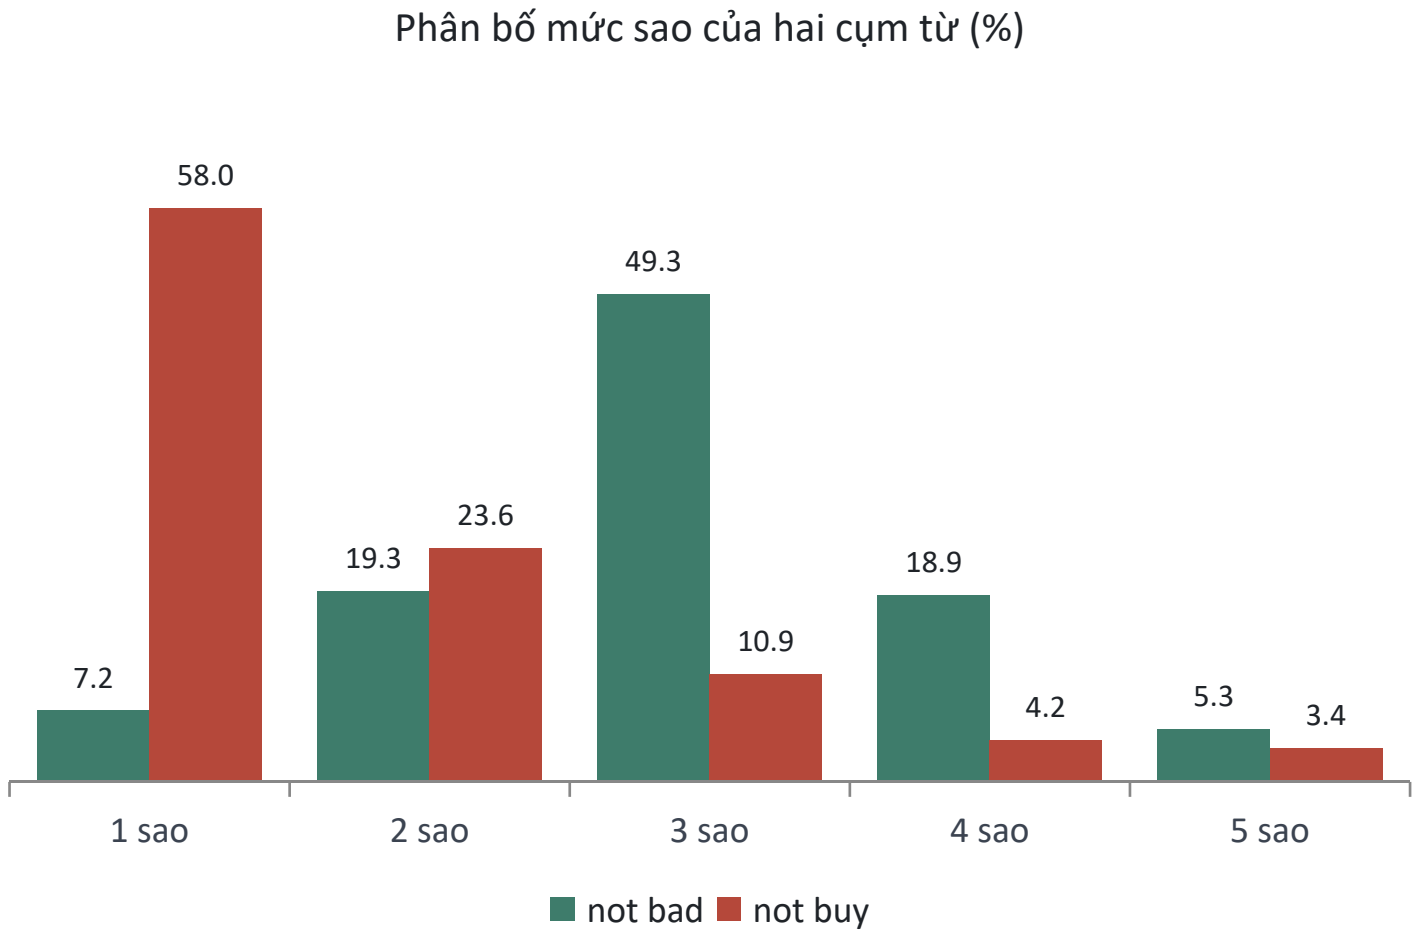
zero stars	**Lift 4.81** Confidence 93.70%
worst movies	**Lift 4.49** Confidence 87.38%
piece junk	**Lift 4.44** Confidence 86.50%

Dẫn tới 5 sao

excellent exclam	**Lift 3.67** Confidence 74.44%
fantastic exclam	**Lift 3.56** Confidence 72.16%
exclam highly	**Lift 3.55** Confidence 71.90%

Lift 4.81 nghĩa là khi review có “zero stars”, khả năng là 1 sao cao gấp 4.81 lần mức ngẫu nhiên 20%. 9 trong 10 luật mạnh nhất của 5 sao chứa token exclam.

“not” không phải lúc nào cũng tiêu cực



49.3%

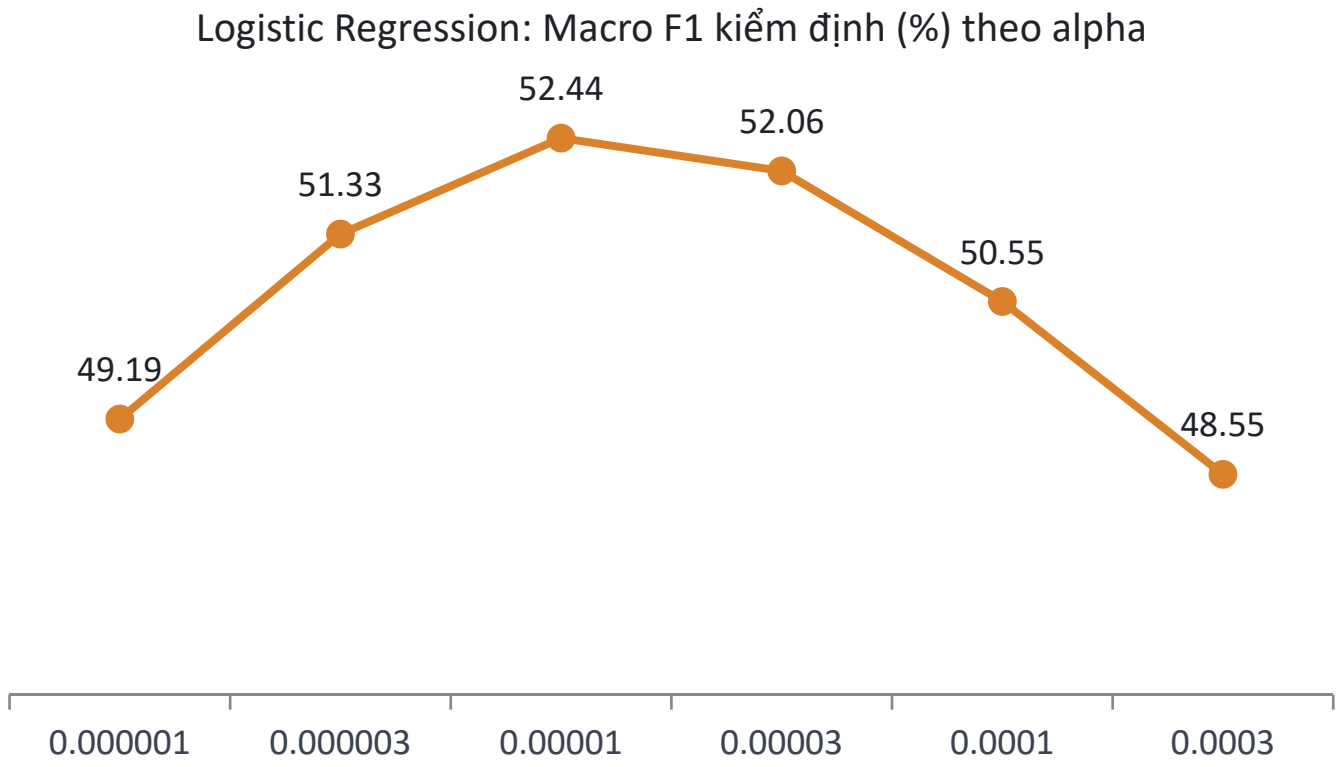
“not bad” rơi vào 3 sao, gần như trung lập

81.6%

“not buy” rơi vào 1 đến 2 sao, rất tiêu cực

Phân loại đánh giá Amazon theo 5 mức sao

Ba mô hình và cách chọn alpha



Alpha chọn trên tập kiểm định, không dùng tập test để tránh rò rỉ dữ liệu.

Complement NB

Alpha 1.0, Macro F1 47.00%

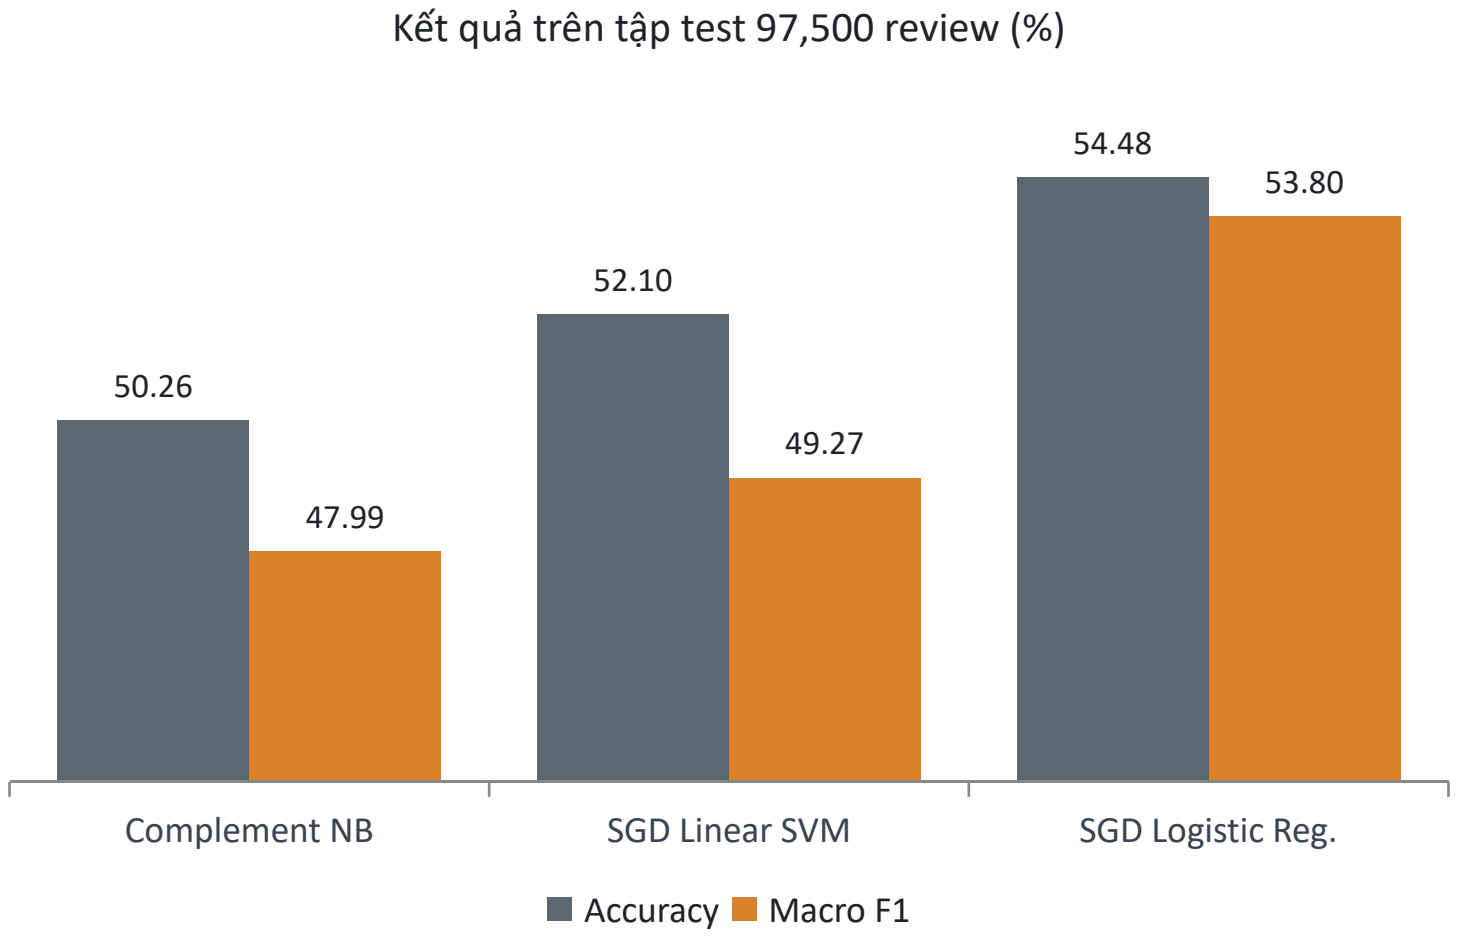
SGD Logistic Regression

Alpha 1e-5, Macro F1 52.44%

SGD Linear SVM

Alpha 1e-5, Macro F1 49.90%

Logistic Regression cho kết quả tốt nhất



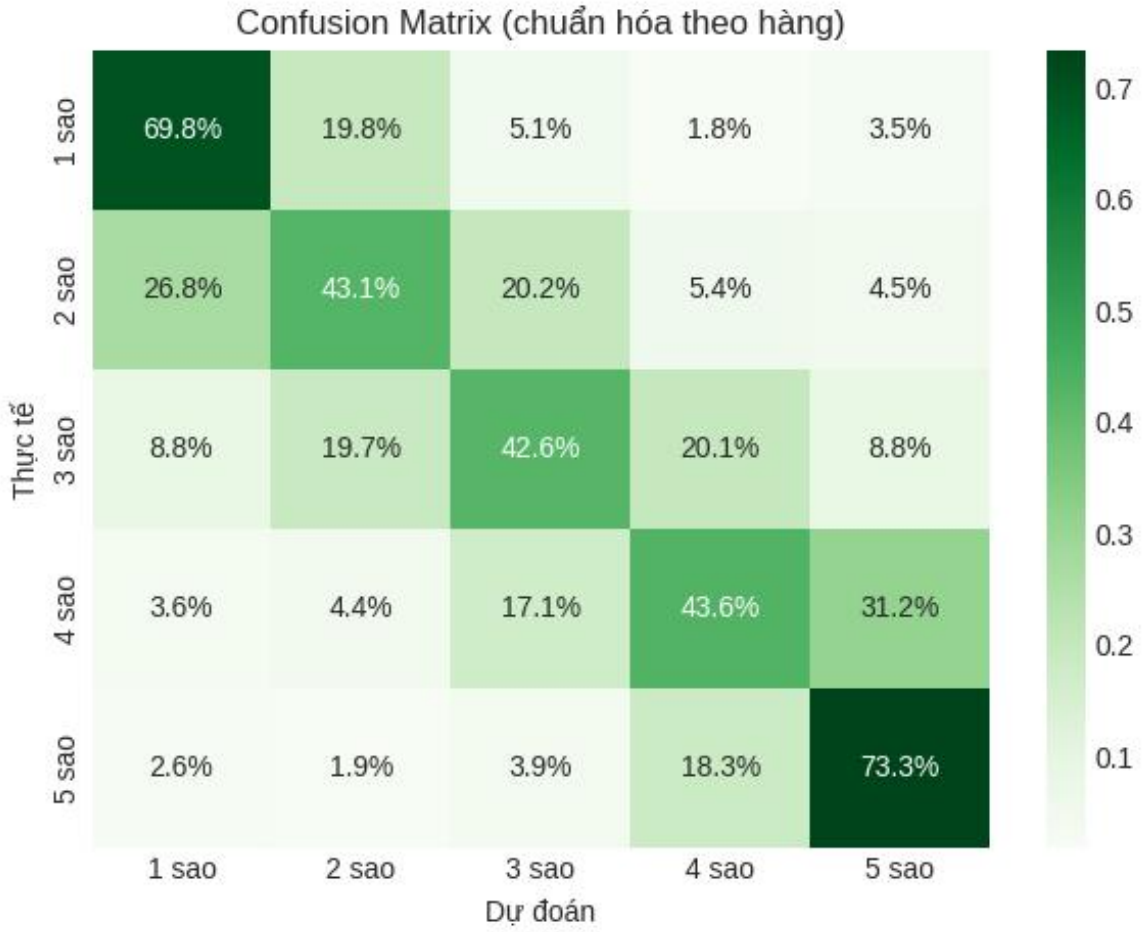
54.48%

Accuracy của Logistic Regression, gấp 2.72 lần mức ngẫu nhiên

Gần bằng bài gốc NeurIPS 2015: 54.64%

Dự đoán 97,500 review chỉ mất khoảng 0.06 giây

Sai lệch chủ yếu nằm ở 2, 3, 4 sao



89.14%

đoán đúng hoặc lệch tối đa 1 sao

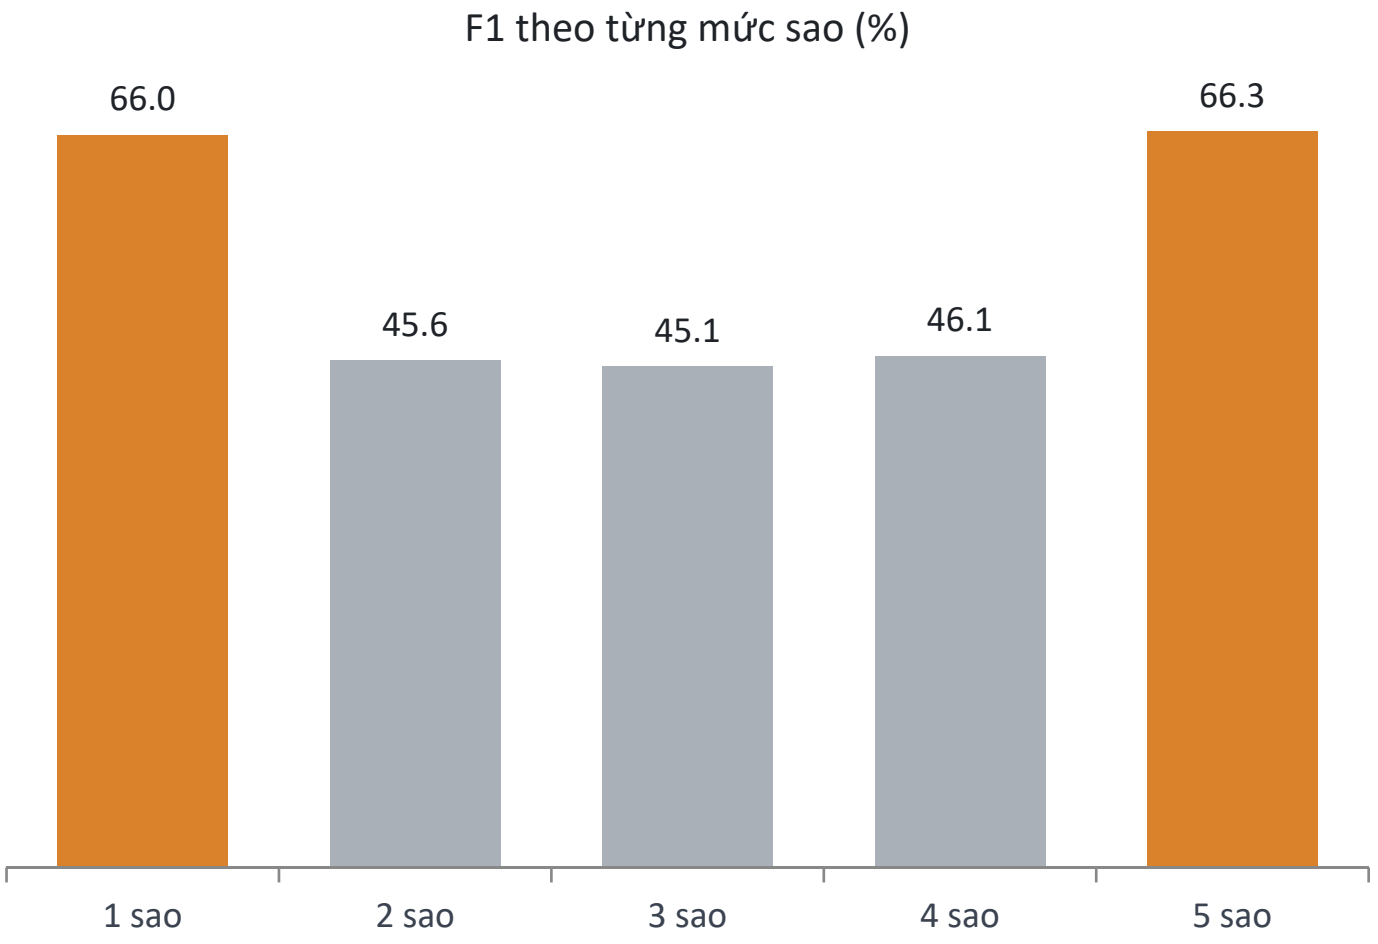
0.612

sao lệch trung bình (MAE)

- 4 sao bị đoán thành 5 sao tới 31.2%.
- 3 sao chia gần đều sang 2 sao (19.7%) và 4 sao (20.1%).
- Nhầm 1 sao thành 5 sao chỉ khoảng 3.5%.

Ma trận chuẩn hóa theo hàng (Hình 11.1 trong báo cáo).

Hai đầu thang dễ đoán, ba mức giữa khó hơn



Hai đầu: F1 khoảng 66%

Từ rất rõ như worst, waste, junk hoặc love, best, excellent.

Ba mức giữa: F1 khoảng 45–46%

Từ ngữ chồng lấn với mức liền kề. Người viết 4 sao hay dùng từ khen giống 5 sao.

Phân loại đánh giá Amazon theo 5 mức sao

Từ khóa quyết định của mô hình

Mức sao	Từ khóa có trọng số dương lớn nhất	Sắc thái
1 sao	waste, terrible, worst, junk, garbage, useless	**Bức xúc**
2 sao	not worth, disappointing, unfortunately, boring	**Thất vọng**
3 sao	ok, decent, average, not bad, mixed	**Có khen có chê**
4 sao	good, nice, solid, overall, recommended	**Hài lòng, còn điểm trừ**
5 sao	great, love, best, excellent, perfect	**Hài lòng tột độ**

Bốn kiểu dự đoán sai tiêu biểu

Mỉa mai

Thật 1 sao, đoán 5 sao

“A masterpiece of complete garbage! Wonderful way to throw 50 dollars into the fire!”

Mô hình cộng điểm từ khen, không hiểu châm biếm.

Khen nội dung, chê giao hàng

Thật 2 sao, đoán 4 sao

“The novel plot is brilliant and captivating, but delivery took 4 weeks and arrived torn.”

Từ khen mạnh lấn át từ chê.

Tiêu đề trái nội dung

Thật 1 sao, đoán 3 sao

Tiêu đề “Very bad”, nội dung toàn “works fine”, “decent”.

Nội dung dài hơn nên mô hình nghiêng về 3 sao.

Nhãn nhiễu

Thật 1 sao, đoán 5 sao

“I absolutely love this product! … Five stars!”

Người mua bấm nhầm. Mô hình đoán đúng bản chất văn bản.

Quy trình suy luận từ văn bản đến xác suất

1

Ghép chuỗi

Ghép tiêu đề + " . " + nội dung

2

Tiền xử lý

Chữ thường, bỏ HTML, giữ phủ định, "!" "?" thành token

3

Vector TF-IDF

Vector thưa 50,000 chiều với từ vựng đã khớp sẵn

4

Softmax

Điểm 5 mức sao thành xác suất, chọn mức cao nhất

Đóng gói gọn

Từ điển và mô hình nằm trong một tệp joblib 4.8 MB, nạp vào bộ nhớ dưới 0.1 giây.

Xác suất giúp quyết định

Một mức đạt 85% thì tự tin. Hai mức kề nhau 42% và 45% là ca mơ hồ, nên gắn cờ cho người đọc.

Thử suy luận trên ba review thực tế

Review	Dự đoán	Xác suất
“Terrible waste of money” Broke on the first day. Very bad quality. Do not buy!	**1 sao**	84.5%
“Average product” It works fine, but nothing special. Delivery took longer than expected.	**3 sao**	69.7%
“Totally exceeded my expectations!” Fast shipping, high quality material, and works perfectly.	**5 sao**	67.1%

Cả ba đều đúng. Mô hình bắt được các cụm “do not buy”, “waste of money” và từ khen mạnh như “exceeded”, “perfectly”.

Chẩn đoán sản phẩm bằng 9 nhóm khía cạnh

1

Dự đoán sao

Sao trung bình và khoảng tin cậy 95% (bootstrap 1,000 lần)

2

Phân loại chất lượng

Từ 3.5 và cận dưới từ 3.0 là rất tốt, dưới 3.0 là không tốt

3

Bóc khía cạnh

Chỉ lấy review 1–2 sao, câu phàn nàn khi P(1) + P(2) từ 0.5

4

Báo cáo

Top 3 vấn đề nghiêm trọng kèm gợi ý hành động

9 nhóm khía cạnh

Giao hàng, đóng gói	**Chất lượng**	**Độ bền, hỏng hóc**
Hoạt động kém	**Giá cả**	**Sai mô tả**
Kích cỡ, vừa vặn	**Dịch vụ, đổi trả**	**Nội dung sách, phim, nhạc**

Kiểm tra trên 6,000 review: cả 9 nhóm xuất hiện ở bài chê gấp 4.2 đến 11.4 lần bài khen.

Chẩn đoán thử trên 4 sản phẩm mô phỏng

Sản phẩm	Sao dự đoán	Sao thật	Vấn đề phát hiện
A: khen toàn diện	**4.06**	4.04	Không có vấn đề nổi cộm
B: chê giao hàng	**2.60**	2.52	Giá cả 33%, giao hàng 30%
C: chê chất lượng	**2.58**	2.40	Chất lượng 34%, độ bền 34%
D: chê giá và dịch vụ	**2.48**	2.48	Dịch vụ 44%, giá cả 41%

Sao dự đoán sát sao thật. Mỗi sản phẩm có 50 review, tỷ lệ vấn đề tính trên số review chê.

Kiểm chứng trên 500 sản phẩm mô phỏng

0.978

hệ số Pearson giữa sao thật và sao dự đoán

0.178

sao sai số trung bình ở cấp sản phẩm

+0.046

độ lệch trung bình, gần như không thiên lệch

95.4%

đoán đúng sản phẩm tốt hay không tốt

Cách kiểm chứng

500 sản phẩm mô phỏng, mỗi sản phẩm 50 review ngẫu nhiên từ tập test, tổng 25,000 review.

Vì sao sai số nhỏ

Sai số từng review là 0.612 sao. Gộp 50 review thì lệch lên và lệch xuống triệt tiêu, còn 0.178 sao.

Đây là sản phẩm mô phỏng từ tập test, chưa phải dữ liệu bán hàng thật. Với 292 sản phẩm cách mốc 3.0 ít nhất 0.5 sao, độ chính xác lên tới 99.7%.

Kết quả đạt được

Mô hình tuyến tính với TF-IDF n-gram: nhẹ, giải thích được và chạy trên máy cá nhân.

54.48%

Accuracy của Logistic Regression, gần bằng bài gốc (54.64%)

89.14%

đoán đúng hoặc lệch tối đa 1 sao, MAE 0.612

+3.2%

Macro F1 nhờ giữ từ phủ định và dùng bigram

0.978

Pearson ở cấp sản phẩm, sai số chỉ 0.178 sao

Hạn chế và hướng phát triển

Hạn chế

- TF-IDF chưa xử lý tốt mỉa mai và phủ định đứng xa nhau.
- Từ điển khía cạnh là regex tĩnh, phải cập nhật tay.
- Mới thử trên tiếng Anh, chưa có tiếng Việt.

Bước tiếp theo

- Thử DistilBERT hoặc MobileBERT cho câu mỉa mai.
- Tự tìm khía cạnh mới bằng BiLSTM-CRF.
- Làm web app Streamlit hoặc FastAPI cho người bán.

Xin cảm ơn hội đồng đã lắng nghe.